MPC monolítico del SMDFR

Contexto, formulación, resultados y próximos pasos

Proyecto DT–SMDFR Risk Control

9 de noviembre de 2026

Resumen

El controlador del gemelo digital del SMDFR decidía la corriente de la bomba del sistema de enfriamiento auxiliar (ACS) con optimizadores sin derivadas (Luus–Jaakola, GA) que simulan el ROM en Simulink para cada candidato: minutos por consulta y resultados que dependen de la semilla. Este documento resume la reformulación del problema como un *programa no lineal monolítico*, en el que las ecuaciones del ROM son restricciones, y los resultados obtenidos hasta ahora:

- una réplica algebraica del ROM con error de $\sim 10^{-6}$ K frente a Simulink;
- un NLP (N3) que resuelve la consulta en ~ 0.05 s, entre un 28 y un 56 % mejor que LJ y GA en la consulta de 1180 s;
- un QP linealizado (N1, N2) en forma monolítica y condensada (77 variables, ~ 10 ms) con certificado dual de optimalidad global para el modelo lineal. N2, iterado, converge al NLP;
- el primer análisis de riesgo (F4) con el ensamble MC-dropout de la BiLSTM regenerado: está mal calibrado, pero aun así no cambia la decisión;
- una revisión física de las cotas del actuador: la cota en amperios no tiene significado físico y la autoridad la fija la rampa del actuador;
- la certificación del P0 no lineal (F3c). La solución es un mínimo local estricto y el único óptimo en ≈ 590 arranques. La primera brecha certificada es de 2.3 % (1180 s) y 11.4 % (1161 s). Comparadas con la misma vara, N3 y N2 son las mejores decisiones, N1 queda a 0.0026 %, y LJ y GA quedan al menos un 28 % y un 43 % por encima del óptimo global.

1 Contexto y problema

El sistema. El SMDFR (*Small Modular Dual Fluid Reactor*, 100 MWt) usa combustible líquido y refrigerante de plomo. Caudal nominal del refrigerante: 5550.5 kg/s (Liu et al., 2021). El escenario es un LOCA de pequeña ruptura: el refrigerante se pierde por una fuga $\dot{m}_{\text{leak}}(t)$, el inventario M baja, con él baja el caudal primario $\dot{m}_c$, y la temperatura pico de vaina (PCT) sube. Por encima de 1180 K se demanda el ACS, que repone inventario con un caudal $\dot{m}_{\text{ACS}}(u)$ que se fija con la corriente u de una bomba MHD.

El gemelo digital y el controlador. Cada 0.5 s, entre 1160 y 1190 s, un MPC decide la secuencia de 26 acciones sobre un horizonte de 12.5 s:

- el modelo de predicción es un ROM de 17 estados (Simulink);
- una BiLSTM con MC-dropout pronostica la fuga;
- un árbol dinámico de eventos (DET) representa fallas y reparaciones de los componentes del ACS;

- el costo P0 penaliza el seguimiento de la PCT a una referencia, los cambios bruscos de caudal y la violación del límite de 1244 K.

El problema. P0 se resolvía con Luus–Jaakola (LJ) o un algoritmo genético (GA), que tratan el ROM como una caja negra. Cada evaluación es una simulación en Simulink, y cada consulta exige cientos de evaluaciones: unos 800 s. La acción aplicada depende de la semilla, y no hay garantía de optimalidad. Esto impide dos cosas: volver estocástico el MPC, que multiplica el número de escenarios, y cerrar el lazo en tiempo real, con una meta de menos de 120 s por consulta.

2 Plan de acción

La idea central es escribir las ecuaciones del ROM *una sola vez* en forma algebraica. De esa única fuente salen los cuatro niveles de modelo:

- N0, estado estacionario;
- N1, linealización en un punto (LTI);
- N2, linealización a lo largo de la trayectoria (LTV);
- N3, el modelo no lineal completo como restricciones.

El riesgo se agrega sobre esa base en tres capas de costo creciente: una restricción probabilística analítica, escenarios (SAA) y el escenario óptimo de Homem-de-Mello et al. (2026).

Etapa	Objetivo	Criterio de cierre	Estado
F0 Ecuaciones	ROM escrito término a término desde el `.slx`	Cada término trazado a un bloque	Cerrada
F1 Réplica	ROM algebraico con diferenciación automática (Julia)	Error $\ll 1$ K frente a Simulink	Cerrada
F2 NLP (N3)	P0 como NLP con JuMP + Ipopt	Comparado con LJ y GA re-simulando en Simulink	2 consultas
F3 QP (N1, N2)	MPC lineal (disperso y condensado), $G(s)$, certificado dual	Brecha frente a N3 medida	2 consultas
F3c Certificación	Brecha de optimalidad del P0 no lineal y comparación de decisiones	Brecha certificada pequeña	1–4b; 4b.5 pendiente
F4 Riesgo	Capas probabilística, SAA y cuantiles	Una decisión que cambie por riesgo	Abierta
F5 Lazo cerrado	61 consultas, multietapa	< 120 s por consulta; frontera costo–riesgo	Pendiente

Cuadro 1: Etapas del plan (detalle en `docs/monolithic_formulation_plan.md`).

2.1 Cómo se conectan las fases

Las fases no son tareas independientes. Cada una produce el insumo de la siguiente y, además, valida a la anterior. La figura 1 resume el flujo.

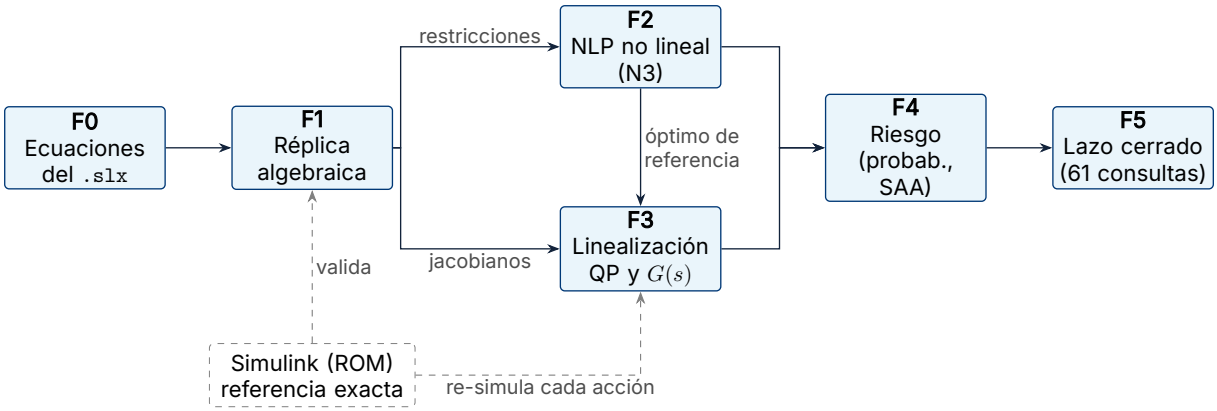


Figura 1: Flujo entre fases. Las flechas continuas indican qué produce cada fase para la siguiente: F2 y F3 dan a F4 un problema tratable, y F4 da a F5 la decisión con riesgo. Las discontinuas indican la validación contra Simulink, que se usa como referencia exacta.

F0 $\rightarrow$ F1: de un diagrama a ecuaciones verificables.
El ROM vivía repartido en bloques de Simulink. F0 lo escribe término a término y deja trazado cada término a un bloque. F1 lo programa en Julia, un lenguaje con *diferenciación automática*, y lo valida contra Simulink sobre la trayectoria archivada. Sin F1 no hay derivadas exactas, y sin derivadas no se puede usar un optimizador basado en gradiente.

F1 $\rightarrow$ F2: el modelo pasa a ser restricción.
La réplica validada se escribe como restricciones de igualdad de un NLP: el nivel N3, sin aproximar nada. F2 da el *óptimo de referencia* del modelo. Contra él se mide todo lo demás: los optimizadores sin derivadas (LJ, GA) y las aproximaciones de F3.

F1 $\rightarrow$ F3: la misma réplica, derivada.
Los jacobianos de la réplica (A, B, E y la salida) se obtienen por diferenciación automática, no con otro modelo. F3 construye con ellos el MPC lineal (un QP) y la función de transferencia, y mide su error contra F2. Si el error es pequeño, el modelo lineal es un sustituto legítimo.

F2, F3 $\rightarrow$ F4: el riesgo necesita un problema tratable.
Agregar incertidumbre multiplica el problema: por M escenarios en SAA, o con una restricción probabilística que exige propagar distribuciones. Esto sólo es viable si el problema determinista es rápido (F2) y, para las capas analíticas, lineal (F3).

F4 $\rightarrow$ F5: de una consulta al lazo.
F5 resuelve el problema elegido en cada una de las 61 consultas, con el estado real de cada instante, y mide el costo y el riesgo del lazo completo.

3 Fundamentos teóricos

3.1 Control predictivo de horizonte deslizante

En cada instante de consulta t_q, el MPC resuelve un *problema de control óptimo en lazo abierto* sobre un horizonte finito de K pasos, a partir del estado estimado $\hat{x}(t_q)$. Aplica sólo la primera acción y repite el cálculo en $t_q + \Delta t$ con la nueva medición. La realimentación nace de esa re-optimización: errores de modelo o de pronóstico se corrigen en la consulta siguiente. Por eso importan dos cosas: que el problema se resuelva en tiempo real, y que su solución sea *reproducible*. Una acción que cambia con la semilla del optimizador introduce ruido en el lazo.

3.2 De la caja negra a la transcripción directa

Hay dos maneras de plantear el problema de control óptimo:

- **Disparo simple** (*single shooting*): las únicas incógnitas son los controles $u_{0:K-1}$, y el costo se evalúa simulando el modelo. Es lo que hacen LJ y GA, que además no usan derivadas. Cada evaluación es una simulación completa, y la búsqueda explora a ciegas un espacio de 26 dimensiones.
- **Transcripción directa simultánea**: los estados $x_{0:K}$ también son incógnitas, y la dinámica entra como restricciones de igualdad $x_k = x_{k-1} + \Delta t\, f(x_k, d_k, u_k)$. El problema es más grande, pero cada restricción depende sólo de dos instantes consecutivos. Las matrices son *dispersas*, las derivadas son exactas y baratas, y el optimizador no necesita que la trayectoria sea factible en cada iteración. Eso ayuda con dinámicas rígidas o inestables.

La formulación "monolítica" es esta segunda: simulador y optimizador quedan fusionados en un solo problema.

3.3 Rigidez y Euler implícito

Los valores propios del jacobiano A van desde $-1.7 \cdot 10^3$ s^{-1} (la cinética neutrónica) hasta escalas de segundos o más lentas (la termohidráulica y el inventario). Un sistema con escalas tan separadas es *rígido*. Euler explícito sería estable sólo con $\Delta t < 2/1.7{\cdot}10^3 \approx 1.2$ ms, unas 400 veces menor que el paso del MPC. Euler implícito,

$$x_k = x_{k-1} + \Delta t\, f(x_k, d_k, u_k),$$

es A-estable y L-estable: los modos rápidos se amortiguan con cualquier Δt. Por eso permite $\Delta t = 0.5$ s. Su precisión es de primer orden. Pero como Simulink usa `ode1be`, el mismo esquema, la réplica reproduce el *mismo modelo discreto* y el error de discretización es idéntico en ambos.

3.4 Programación no lineal, condiciones KKT y punto interior

El NLP tiene la forma $\min_z \phi(z)$ con restricciones $c(z) = 0$ y $g(z) \le 0$. Un óptimo local satisface las condiciones de Karush–Kuhn–Tucker (KKT):

$$\nabla\phi + \nabla c^\top \lambda + \nabla g^\top \mu = 0, \qquad c = 0, \qquad g \le 0, \qquad \mu \ge 0, \qquad \mu_i g_i = 0.$$

Ipopt es un método de *punto interior primal-dual*. Reemplaza las desigualdades por una barrera logarítmica y resuelve las KKT perturbadas con pasos de Newton, que usan primeras y segundas derivadas. JuMP las obtiene por diferenciación automática.

Como el modelo es no lineal, el problema no es convexo, y Ipopt garantiza sólo un óptimo *local*. Por eso se lanzaron cuatro inicializaciones distintas, que llegaron al mismo óptimo. Eso es un indicio de unicidad, no una garantía. Las bisagras $[\cdot]_+^2$ del costo original no son dos veces diferenciables. Se reescriben con holguras ($s \ge 0$, $s \ge z$, costo s^2), lo que es exacto y deja el problema suave.

3.5 Linealización

La linealización es una expansión de Taylor de primer orden de la dinámica y de la salida alrededor de un punto $(\bar{x}, \bar{u}, \bar{d})$:

$$f(x,d,u) \approx \bar{f} + A(x-\bar{x}) + B(u-\bar{u}) + E(d-\bar{d}), \qquad A = \frac{\partial f}{\partial x},\ B = \frac{\partial f}{\partial u},\ E = \frac{\partial f}{\partial d}.$$

El error es de segundo orden en la distancia al punto. Por eso la calidad depende de cuánto se aleje la trayectoria. Hay dos variantes:

- **LTI (N1):** un solo punto para todo el horizonte. Es suficiente si la trayectoria no se aleja mucho de ese punto.
- **LTV (N2):** un punto por paso, $(\bar{x}_k, \bar{u}_k, \bar{d}_k)$, tomado de una trayectoria nominal no lineal. Si se itera (se linealiza, se resuelve, se re-simula y se vuelve a linealizar), el método es una programación cuadrática secuencial. Cuando converge, su punto fijo coincide con el óptimo del modelo no lineal.

Con la dinámica afín, el costo cuadrático y las restricciones lineales, el problema es un **QP convexo**: todo óptimo local es global, existen métodos con tiempo de cálculo acotado y predecible, y la dualidad entrega cotas certificadas del óptimo.

3.6 Riesgo: restricción probabilística, SAA y dos etapas

- **Restricción probabilística.** Se exige $\mathbb{P}(\hat{y}_k > U_y) \le \varepsilon$. Si el modelo es lineal y el error del pronóstico w es gaussiano, $\hat{y}_k = \bar{y}_k(u) + c_k^\top w$ también es gaussiano. Entonces la restricción equivale exactamente a

$$\bar{y}_k(u) + z_{1-\varepsilon}\,\sigma_k \le U_y, \qquad \sigma_k^2 = c_k^\top \Sigma c_k.$$

  La fuga entra de forma aditiva, así que σ_k no depende de u, y la restricción es un *ajuste lineal* de la cota: el QP sigue siendo un QP. Con el modelo no lineal no hay esa equivalencia.

- **SAA** (*sample average approximation*). Reemplaza la esperanza por el promedio sobre M escenarios muestreados. Al crecer M, el valor y las soluciones convergen a los del problema verdadero. Con M finito, el óptimo dentro de la muestra es optimista, con sesgo hacia abajo. Por eso cada decisión se evalúa *fuera de muestra*, con escenarios que no se usaron para optimizar.

- **Dos etapas y no anticipación.** La primera acción u_0 se decide antes de conocer qué escenario ocurre, así que debe ser común a todos. Las acciones posteriores son *recurso*: pueden adaptarse a cada escenario, porque en el lazo se re-optimizan con información nueva. Esto evita la sobreconfianza de una secuencia fija en lazo abierto.

- **Escenario óptimo** (Homem-de-Mello et al., 2026). En programas estocásticos de dos etapas con segunda etapa lineal y recurso fijo, una sola realización bien elegida puede reproducir la decisión estocástica. En el *newsvendor*, por ejemplo, es un cuantil de la demanda. Esto exige un modelo lineal y un costo en norma L_1: es otra razón para disponer de F3.

4 La formulación monolítica

Modelo de predicción (ROM, 17 estados). Estado $x = (N, C_{1..6}, C^e_{1..6}, T_f, T_w, T_c, \Delta M)$. Cinética puntual con precursores circulantes y termohidráulica de tres nodos (combustible, pared y refrigerante):

$$\dot{N} = \tfrac{\rho-\beta}{\Lambda} N + \textstyle\sum_i \lambda_i C_i, \qquad \dot{C}_i = \tfrac{\beta_i}{\Lambda} N - (\lambda_i + \lambda_c) C_i + \lambda_e C_i^e, \qquad \dot{C}_i^e = \lambda_c C_i - (\lambda_i + \lambda_e) C_i^e,$$

$$\rho = \rho_0 + \alpha_f (T_f - \bar{T}_{f0}) + \alpha_c (T_c - \bar{T}_{c0}), \qquad P = \tfrac{P_0}{N_0} N,$$

$$M_w c_{pw} \dot{T}_w = h_{fw} A_{fw} (T_f - T_w) - h_{wc}(\dot{m}_c) A_{wc} (T_w - T_c),$$

con ecuaciones análogas para T_f y T_c. El control entra sólo por el inventario:

$$\Delta\dot{M} = \dot{m}_{\text{leak}}(t) + \dot{m}_{\text{ACS}}, \qquad \dot{m}_c = \dot{m}_{\text{nom}}\frac{M_c + \Delta M}{M_c}, \qquad h_{wc} = h_{wc0}\Big(\frac{\dot{m}_c}{5550}\Big)^{0.8},$$
$$\hat{y} = T_w + p_4(\dot{m}_{\text{leak}} + \dot{m}_{\text{ACS}} + 5550) + 0.4,$$

donde $\hat{y}$ es la PCT estimada y p_4 es una regresión de grado 4 del desvío entre el HRM y el ROM.

P0 como NLP. La decisión pasa a ser el caudal $\dot{m}_{\text{ACS}}$, y la corriente se recupera con el mapa inverso de la bomba. La dinámica se impone con Euler implícito, igual que el integrador `ode1be` de Simulink. Las bisagras $[\cdot]_+^2$ del costo se reemplazan por holguras, lo que es exacto:

$$\begin{aligned}
\min_{\dot{m},\,x,\,s,\,r} \quad & \sum_{k=1}^{K}(\hat{y}_k - y_{\text{ref}})^2 + \lambda_m \sum_k s_k^2 + \lambda_{\text{pct}} \sum_k r_k^2 \\
\text{s.a.} \quad & x_k = x_{k-1} + \Delta t\, f(x_k, \hat{d}_k, \dot{m}_k), \quad x_0 = \hat{x}(t_q - \Delta t), \\
& |\dot{m}_{k+1} - \dot{m}_k| \le \Delta\dot{m} + s_k, \qquad \hat{y}_k - U_y \le r_k, \qquad s, r \ge 0, \qquad \dot{m}_{\min} \le \dot{m}_k \le \dot{m}_{\max},
\end{aligned}$$

con $K = 26$, $\Delta t = 0.5$ s, $U_y = 1244$ K, $\lambda_m = 10^{-4}$, $\Delta\dot{m} = 5$ kg/s y $\lambda_{\text{pct}} = 10$, los valores de `fitness_cost.m`. El problema tiene unas 520 variables libres (442 de estado, 26 de control y 51 holguras) y 442 restricciones de dinámica.

Escalado. $N \sim 10^{13}$ y $C_i \sim 10^{16}$ conviven con temperaturas de $\sim 10^3$ K. Por eso cada estado se escribe como $x_j = S_j z_j$, con $S_j = \max(|x_{j,0}|, 1)$. Sin este cambio, las matrices de Newton quedan mal condicionadas y Ipopt no converge de forma fiable.

Niveles del modelo. Este NLP es el nivel N3. Los niveles linealizados N1 y N2, cómo se resuelve cada uno y para qué sirven se detallan en la sección 5.

Riesgo (F4): SAA en dos etapas. Con M trayectorias $\hat{d}^{(j)}$ de fuga del ensamble MC-dropout, la primera acción $\dot{m}_0$ es común a todos los escenarios y el resto del horizonte es un recurso por escenario:

$$\min_{\dot{m}_0} \frac{1}{M}\sum_{j=1}^{M} \min_{\dot{m}^{(j)}_{1:K-1}} J_{\text{P0}}\big(\dot{m}_0, \dot{m}^{(j)}_{1:K-1}; \hat{d}^{(j)}\big).$$

Es la estructura de dos etapas que supone el teorema del escenario óptimo.

5 Los tres niveles del modelo: N3, N1 y N2

Los tres niveles resuelven *el mismo* problema P0, con el mismo costo y las mismas restricciones sobre el actuador. Lo único que cambia es cómo se representa la dinámica $x_k = x_{k-1} + \Delta t\, f(x_k, d_k, u_k)$ en las restricciones.

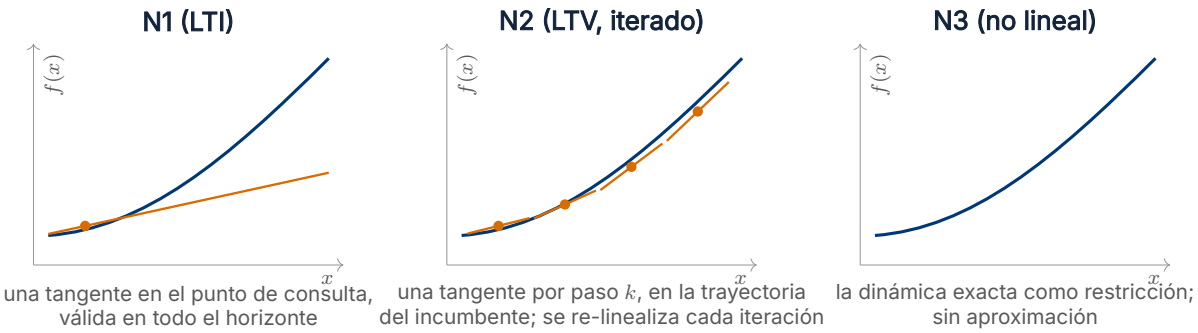


Figura 2: Esquema de los tres niveles. La curva azul representa la dinámica no lineal f, y en naranja están las aproximaciones lineales. N1 usa una sola tangente; N2, una por paso del horizonte, que se actualizan en cada iteración; N3 usa la curva misma.

5.1 N3: el modelo no lineal completo

Es el NLP de la sección anterior. Ipopt lo resuelve con pasos de Newton sobre las KKT perturbadas por la barrera. Usa la matriz hessiana exacta del lagrangiano, que JuMP obtiene por diferenciación automática, y tarda unos 0.05 s. El problema no es convexo, así que el resultado es un óptimo *local*, sin certificado de optimalidad global.

5.2 N1: un solo punto de linealización (LTI)

Se linealiza una vez, en $(\bar{x}, \bar{d}, \bar{u}) = (x(t_q - \Delta t),\ d(t_q - \Delta t),\ \tfrac{1}{2}(\dot{m}_{\text{min}} + \dot{m}_{\text{max}}))$. Las matrices A, B, E y D son las mismas para los 26 pasos. Conviene escribir el modelo en *desviaciones*, $\delta_k = x_k - \bar{x}_k$, $\Delta u_k = u_k - \bar{u}_k$ y $\Delta d_k = d_k - \bar{d}_k$, porque así se evita restar números de $\sim 10^{16}$ (ver los resultados de F3). Con Euler implícito:

$$(I - \Delta t\, A_k)\,\delta_k = \delta_{k-1} + r_k + \Delta t\, B_k\, \Delta u_k + \Delta t\, E_k\, \Delta d_k, \qquad r_k = \bar{x}_{k-1} - \bar{x}_k + \Delta t\, \bar{f}_k,$$
$$\hat{y}_k = \bar{y}_k + \delta_k[T_w] + D_k\,(\Delta d_k + \Delta u_k),$$

con $A_k \equiv A$ en N1, $\bar{x}_k \equiv \bar{x}$ y, por lo tanto, $r_k = \Delta t\, \bar{f}$. Con este modelo, P0 es un QP convexo: costo cuadrático en $\hat{y}$, que es afín en u, y restricciones lineales.

5.3 N2: un punto por paso, actualizado por programación secuencial (LTV)

Dos índices. En N2 conviven dos índices que no hay que confundir:

- $k = 1, \ldots, 26$ es el paso del horizonte de predicción;
- $i = 1, 2, \ldots$ es la iteración de la programación secuencial.

En la iteración i, los jacobianos del paso k se evalúan en el estado $\bar{x}_k^{(i-1)}$, en el *mismo paso* k, de la trayectoria no lineal que produce el control incumbente $u^{(i-1)}$ de la iteración anterior:

$$A_k^{(i)} = \frac{\partial f}{\partial x}\Big(\bar{x}_k^{(i-1)}, d_k, u_k^{(i-1)}\Big), \quad B_k^{(i)} = \frac{\partial f}{\partial u}(\cdot), \quad E_k^{(i)} = \frac{\partial f}{\partial d}(\cdot), \qquad \bar{x}^{(i-1)} = \mathcal{S}\big(x_0,\, u^{(i-1)},\, d\big),$$

donde $\mathcal{S}$ es la simulación no lineal (la réplica). No dependen del paso $k-1$ de la misma iteración: los 26 jacobianos se calculan juntos, a partir de una trayectoria ya simulada, *antes* de resolver el QP. La matriz del paso k cambia con k porque la trayectoria nominal recorre estados distintos (el inventario crece y la PCT baja), y cambia con i porque la trayectoria se corrige en cada iteración.

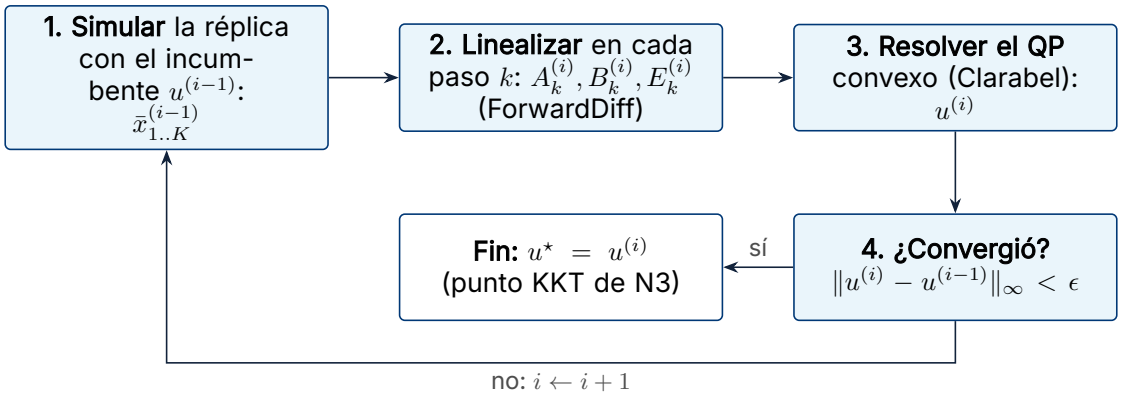


Figura 3: Iteración de N2. Cada vuelta usa el modelo exacto sólo para simular y derivar, y optimiza sobre un QP convexo.

Este esquema es una *programación cuadrática secuencial* sin término de curvatura de las restricciones. También es análogo al LQR iterativo. Si converge, el punto fijo cumple las condiciones KKT del NLP (N3): en ese punto, el modelo lineal y el no lineal tienen el mismo valor y las mismas primeras derivadas. N1 equivale a detenerse en la primera iteración con un punto constante.

5.4 Cómo se resuelven los QP: forma dispersa y forma condensada

- **Monolítica dispersa.** Los estados $\delta_{1..K}$ son variables y la dinámica lineal son restricciones de igualdad: es la misma transcripción directa del NLP, con la dinámica afín. Tiene 519 variables y 442 igualdades de estructura bloque-bidiagonal (figura 9, izquierda).
- **Condensada.** Los estados se eliminan con la recursión anterior: $\delta_k = (I - \Delta t A_k)^{-1}\big(\delta_{k-1} + r_k + \Delta t B_k \Delta u_k + \Delta t E_k \Delta d_k\big)$. La salida queda como una función afín del control, $\hat{y} = \hat{y}^0 + G\,u$, con $G \in \mathbb{R}^{26\times 26}$ triangular inferior. La triangularidad expresa la causalidad: u_j sólo afecta a $\hat{y}_k$ con $k \geq j$. Las columnas de G son casi constantes bajo la diagonal: es la huella del integrador del inventario. Quedan 77 variables: 26 controles y las holguras de las bisagras.

Ambas formas dan la misma solución. La condensada es más pequeña y densa. Es la base de un MPC explícito o embebido, y con Clarabel se resuelve en unos 10 ms.

Certificado de optimalidad (dualidad). Para un QP convexo $\min\{\frac{1}{2}z^\top P z + q^\top z : \; Az \leq b,\; Fz = g\}$, la función dual $g(\lambda,\nu)$ cumple la dualidad débil: $g(\lambda,\nu) \leq p^\star$ para todo $\lambda \geq 0$. Bajo condiciones de Slater hay dualidad fuerte, $g^\star = p^\star$. Un solver primal-dual como Clarabel entrega un par (z,λ,ν), y la **brecha dual** $p(z) - g(\lambda,\nu) \geq 0$ acota cuánto puede mejorarse la solución: es un *certificado de optimalidad global*. Hay que entender bien qué certifica: el óptimo del *modelo lineal* (N1 o N2), no el del P0 no lineal. Para certificar N3 hace falta acotar el error de linealización: eso se hizo en F3c (sección 7).

Para qué sirven N1 y N2. No buscan reemplazar al NLP, que ya es rápido. Buscan abrir lo que el modelo no lineal no permite:

1. **Garantías.** Un QP convexo da el óptimo global de su modelo, con tiempo de cálculo acotado y un certificado dual, ya calculado para N1 y N2 (sección 6.3).
2. **Riesgo analítico.** Bajo linealidad, un error gaussiano sigue siendo gaussiano. La restricción probabilística se vuelve un ajuste lineal de la cota y el problema sigue siendo

un QP (capa 1). Con M escenarios, el SAA es un QP con estructura de bloques (capa 2), y el teorema del escenario óptimo exige un modelo lineal (capa 3).

3. **Comprensión física.** La función de transferencia $G(s) = C(sI - A)^{-1}B + D$, de $\dot{m}_{\text{ACS}}$ a $\hat{y}$, muestra que el actuador actúa a través de un integrador puro (el inventario). Eso explica la estructura "saturar y luego seguir" y la autoridad limitada del ACS.
4. **Medir la no linealidad.** La diferencia entre N1 y N3 cuantifica cuánto importa la no linealidad en el horizonte para la decisión.

6 Resultados

6.1 F1: la réplica algebraica reproduce Simulink

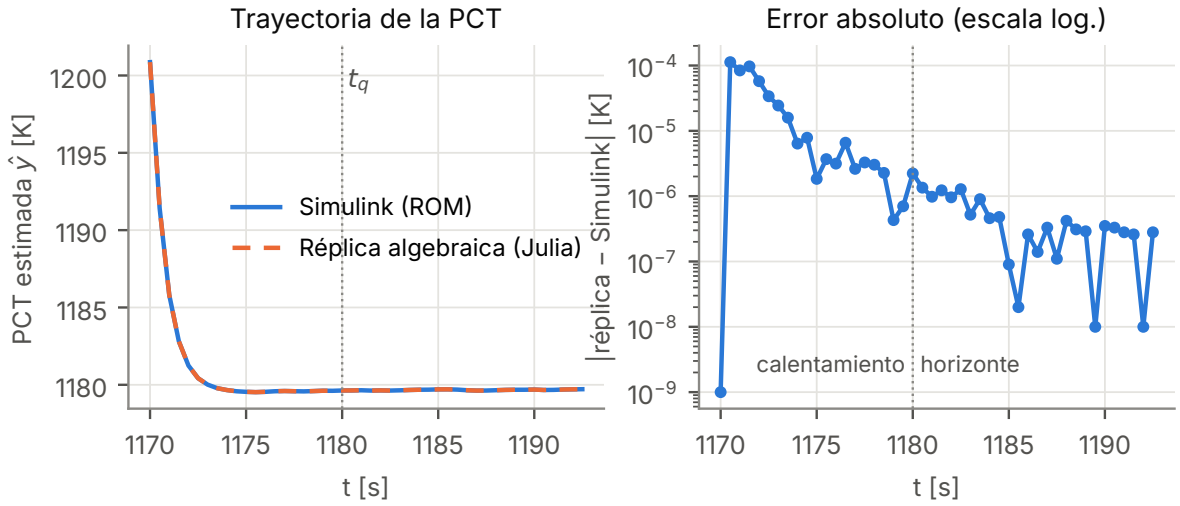


Figura 4: Consulta $t_q = 1180$ s. La simulación arranca en $t_q - 10$ s con el estado inyectado desde el HRM: 10 s de calentamiento y luego el horizonte. La réplica en Julia (`ode1be` con una iteración de Newton y entradas en t_{n+1}) sigue a Simulink con un error de $2 \cdot 10^{-6}$ K en el horizonte y de 10^{-4} K en el transitorio del calentamiento.

6.2 F2: el NLP monolítico frente a los optimizadores sin derivadas

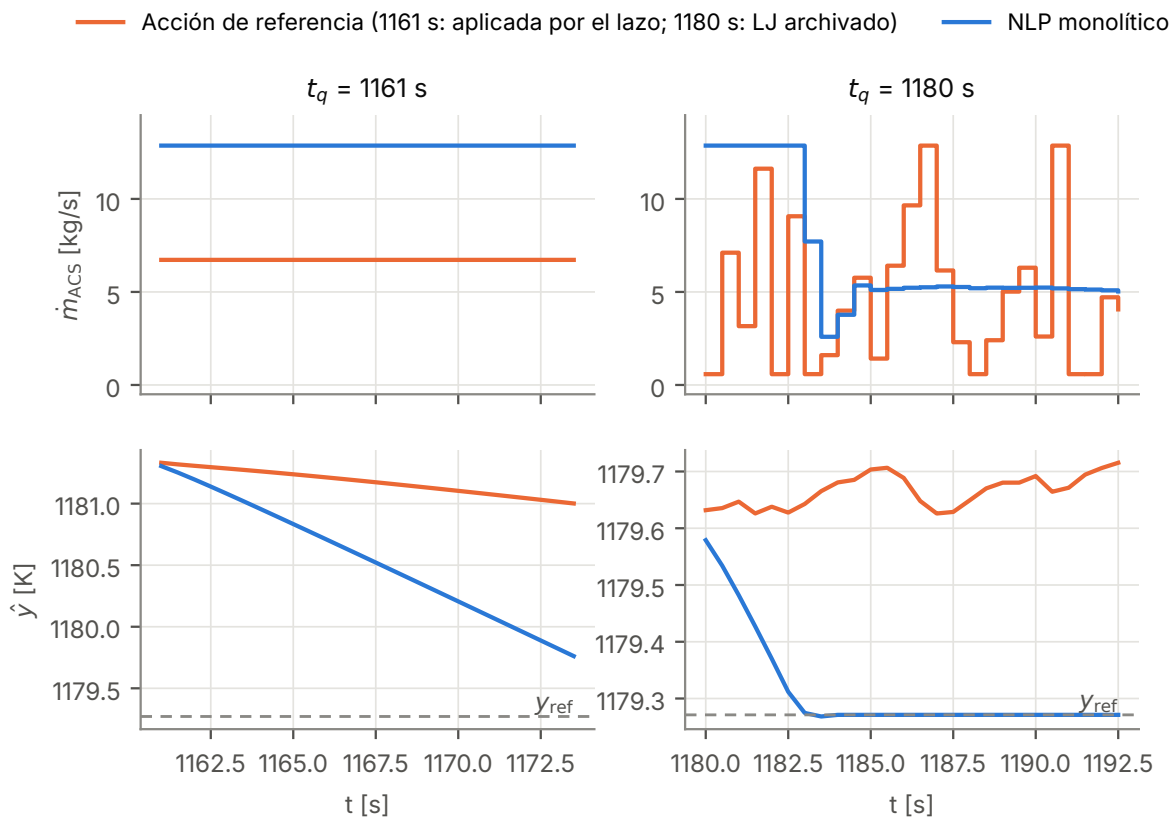


Figura 5: Acción (arriba) y PCT estimada (abajo) en las dos consultas, con la cota archivada $u \leq 56.75$ A ($\dot{m} \leq 12.86$ kg/s). En 1180 s el NLP satura durante 3 s para bajar la PCT y luego sigue la referencia exactamente. En 1161 s, la fase aguda, el óptimo es la esquina $u = u_{max}$ durante todo el horizonte, y aun así la PCT no alcanza la referencia.

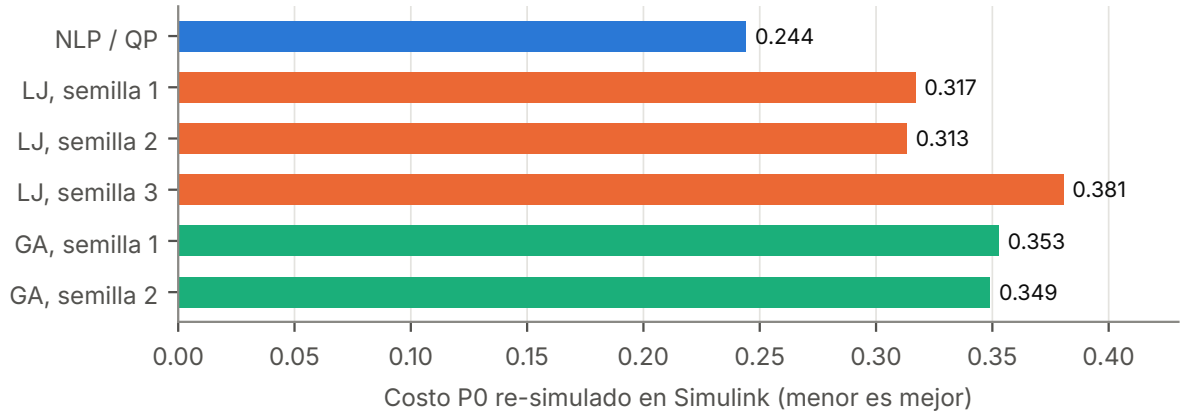


Figura 6: Consulta de 1180 s: costo P0 de cada acción re-simulada en Simulink con el mismo evaluador (`DET_2` + `fitness_cost`). LJ corregido usa 721 evaluaciones y unos 830 s; GA, 420 evaluaciones y unos 615 s; el NLP, 0.1 s. El LJ archivado, anterior a la corrección de la búsqueda, costaba 4.08 y queda fuera de escala.

Lectura. Ningún optimizador sin derivadas alcanza el óptimo: quedan entre un 28 y un 56 % por encima, y en 2 de 5 corridas la primera acción, que es la que se aplica, no satura. El NLP y el QP dan siempre la misma acción y son unas 10^4 veces más rápidos. Las cuatro inicializaciones del NLP llegan al mismo óptimo. En temperatura las diferencias son pequeñas, con un máximo de 0.02 K de PCT, así que en esta consulta el beneficio es velocidad y reproducibilidad.

6.3 F3: N1 y N2 frente a N3, certificados y forma condensada

Trayectorias de control. La figura 7 superpone las trayectorias completas, no sólo la primera acción. En 1161 s las tres saturan durante todo el horizonte y coinciden a 10^{-7} kg/s. En 1180 s, N1 se separa del NLP hasta 0.054 kg/s, justo donde el óptimo deja la saturación ($t \approx 1183$ s): es el error de usar una sola tangente. N2 converge al NLP a $6 \cdot 10^{-6}$ kg/s. La primera acción, que es la que se aplica, coincide en todos los casos a $\leq 2 \cdot 10^{-5}$ kg/s.

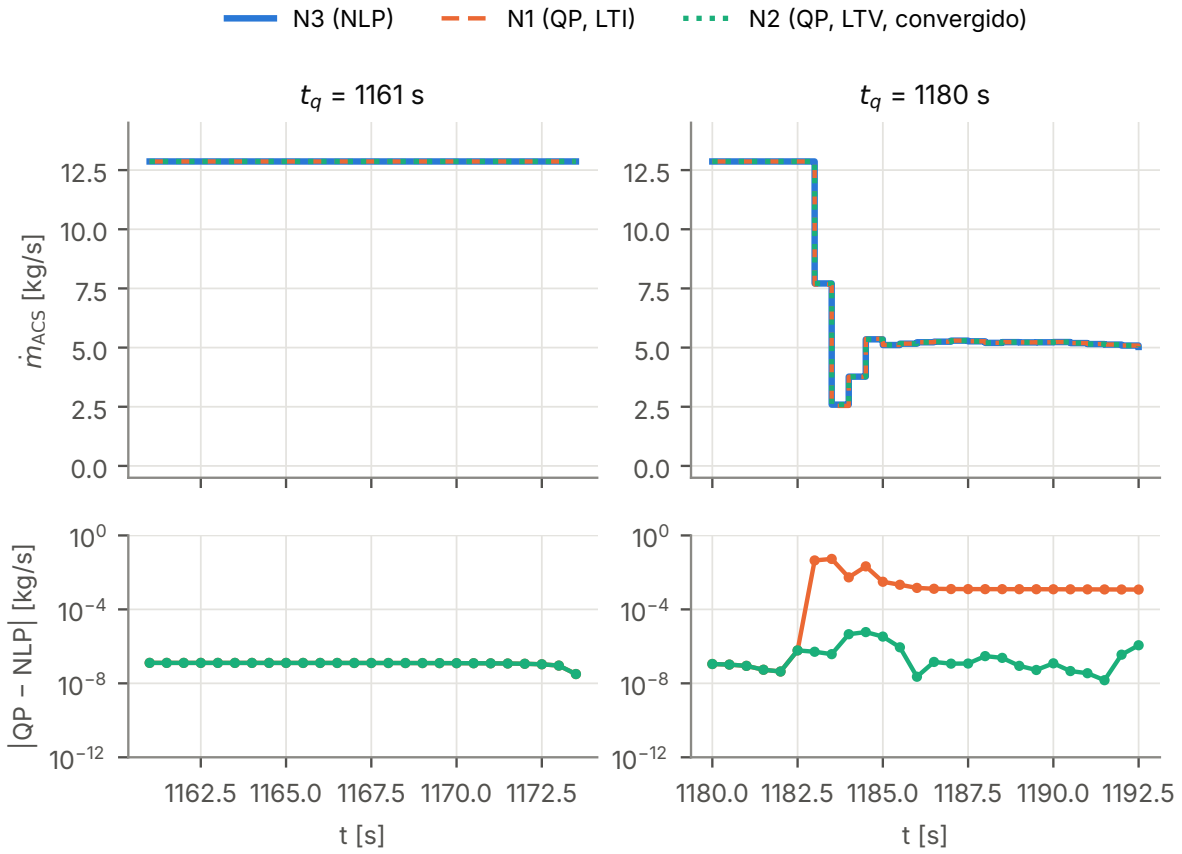


Figura 7: Arriba, las acciones de N3 (NLP), N1 y N2 (convergido). Abajo, la diferencia absoluta con el NLP en escala logarítmica.

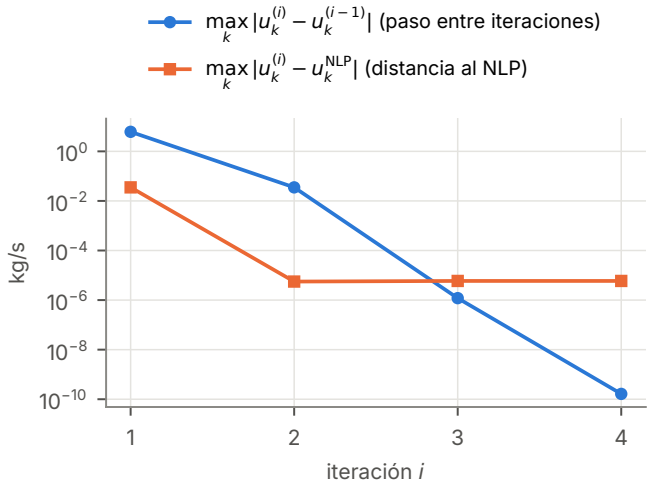


Figura 8: Convergencia de N2 en $t_q = 1180$ s. El paso entre iteraciones cae de forma superlineal (6.1, $3.5 \cdot 10^{-2}$, $1.2 \cdot 10^{-6}$, $1.6 \cdot 10^{-10}$ kg/s), y la distancia al NLP se estabiliza en $6 \cdot 10^{-6}$ kg/s, el nivel de tolerancia del propio NLP. En 1161 s converge en una iteración.

Solvers, formas y certificados. Cada QP se resolvió en sus dos formas, con Ipopt (un solver general de NLP) y con Clarabel (un solver cónico primal-dual que entrega la brecha dual):

Modelo	Forma, solver	Var.	Tiempo [s]	Brecha dual	máx$_k$ $\lvert u_k - u_k^{\text{NLP}} \rvert$ [kg/s]	Costo re-sim.
$t_q = 1180$ *s*						
N3	disperso, Ipopt	519	0.055	—	—	0.2439975
N1	disperso, Ipopt	519	0.037	—	$5.4 \cdot 10^{-2}$	0.2440038
N1	disperso, Clarabel	519	0.037	$1.4 \cdot 10^{-12}$	$5.4 \cdot 10^{-2}$	0.2440038
N1	condensado, Clarabel	77	0.010	$4.3 \cdot 10^{-12}$	$5.4 \cdot 10^{-2}$	0.2440038
N2	disperso, Clarabel	519	0.053	$< 10^{-11}$	$5.9 \cdot 10^{-6}$	0.2439975
N2	condensado, Clarabel	77	0.010	$< 10^{-11}$	$5.9 \cdot 10^{-6}$	0.2439975
$t_q = 1161$ *s*						
N3	disperso, Ipopt	519	0.048	—	—	48.026943
N1	condensado, Clarabel	77	0.009	$4.0 \cdot 10^{-11}$	$1.3 \cdot 10^{-7}$	48.026944
N2	condensado, Clarabel	77	0.009	$3.9 \cdot 10^{-11}$	$1.3 \cdot 10^{-7}$	48.026944

Cuadro 2: Las filas de N2 corresponden al QP linealizado en el punto fijo. Su tiempo es el de un QP; cada iteración agrega la simulación y los jacobianos. Ipopt no entrega valor dual. Las tablas completas están en `results/f3_certificates/`.

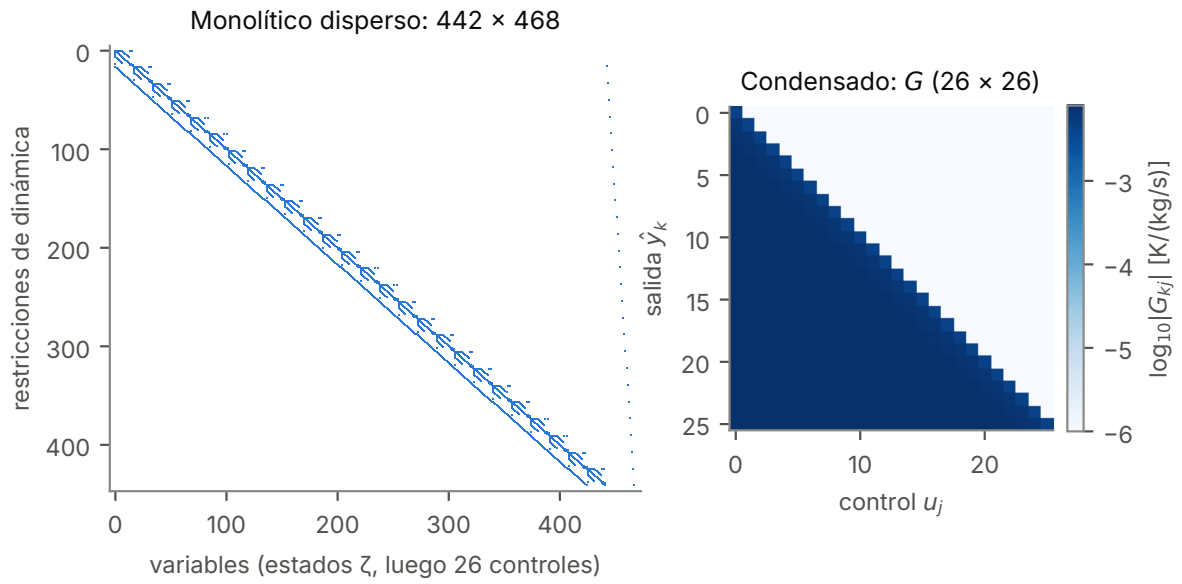


Figura 9: Estructura del QP de N1 en 1180 s. A la izquierda, la matriz de restricciones de la forma monolítica dispersa: bloques $(I - \Delta t A)$ en la diagonal, $-I$ en la subdiagonal y una columna por control. A la derecha, la matriz condensada G: triangular inferior por causalidad, con columnas casi constantes por el integrador del inventario.

Lectura. (i) **Hay certificado para el modelo lineal:** Clarabel cierra la brecha dual a $\sim 10^{-12}$, lo que demuestra que la solución de N1 y de N2 es el óptimo global de su QP. El certificado del P0 no lineal requiere acotar además el error de linealización (sección 7). (ii) El punto fijo de N2 es un punto factible de N3 con el mismo costo que el óptimo de Ipopt (diferencia de $4 \cdot 10^{-8}$). Es una verificación independiente del óptimo local del NLP. (iii) La forma condensada reduce el problema de 519 a 77 variables y el tiempo a ~ 10 ms. (iv) El óptimo es *plano*: N1 se aleja 0.054 kg/s del NLP y su costo re-simulado sólo sube un 0.0026 %.

Corrección respecto de la versión anterior de F3. La implementación original (`f3_linearized_qp.jl`) hacía que N2 se estancara a 0.020 kg/s del NLP. Se probó la hipótesis de que la causa era linealizar sobre trayectorias `ode1be` en lugar de Euler implícito convergido, y quedó **descartada**: con la formulación en desviaciones, ambas variantes dan las mismas iteraciones y convergen al NLP. La causa estaba en la implementación anterior, que escribía el modelo afín con los términos constantes $\bar{f} - A\bar{x}$, con $C_i \sim 10^{16}$. No se aisló el detalle exacto. La versión nueva es `f3_certificates_condensed.jl`.

Función de transferencia. La función de transferencia de $\dot{m}_{\text{ACS}}$ a $\hat{y}$ explica la forma de la solución. El caudal del ACS actúa a través del inventario, que es un integrador puro: $G(s) \approx G_M/s$, con $\partial\hat{y}/\partial\Delta M = -1.6 \cdot 10^{-2}$ K/kg. Por eso conviene acumular inventario lo antes posible ("saturar y luego seguir"). Con la cota archivada, la autoridad sobre el horizonte es de unos 150 kg, es decir ≈ -2.4 K como máximo sobre la PCT.

6.4 F4: el riesgo del pronóstico de fuga

Ensamble regenerado. La ventana de entrada de la BiLSTM (200 muestras de fuga y de $T_{e,c}$) se reconstruyó desde las trayectorias archivadas, con los pesos `model_200x200_drop1_1.pth`. La muestra archivada en 1180 s cae dentro del ensamble regenerado. Además se halló que el lazo archivado usaba `N_par = 1`: el MPC decidía con *una* realización aleatoria del dropout.

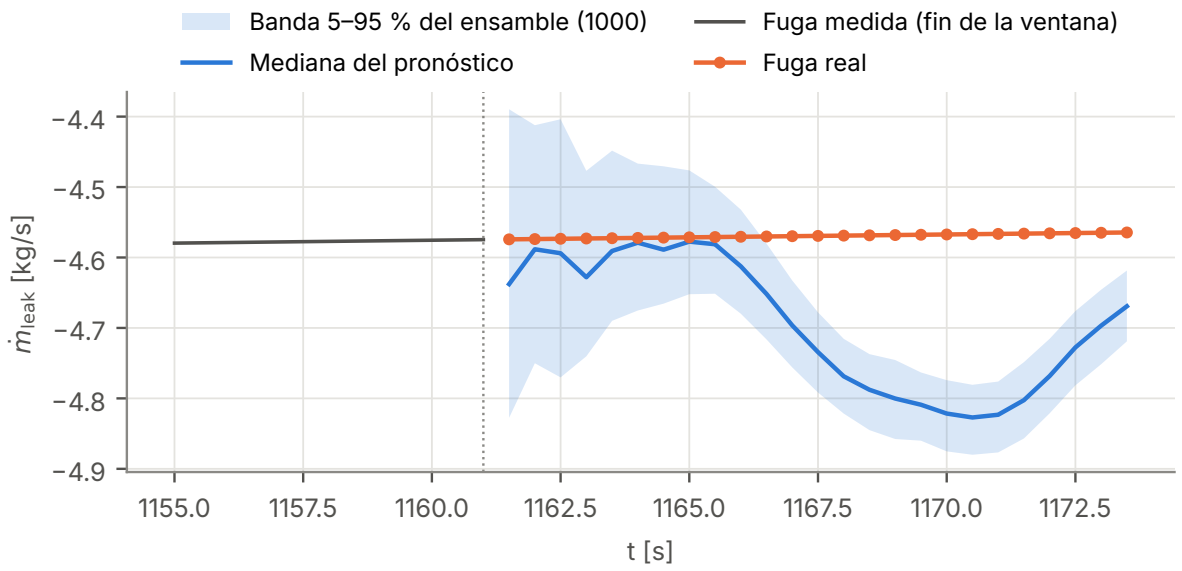


Figura 10: Pronóstico de la fuga en $t_q = 1161$ s. La fuga real (registrada en el HRM) queda en el borde superior de la banda del 90 % o fuera de ella.

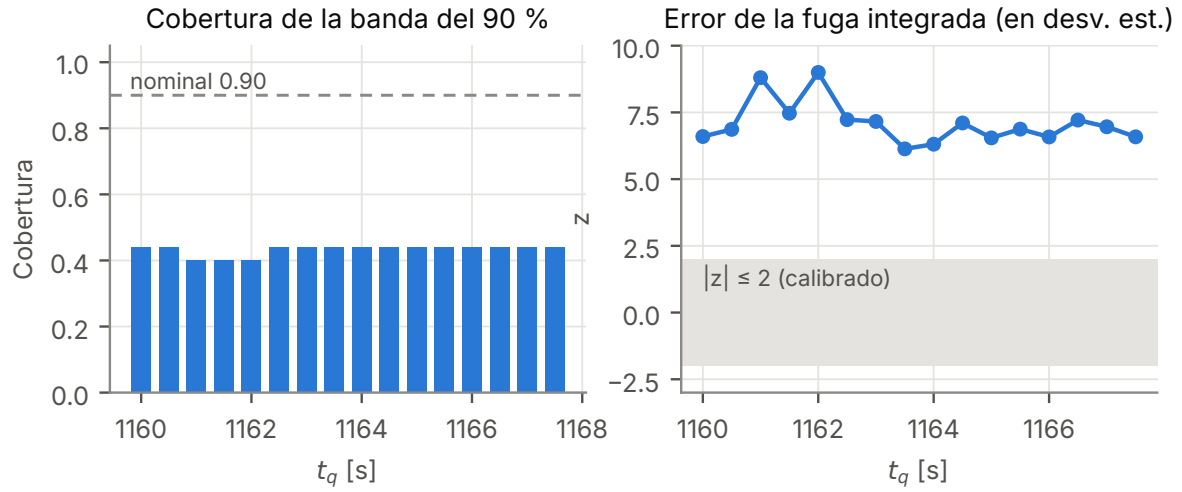


Figura 11: Calibración en 16 consultas (1160–1167.5 s), con 500 trayectorias cada una. La banda del 90 % cubre la fuga real el 44 % de las veces, y el error de la fuga integrada sobre el horizonte es de unas 7 desviaciones estándar del ensamble.

El pronóstico está **sesgado**: la fuga real es unos 0.12 kg/s menor en magnitud. También es **sobreconfiado**: el error de la mediana (0.16 kg/s) duplica la dispersión del ensamble (0.08 kg/s). Sin embargo, ese error, integrado en el horizonte (1.5 kg), equivale a sólo ≈ 0.025 K de PCT, y la dispersión del ensamble a ≈ 0.003 K.

	$t_q = 1161$ s	$t_q = 1180$ s
u_0 con fuga p05, p50, p95, sin dropout, real y SAA-59	todas 56.750 A	todas 56.750 A
Costo medio fuera de muestra (941 miembros), rango entre variantes	48.350 (idéntico)	0.2443–0.2480
Tiempo: NLP determinista / SAA con 59 escenarios	0.03 s / 2.2 s	0.03 s / 2.3 s

Cuadro 3: Ninguna variante del riesgo de pronóstico cambia la primera acción.

6.5 Cotas del actuador con base física

Las conclusiones anteriores usan la cota archivada $u \in [56.69, 56.75]$ A. Al revisarla aparecieron tres hechos:

- El ACS es una *inyección de reposición de inventario*; el caudal primario es consecuencia del inventario.
- En las consultas ya se perdió el 40 % del inventario (unos 3300 kg), y $\dot{m}_c \approx 0.6\,\dot{m}_{\text{nom}}$. La banda exploratoria de ± 20 % sobre el caudal nominal ya está violada por el propio LOCA. Recuperar $0.8\,\dot{m}_{\text{nom}}$ exigiría unos 1700 kg, lo que no cabe en un horizonte de 12.5 s.
- El ECM de la bomba es el de una *bomba principal*: ducto de 0.515×0.515 m, 15 kPa, 5543 kg/s a 2 m/s. El ACS usa el pie de su curva: 0–13 kg/s en 0.06 A, con 1 mA equivalente a 0.2 kg/s. La cota en amperios no tiene significado físico; la cota defendible está en kg/s.

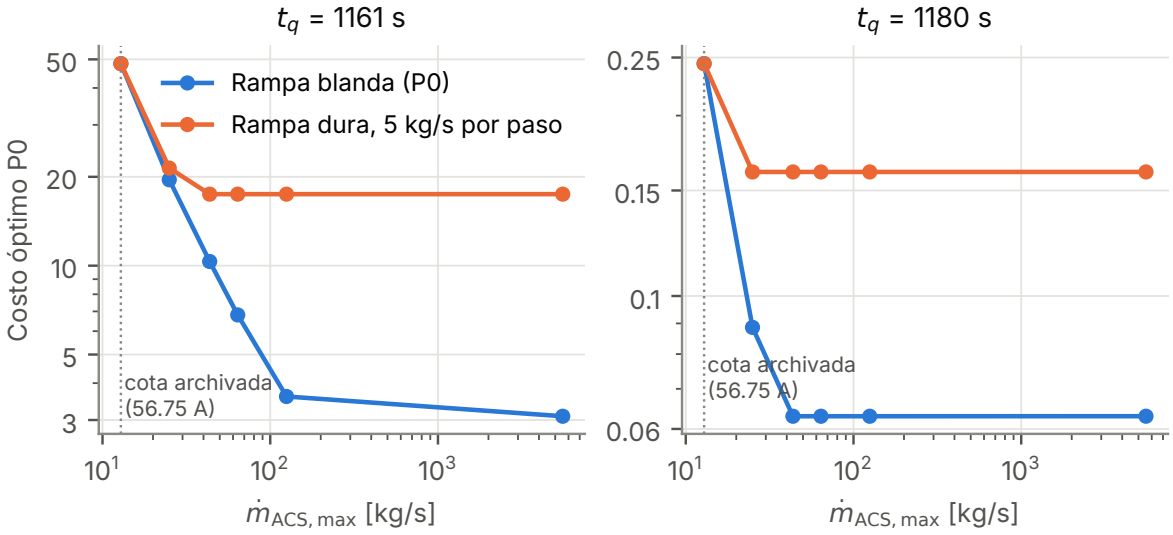


Figura 12: Costo óptimo según la cota de caudal $\dot{m}_{\text{ACS,max}}$, con la rampa blanda de P0 (penalización con $\lambda_m = 10^{-4}$) o con una rampa dura de 5 kg/s por paso (10 kg/s^2) desde la acción aplicada.

Lectura. Con la rampa dura, la cota de caudal deja de importar desde 25–44 kg/s: la autoridad la fija la rampa. La pregunta física pasa de "¿qué $u_{\max}$?" a "¿qué rampa admite la inyección?". Con la rampa blanda, el óptimo deja de saturar sobre unos 40 kg/s en 1180 s y unos 170 kg/s en 1161 s. Aun entonces, decidir con p05 o p95 mueve $\dot{m}_0$ como mucho 0.5 kg/s, y fuera de muestra cuesta un 5–6 % más que el SAA en 1180 s. La conclusión de F4 se mantiene: la incertidumbre de pronóstico de la fuga no cambia la decisión de forma relevante. El polinomio p_4 se extrapola en estos casos, pero su aporte es de 0.017 K como máximo.

7 Certificación de optimalidad del P0 no lineal (F3c)

7.1 Qué se quiere certificar

El problema de referencia es P0 sobre el ROM **no lineal** (N3), con las cotas archivadas del actuador:

$$J^\star = \min_{u \in \mathcal{U}} J(u), \qquad \mathcal{U} = [\dot{m}_{\min}, \dot{m}_{\max}]^{26}.$$

$J^\star$ es el óptimo *global*, y no se conoce. Una **brecha de optimalidad** necesita dos números: una cota superior UB, el costo de cualquier control admisible (aquí, la solución de Ipopt), y una cota inferior LB, demostrada, tal que $LB \le J^\star \le UB$. Hay que distinguirla de la *brecha del solver*: la brecha dual del QP (F3b) o los residuos KKT del NLP sólo dicen que cada solver resolvió bien *su propio* problema, no qué tan buena es la decisión para P0. Antes de F3c, la única cota inferior de P0 era $J \ge 0$.

Paso	Pregunta que responde	Tipo de resultado
1	¿La solución de Ipopt es un mínimo, y no un punto de silla?	Prueba local
2	¿Cambia el óptimo si se usa exactamente la discretización de Simulink?	Consistencia del modelo
3	¿Hay otro óptimo mejor en la caja de control?	Evidencia global (no es prueba)
4a	¿Cuánto podría mejorarse como máximo, si el residuo no lineal está bien estimado?	Brecha semi-rigurosa
4b	¿Cuánto podría mejorarse como máximo, con demostración?	**Brecha certificada**

Cuadro 4: Las pruebas de F3c y lo que garantiza cada una.

7.2 Formulación en espacio reducido

Los estados se eliminan con la simulación, $x_k = \Phi(x_{k-1}, u_k)$, y el costo queda como función sólo del control:

$$J(u) = \sum_{k=1}^{K} \left(\hat{y}_k(u) - y_{\text{ref}}\right)^2 + \lambda_m \sum_{k=1}^{K-1} \left[|u_{k+1} - u_k| - \Delta\dot{m}\right]_+^2 + \lambda_{\text{pct}} \sum_{k=1}^{K} \left[\hat{y}_k(u) - U_y\right]_+^2.$$

Φ es el paso de Euler implícito *convergido* (el modelo del NLP) o el paso `ode1be` (una iteración de Newton: lo que calcula Simulink). J está escrita de forma genérica, así que ForwardDiff la deriva *a través de la simulación*. En el paso implícito, primero se resuelve Newton sobre valores y luego se hacen tres refinamientos con números duales, lo que da primeras y segundas derivadas exactas. La consistencia se verificó: $J(u^\star)$ en espacio reducido coincide con el objetivo del NLP monolítico a $4 \cdot 10^{-8}$.

7.3 Paso 1: certificado de mínimo local

Para un problema con cotas de caja, $u^\star$ es un **mínimo local estricto** si se cumplen tres condiciones:

1. $\partial J / \partial u_k = 0$ en las variables libres (estacionariedad);
2. el multiplicador de cada cota activa es estrictamente positivo: $\mu_k = -\partial J / \partial u_k > 0$ en la cota superior y $\mu_k = \partial J / \partial u_k > 0$ en la inferior (complementariedad estricta);

3. la hessiana restringida a las variables libres es definida positiva (condición suficiente de segundo orden).

La hessiana se calcula por diferencias centrales del gradiente exacto, con paso 10^{-4}. Es mucho más liviano que la hessiana exacta anidada, que agotó la memoria. Su error es muy inferior a los valores propios medidos.

	$t_q = 1180$ s	$t_q = 1161$ s
Cotas activas / variables libres	6 superiores / 20	26 superiores / 0
máx $\lvert\partial J/\partial u\rvert$ en las libres	$8.7 \cdot 10^{-10}$	—
Menor multiplicador de cota activa	$3.2 \cdot 10^{-4}$	$4.2 \cdot 10^{-3}$
$\lambda_{\min}$ de la hessiana reducida (condición)	$4.3 \cdot 10^{-6}$ ($4.6 \cdot 10^{3}$)	— (vértice)
Conclusión	**mínimo local estricto**	**mínimo local estricto (vértice)**

Cuadro 5: Paso 1, con el modelo de Euler implícito. Con `ode1be` los valores son prácticamente los mismos.

7.4 Paso 2: P0 sobre la discretización de Simulink

Se resolvió P0 en espacio reducido con `ode1be`: Ipopt con gradiente exacto a través de la simulación y hessiana aproximada con L-BFGS, desde dos arranques. Su óptimo está $4.5 \cdot 10^{-9}$ (1180 s) y $6.8 \cdot 10^{-7}$ (1161 s) por debajo del costo `ode1be` de la solución de Euler implícito. Tiene la misma primera acción, y las trayectorias difieren $\leq 6 \cdot 10^{-4}$ kg/s. Las dos definiciones de P0 son equivalentes a efectos prácticos, y todo lo que sigue vale para ambas.

7.5 Paso 3: evidencia global

- **Multistart** del NLP monolítico desde 500 arranques aleatorios uniformes, 50 caminatas aleatorias, 11 constantes, 25 bang-bang, uno alternado y (en 1180 s) las soluciones de LJ y GA. Convergen 593/593 (1180 s) y 587/587 (1161 s), todos al *mismo* óptimo, a $\leq 5 \cdot 10^{-6}$ kg/s.
- **Evolución diferencial** (DE/rand/1/bin, población 60, $F = 0.7$, $CR = 0.9$, 1500 generaciones, 90 060 evaluaciones, sin derivadas). Llega a $+2.4 \cdot 10^{-7}$ del NLP (1180 s) y lo iguala (1161 s). Pulida con el NLP, cae en el mismo óptimo.
- **Convexidad**: valores propios de $\nabla^2 J(u)$ en 300 puntos de la caja (figura 13).

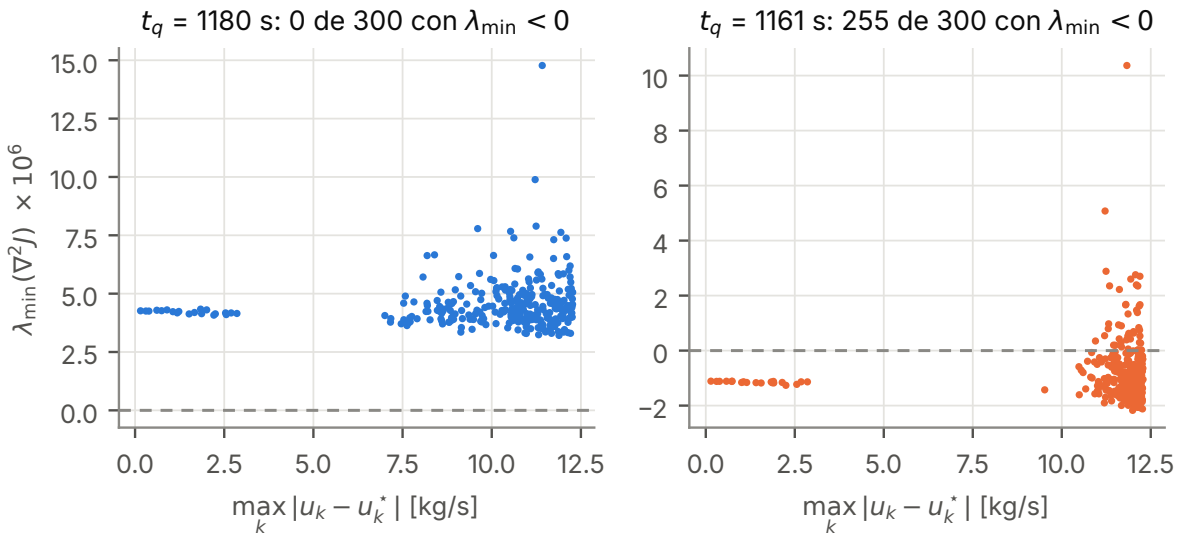


Figura 13: Menor valor propio de la hessiana del costo en 300 puntos de la caja de control, según la distancia a $u^\star$. En 1180 s es positivo en todos: hay señal de convexidad. En 1161 s es levemente negativo en 255 de 300 puntos (hasta $-2{\cdot}10^{-6}$, un 0.006 % de $\lambda_{\max}$), también cerca del óptimo. Eso no contradice el paso 1: en 1161 s las 26 variables están en su cota con multiplicadores positivos, y la dirección de curvatura negativa queda bloqueada por las cotas.

La evidencia es fuerte: un solo óptimo en ≈ 590 arranques y ninguna búsqueda global lo mejora. Pero no es una prueba, y la no convexidad de 1161 s muestra que no se puede suponer convexidad. Por eso hace falta el paso 4.

7.6 Paso 4a: cota inferior semi-rigurosa

1. **Modelo afín de referencia:** $a(u) = \hat{y}(u_c) + G\,(u - u_c)$, con $G = \partial\hat{y}/\partial u$ exacta en un punto u_c. Es sólo una herramienta: cualquier modelo afín sirve.
2. **Residuo no lineal:** $e_k(u) = \hat{y}_k(u) - a_k(u)$, con $\varepsilon_k \geq \max_{u\in\mathcal{U}} |e_k(u)|$ estimado por muestreo (3000 puntos y 63 patrones extremos) y maximización adversaria con Ipopt.
3. **Relajación convexa:** si $|e_k| \leq \varepsilon_k$, entonces $(\hat{y}_k - y_{\text{ref}})^2 \geq \left(|a_k(u) - y_{\text{ref}}| - \varepsilon_k\right)_+^2$ y $[\hat{y}_k - U_y]_+^2 \geq [a_k - \varepsilon_k - U_y]_+^2$. La penalización de la rampa es exacta. La función resultante $L(u)$ cumple $L \leq J$ en toda la caja y es convexa, así que $LB = \min L$ es un QP (Clarabel, cota dual).

Con $u_c = u^\star$, la búsqueda adversaria no supera al muestreo en ningún paso, y la brecha $(UB - LB)/UB$ es de **0.30 % (1180 s) y 1.2 % (1161 s)**. Con un factor de seguridad de 2 sobre ε sube a 0.59 % y 2.4 %. Es *semi*-rigurosa porque el muestreo podría no encontrar el peor residuo. En sub-cajas de semiancho ρ la brecha baja como ρ^2, igual que el resto de Taylor (figura 14, derecha).

7.7 Paso 4b: cota inferior certificada

Se reemplaza el ε muestreado por uno **demostrado**. Para eso se usa un modelo de Taylor de primer orden con resto por intervalos, en variables escaladas:

$$\delta_k(u) = x_k(u) - x_k^c = T_k\,\Delta u + r_k, \qquad \Delta u = u - u_c,$$

donde r_k es una caja de intervalos.

- Restando el paso implícito real y el nominal, y aplicando el teorema del valor medio a f:

$$M_k^c\, r_k = r_{k-1} + h\big([A](Z_k) - A_k^c\big)[\delta_k] - \mathrm{res}_k - D_k\,\Delta u,$$

  con $M_k^c = I - hA_k^c$. $[A](Z_k)$ es el jacobiano de f evaluado con aritmética de intervalos (`IntervalArithmetic.jl`) sobre la caja alcanzable Z_k. $B = e_{\Delta M}$ es constante, porque el control sólo entra en el inventario.

- res_k y D_k son los defectos de punto flotante de la trayectoria nominal y de la parte lineal, encerrados con intervalos: el redondeo queda controlado.
- Como r_k aparece a ambos lados, se acepta una caja R cuando el operador la manda dentro de sí misma (teorema de Brouwer). Se supone que cada paso implícito tiene solución única, lo que respalda la convergencia de Newton.
- El término directo de la salida se acota exactamente: $\frac{1}{2}[p_4'']() \,\Delta u_k^2$.

Verificaciones. El jacobiano por intervalos contiene los 1300 jacobianos muestreados por consulta, sin ninguna violación. La propagación cierra en los 26 pasos (dos iteraciones de punto fijo por paso, unos 4 s). El ε riguroso queda por encima del residuo muestreado del *mismo* modelo afín en todos los pasos.

Centro u_c del modelo de Taylor	ε_{26} riguroso / muestreado	Brecha 1180 s	Brecha 1161 s
$u^\star$ (solución del NLP)	0.50 / 0.010 K; 1.32 / 0.038 K	4.86 %	20.85 %
Punto medio de la caja	0.47 / 0.009 K; 0.48 / 0.010 K	**2.34 %**	**11.44 %**

Cuadro 6: Brecha certificada $(UB - LB)/UB$ del P0 no lineal sobre toda la caja de control. Con el centro en el punto medio, $LB = 0.23834$ (1180 s) y 42.533 (1161 s).

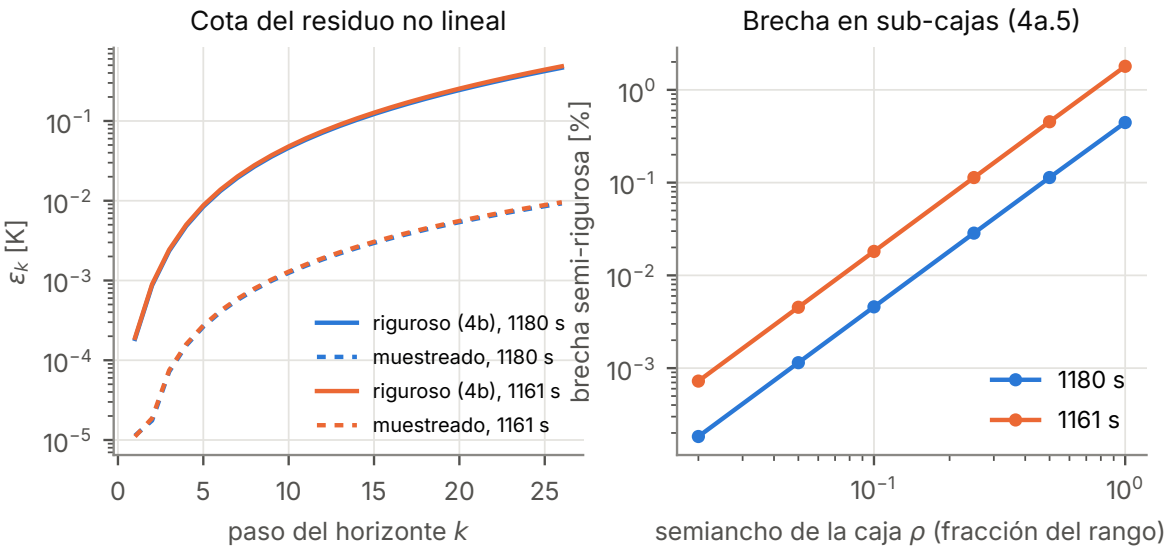


Figura 14: Izquierda: cota del residuo no lineal por paso del horizonte, rigurosa (4b) frente a muestreada, con el modelo centrado en el punto medio. Derecha: brecha semi-rigurosa en sub-cajas de semiancho ρ alrededor de $u^\star$ (4a.5), que baja como ρ^2.

Lectura. Es la **primera cota inferior certificada** del P0 no lineal: el óptimo global está en $[0.23834,\ 0.24403]$ (1180 s) y en $[42.53,\ 48.03]$ (1161 s). El ε riguroso sobreestima el real entre 16 y 50 veces, por dos razones. (i) El término de segundo orden se acota como el producto de dos cajas, lo que ignora que las 26 direcciones de control mueven el estado casi en una sola dirección, la del inventario. (ii) El resto se acumula a través del integrador. El ajuste (paso 4b.5: partición por masa inyectada o modelo de Taylor de segundo orden) queda para la próxima ronda.

8 Comparación de las decisiones de todos los métodos

8.1 Modelos y métodos comparados

Cada método entrega una secuencia de 26 caudales del ACS para la misma consulta. Lo que cambia es el modelo con que decide, la formulación y el algoritmo:

Método	Modelo con el que decide	Formulación	Algoritmo y derivadas	Tiempo
N3, NLP (BE)	ROM no lineal, Euler implícito convergido	Monolítica dispersa: 519 variables, 442 igualdades	Ipopt (punto interior), hessiana exacta por diferenciación automática	0.05 s
N3 sobre `ode1be`	ROM no lineal, `ode1be` (= Simulink)	Espacio reducido: 26 variables	Ipopt, gradiente exacto a través de la simulación, hessiana L-BFGS	2.5–10 s
N2, QP-LTV iterado	ROM linealizado en cada paso de la trayectoria del incumbente	QP condensado (77 variables) por iteración	SQP: simular, linealizar (ForwardDiff), QP (Clarabel); 4 iteraciones en 1180 s, 1 en 1161 s	$\sim$10 ms por QP
N1, QP-LTI	ROM linealizado en el punto de consulta	QP condensado, 77 variables	Clarabel, con certificado dual	0.01 s
Evolución diferencial	ROM no lineal, Euler implícito	26 variables	Sin derivadas: DE/rand/1/bin, 90 060 evaluaciones	90 s
LJ corregido	ROM en Simulink (`DET_2` + `fitness_cost`)	26 corrientes	Sin derivadas: Luus–Jaakola ($R = 24$, $\gamma = 0.9$, $M = 5$), 721 evaluaciones	≈ 800 s
GA	Igual que LJ	26 corrientes	Sin derivadas: genético 20×20, cruce 0.8, mutación 0.3, 420 evaluaciones	≈ 615 s
Lazo archivado	Lazo original, anterior a la corrección de LJ	—	—	—

Cuadro 7: Métodos comparados. Los tiempos de LJ y GA se midieron en MATLAB/Simulink (E2); los demás, en Julia sobre leo_acer.

8.2 Consideraciones para que la comparación sea justa

1. **Misma vara.** Cada control se evalúa con el costo P0 sobre el ROM *no lineal*, en las dos discretizaciones (Euler implícito y `ode1be`). Las dos dan el mismo ordenamiento, y difieren en un desplazamiento casi constante de $3.6 \cdot 10^{-5}$ (1180 s). Las corrientes de LJ y GA se convierten a caudal con el mapa de la bomba. Su costo recalculado coincide con el que E2 midió en Simulink (por ejemplo, 4.081 para el LJ archivado).

2. **Mismas condiciones.** Todos parten del mismo estado $x(t_q - \Delta t)$ y usan el mismo pronóstico de fuga (el de F2), la misma referencia, las mismas cotas archivadas del actuador (0.58–12.86 kg/s) y la rampa blanda de P0.
3. **Cómo se mide la calidad.** Se usa el costo no lineal de cada decisión, nunca el objetivo interno de su solver. Por ejemplo, el QP N1 predice 47.81 en 1161 s, pero su control cuesta 48.03 en el modelo no lineal: el 47.81 no es una cota de nada.
4. **Exceso garantizado.** Como $LB \le J^\star \le UB$, el exceso real de una decisión u sobre el óptimo global queda en el intervalo $\left[(J(u) - UB)/UB,\ (J(u) - LB)/LB\right]$. El extremo inferior es el exceso sobre el mejor encontrado; el superior, la peor posibilidad compatible con la cota certificada.
5. **Alcance.** La comparación vale para P0 sobre el ROM, en dos consultas y con las cotas archivadas del actuador, que no tienen base física (sección 7). No dice nada sobre el desajuste ROM–HRM. En 1161 s, LJ y GA no tienen corridas completas.

8.3 Resultados

	$t_q = 1180$ s			$t_q = 1161$ s	
Método	Costo	Exceso/mejor	Exceso garantizado	Costo	Exceso/mejor
N3, NLP (Ipopt, BE)	0.244034	0	0 – 2.4 %	48.028	0
N3 sobre `ode1be`	0.244034	0	0 – 2.4 %	48.028	0
N2, QP-LTV iterado	0.244034	0	0 – 2.4 %	48.028	0
N1, QP-LTI	0.244040	+0.0026 %	0.0026 – 2.4 %	48.028	0
Evolución diferencial	0.244034	+0.0001 %	0.0001 – 2.4 %	48.028	0
LJ corregido (3 semillas)	0.313 – 0.381	+28 a +56 %	28 – 60 %	—	—
GA (2 semillas)	0.349 – 0.353	+43 a +45 %	43 – 48 %	—	—
Lazo archivado	4.081	+1572 %	1572 – 1612 %	94.45	+97 %

Cuadro 8: Costo P0 sobre el ROM no lineal (Euler implícito) de la decisión de cada método. En 1161 s el exceso garantizado de N1–N3 y DE es 0–12.9 %, y el del lazo archivado, 97–122 %.

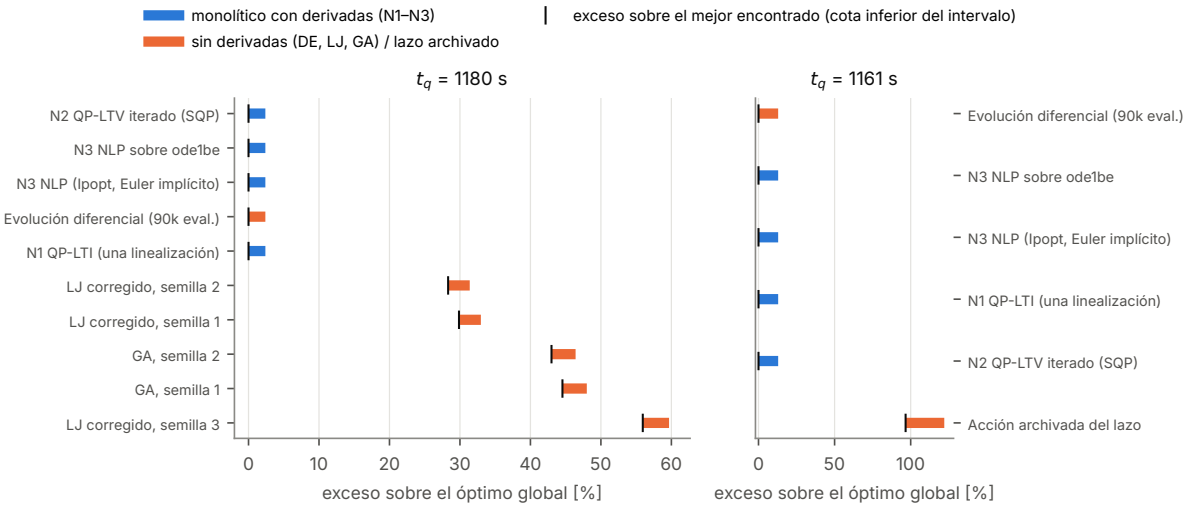


Figura 15: Intervalo de exceso garantizado sobre el óptimo global de cada decisión. La marca negra es el exceso sobre el mejor encontrado (extremo inferior) y la barra llega hasta el extremo superior, que fija la cota certificada. En 1180 s se omite el lazo archivado (1572–1612 %).

Conclusiones. (i) **N3 y N2 son los mejores y empatan**: son la misma decisión, a $6 \cdot 10^{-6}$ kg/s. (ii) **N1** cuesta un 0.0026 % más en 1180 s y lo mismo en 1161 s. Es el más rápido ($\sim$10 ms) y el único que es un QP convexo certificable, así que es el candidato natural para tiempo real. (iii) La primera acción aplicada (56.75 A) coincide en N1, N2, N3 y DE. LJ con la semilla 3 y las dos semillas de GA aplican otra. (iv) **LJ y GA quedan dominados con garantía**: su exceso sobre el óptimo global es de al menos 28 % y 43 %, y son unas 10^4 veces más lentos. (v) El límite superior del intervalo de N1–N3 (2.4 %) es la brecha de la cota certificada, no una pérdida observada: los pasos 1–3 indican que el exceso real es ≈ 0. Cerrarlo es el paso 4b.5.

9 Estado actual

- **Herramientas.** Toda la cadena F1–F4 corre sin MATLAB en Julia (`julia/SMDFRROM.jl` y `F4Lib.jl`) y en Python con `torch` en CPU. MATLAB (leo_asus) sólo hace falta para generar consultas nuevas, el HRM y el lazo completo.
- **Resuelto.** El MPC determinista es tratable y reproducible: el NLP tarda unos 0.05 s y el QP condensado unos 10 ms por consulta. El QP tiene certificado dual de optimalidad global para su modelo lineal, y N2 converge al NLP: son dos verificaciones independientes del óptimo local. El SAA con 59 escenarios toma unos 2 s, así que la capa 2 de riesgo es viable en tiempo real.
- **Certificación del P0 no lineal (F3c).** La solución de Ipopt es un mínimo local estricto y el único óptimo encontrado en ≈ 590 arranques y en una búsqueda global sin derivadas. La primera brecha *certificada* es de 2.3 % (1180 s) y 11.4 % (1161 s); la semi-rigurosa, de 0.3 % y 1.2 %. En la comparación con la misma vara, N3 y N2 empatan como los mejores, N1 queda a 0.0026 %, y LJ y GA quedan al menos un 28 % y un 43 % por encima del óptimo global.
- **Abierto.** La brecha certificada es conservadora (paso 4b.5). F4 todavía no tiene "una decisión que cambie por riesgo". Las conclusiones se apoyan en dos consultas, y la cota del actuador no está fijada.

10 Próximos pasos

1. **Fijar el actuador con el equipo:** la rampa admisible, el caudal máximo y si el ACS repone inventario o impulsa el caudal primario. Es la decisión que más cambia los resultados: el costo óptimo en 1161 s va de 3.1 a 48.4. No requiere ninguna máquina.
2. **F4 con escenarios de falla del ACS** (leo_acer): SAA o MPC multietapa con no anticipación sobre el modo $\sigma \in \{0, 1\}$ y las tasas λ, μ del DET. Criterio: una primera acción que cambie por riesgo, con intervalo de confianza.
3. **Desajuste ROM–HRM como incertidumbre** (leo_asus): re-simular en el HRM las acciones del NLP. Si el error es del orden de 1 K, es la incertidumbre que corresponde a la restricción probabilística.
4. **Recalibrar el pronóstico** (leo_acer): corregir el sesgo, por ejemplo con un modelo de error o predicción conformal, y usar `N_par` > 1 en el lazo.
5. **Más consultas** (leo_asus): reconstruir varias de las 61 con `build_query_from_archive.m`.
6. **F5, lazo cerrado** (leo_asus): las 61 consultas con el NLP o el QP frente al lazo LJ archivado, con menos de 120 s por consulta.

7. **F3c, paso 4b.5** (leo_acer, próxima ronda): ajustar la cota certificada con una partición por masa inyectada o un modelo de Taylor de segundo orden. El objetivo es cerrar el exceso garantizado de N1–N3 (hoy 0–2.4 % y 0–12.9 %) hacia los valores semi-rigurosos (0.3 % y 1.2 %).

Reproducibilidad.

- Resultados: `results/f1_rom_replica/`, `results/f3_certificates/`, `results/f3c_optimality/` y `results/f4_risk/`.
- Julia: `julia/f2_monolithic_nlp.jl`, `f3_certificates_condensed.jl` (sustituye a `f3_linearized_qp.jl`), `f3c_optimality.jl` (pasos 1–3), `f3c_lower_bound.jl` (4a), `f3c_rigorous.jl` (4b; centro con `F3C_CENTER=mid`), `f3c_compare_decisions.jl`, `ReducedP0.jl`, `f4_risk_decisions.jl` y `f4_actuator_sweep.jl`.
- Python: `python/f4_leak_ensemble.py`, `f4_forecast_calibration.py` y `make_status_figures.py` (figuras).