Control predictivo monolítico del SMDFR

Del reactor y su accidente a la formulación, resolución y certificación del problema de control

Proyecto DT–SMDFR Risk Control

10 de noviembre de 2026

Resumen

Durante un accidente con pérdida de refrigerante (LOCA) en el reactor modular SMDFR, un gemelo digital decide cada 0.5 s cuánto plomo inyecta el sistema auxiliar de enfriamiento (ACS), mediante un control predictivo (MPC). Este documento explica el problema desde cero:

- el reactor y su física, a partir del modelo de Liu et al. (2021);
- el accidente y el actuador;
- el controlador y el método actual, que resuelve el problema de optimización con metaheurísticas sobre simulaciones de caja negra;
- las herramientas necesarias: optimización, integración numérica, linealización, incertidumbre y certificación.

Después propone *formulaciones monolíticas* del mismo problema, en las que las ecuaciones del modelo reducido pasan a ser restricciones de un programa no lineal que se resuelve con derivadas exactas. Los resultados, en dos consultas de prueba, son:

- una réplica algebraica del modelo que reproduce Simulink con un error de 10^{-6} K;
- el problema se resuelve en ~ 0.05 s como programa no lineal y en ~ 10 ms como QP linealizado, frente a ~ 800 s del método actual;
- la solución es un mínimo local estricto, es el único óptimo hallado en ≈ 590 arranques, y una cota inferior *certificada* demuestra que está a menos del 2.3 % (1180 s) y del 11.4 % (1161 s) del óptimo global;
- evaluadas con la misma vara, las decisiones de Luus–Jaakola y del algoritmo genético cuestan, con garantía, al menos un 28 % y un 43 % más que el óptimo global;
- la incertidumbre del pronóstico de fuga no cambia la decisión, y la cota del actuador, que hoy se expresa en amperios, no tiene base física y debe fijarse en kg/s.

Índice

1. Introducción 5
   - 1.1. Para quién es este documento y cómo leerlo . . . 5
   - 1.2. La problemática en breve . . . 5
   - 1.3. Preguntas que responde este documento . . . 6
   - 1.4. Ruta de trabajo . . . 6

I El problema físico 7

2. El reactor SMDFR y su física 7
2.1. Qué hace un reactor nuclear . . . 7
2.2. El concepto Dual Fluid y el SMDFR . . . 8
2.3. Neutrones y potencia: la cinética puntual . . . 9
2.4. Calor: del combustible al refrigerante . . . 10
2.5. El modelo de 12 nodos y su versión reducida . . . 11

3. El accidente: pérdida de refrigerante (LOCA) 12
3.1. Qué es un LOCA y por qué es peligroso . . . 13
3.2. El accidente en el tiempo . . . 13
3.3. Por qué sube la PCT: los números . . . 14
3.4. El actuador: la bomba magnetohidrodinámica del ACS . . . 15
3.5. Variables, límites y referencia . . . 16
3.6. ¿Cuánto puede hacer el actuador en un horizonte? . . . 16

II El controlador 17

4. El control predictivo (MPC) 17
4.1. Controlar: lazo abierto y lazo cerrado . . . 17
4.2. La idea del control predictivo . . . 17
4.3. Los elementos de un MPC . . . 18
4.4. El problema de control P0, término por término . . . 18
4.5. Las dos consultas de prueba . . . 19
4.6. Por qué este problema es difícil . . . 19

5. El método actual: gemelo digital con árbol de eventos y metaheurística 19
5.1. Arquitectura del gemelo digital . . . 20
5.2. El pronóstico de la fuga: una red BiLSTM con MC-dropout . . . 20
5.3. El predictor: árbol dinámico de eventos (DET) . . . 21
5.4. El problema de optimización del MPC actual (P0-DET) . . . 22
5.5. Por qué se usaba una metaheurística . . . 22
5.6. La métrica de riesgo . . . 23
5.7. Brechas del método actual . . . 24
5.8. Qué cambia este trabajo . . . 24

III Las herramientas 24

6. Fundamentos de optimización 24
6.1. Qué es un problema de optimización . . . 25
6.2. Mínimo local, mínimo global y convexidad . . . 25
6.3. Condiciones de optimalidad . . . 26
6.4. Métodos con derivadas: Newton y punto interior . . . 27
6.5. Cómo se obtienen las derivadas: diferenciación automática . . . 27
6.6. Métodos sin derivadas . . . 28

7. Del modelo continuo al problema de optimización 28
7.1. Integrar una ecuación diferencial: Euler explícito e implícito . . . 28
7.2. La rigidez del ROM . . . 29
7.3. Euler implícito convergido y `ode1be` . . . 30
7.4. Cómo entra la dinámica en la optimización . . . 30
7.5. Escalado . . . 31

8. Linealización, sistemas lineales e incertidumbre 31
8.1. Linealizar: la expansión de Taylor de la dinámica . . . 31
8.2. Sistemas lineales y función de transferencia . . . 31
8.3. Programación cuadrática y dualidad . . . 32
8.4. Incertidumbre: de dónde viene y cómo se representa . . . 33

9. Formulaciones propuestas 34
9.1. P0-DET: la formulación actual (disparo simple de caja negra) . . . 35
9.2. N3 monolítica: el NLP exacto . . . 35
9.3. N3 reducida: el mismo problema sólo en los controles . . . 35
9.4. N1: una sola linealización (QP-LTI) . . . 36
9.5. N2: una linealización por paso, iterada (QP-LTV secuencial) . . . 36
9.6. Formulaciones auxiliares . . . 37

10. ¿Cómo se demuestra que una solución es buena? Teoría de la certificación 37
10.1. Cotas superior e inferior y brecha de optimalidad . . . 37
10.2. Relajaciones convexas . . . 38
10.3. Aritmética de intervalos . . . 38
10.4. Verificar que una solución existe: punto fijo . . . 39

IV Resultados 39

11. La réplica del ROM es exacta (F1) 39

12. El problema determinista se resuelve en tiempo real (F2, F3) 40
12.1. La solución del NLP . . . 40
12.2. N1 y N2 frente a N3 . . . 42

13. ¿Es el óptimo global? Certificación del P0 no lineal (F3c) 43
13.1. Planteamiento . . . 43
13.2. Paso 1: la solución es un mínimo local estricto . . . 44
13.3. Paso 2: la discretización de Simulink da el mismo óptimo . . . 44
13.4. Paso 3: no aparece ningún óptimo mejor . . . 44
13.5. Paso 4: una cota inferior del óptimo global . . . 45
13.5.1. Paso 4a: residuo estimado por muestreo (semi-riguroso) . . . 45
13.5.2. Paso 4b: residuo demostrado con aritmética de intervalos . . . 46

14. ¿Cuál método es mejor, y por cuánto? 47
14.1. Métodos comparados . . . 48
14.2. Cómo se compara . . . 48
14.3. Resultados . . . 49

15. ¿El riesgo del pronóstico cambia la decisión? (F4) 49

16. ¿Tienen base física las cotas del actuador? 51

17. Conclusiones 51
17.1. Respuestas a las preguntas . . . 51
17.2. Lo que enseña este caso . . . 52
17.3. Limitaciones . . . 52
17.4. Próximos pasos, por prioridad . . . 53

A. Notación 54

B. Glosario 54

C. Reproducibilidad 56

1 Introducción

1.1 Para quién es este documento y cómo leerlo

Este documento está pensado para alguien que llega al proyecto sin conocerlo: un estudiante de ingeniería o de matemática aplicada que sabe cálculo, álgebra lineal y ecuaciones diferenciales ordinarias, pero que no necesariamente conoce la física de reactores, el control predictivo ni la optimización numérica. Por eso cada concepto se introduce antes de usarse, con un ejemplo cuando ayuda, y cada resultado se acompaña de la pregunta que responde.

El texto tiene cuatro partes:

Parte I. **El problema físico** (secciones 2–3): qué es el reactor SMDFR, cómo se describe su dinámica (neutrones y calor) y qué ocurre en el accidente que se quiere controlar.

Parte II. **El controlador** (secciones 4–5): qué es un control predictivo, qué problema de optimización resuelve en cada instante y cómo lo resuelve hoy el método del proyecto.

Parte III. **Las herramientas** (secciones 6–10): los fundamentos de optimización, integración numérica, linealización, incertidumbre y certificación de optimalidad, y las formulaciones que propone este trabajo.

Parte IV. **Los resultados** (secciones 11–17): qué se obtuvo con cada formulación, cuál es mejor, con qué garantía y qué falta.

Quien ya conozca la física puede saltar a la parte II; quien conozca el control predictivo, a la parte III. Los recuadros sombreados resumen la idea principal de cada sección. Al final hay una tabla de notación, un glosario y las instrucciones para reproducir cada número.

1.2 La problemática en breve

El SMDFR (*Small Modular Dual Fluid Reactor*) es un reactor de 100 MWt con combustible de sal fundida y refrigerante de plomo líquido. Durante un accidente con pérdida de refrigerante (LOCA), el inventario de plomo baja, el caudal del circuito primario cae y sube la temperatura pico de la vaina de los tubos de combustible (PCT, *peak cladding temperature*). Un sistema auxiliar de enfriamiento (ACS) puede reponer refrigerante, pero hay que decidir *cuánto* y *cuándo*: con poco, la PCT se acerca al límite de seguridad; con mucho, se gasta un recurso limitado y se fuerza un componente que puede fallar.

El proyecto aborda esa decisión con un **gemelo digital informado por riesgo**. Un control predictivo (MPC) elige, cada 0.5 s, el caudal del ACS para los próximos 12.5 s. Para predecir usa tres piezas: un modelo reducido del reactor, un pronóstico de la fuga hecho por una red neuronal, y un árbol de eventos con las fallas y reparaciones posibles del ACS. La seguridad se mide con un margen probabilístico (PSM).

El problema de optimización del MPC se resolvía con **metaheurísticas** (Luus–Jaakola y algoritmo genético), porque cada evaluación del costo era una simulación de caja negra en Simulink. Eso tiene tres consecuencias:

- cada consulta tarda unos 800 s, cuando la meta del lazo es menos de 120 s;
- la acción aplicada depende de la semilla aleatoria del optimizador;
- no se sabe cuán lejos está la solución de la mejor posible.

Además, sin un problema tratable no se puede incorporar el riesgo dentro de la decisión, porque eso multiplica el número de escenarios que hay que evaluar. Este documento

propone *formulaciones monolíticas* del mismo problema: el modelo deja de ser una caja negra y pasa a formar parte del problema de optimización como un conjunto de ecuaciones derivables. Luego evalúa esas formulaciones y certifica la calidad de sus soluciones.

1.3 Preguntas que responde este documento

Q1. ¿Se puede resolver el problema del MPC con exactitud y en tiempo real?

Q2. ¿La solución obtenida es el óptimo global? ¿Con qué garantía?

Q3. ¿Cuál método produce la mejor decisión, y por cuánto?

Q4. ¿La incertidumbre del pronóstico de fuga cambia la decisión?

Q5. ¿Las cotas del actuador tienen base física?

Cada sección de resultados termina con un recuadro que responde una de ellas, y la sección 17 las reúne.

1.4 Ruta de trabajo

La idea central es escribir las ecuaciones del modelo reducido *una sola vez*, en forma algebraica y derivable. De esa fuente única salen el problema exacto, sus linealizaciones y las cotas que certifican la calidad de las soluciones. El trabajo se organizó en fases (tabla 1 y figura 1).

Fase	Objetivo	Criterio de cierre	Estado
F0 Ecuaciones	Escribir el ROM término a término desde el archivo de Simulink	Cada término trazado a un bloque	Cerrada
F1 Réplica	ROM algebraico en Julia, con diferenciación automática	Error $\ll 1$ K frente a Simulink	Cerrada
F2 NLP (N3)	P0 como programa no lineal monolítico	Comparado con LJ y GA en Simulink	2 consultas
F3 QP (N1, N2)	P0 linealizado como QP; función de transferencia; certificado dual	Brecha frente a N3 medida	2 consultas
F3c Certificación	Brecha de optimalidad global del P0 no lineal; comparación de decisiones	Brecha certificada pequeña	Pasos 1–4b
F4 Riesgo	Restricción probabilística, SAA, cuantiles	Una decisión que cambie por riesgo	Abierta
F5 Lazo cerrado	Las 61 consultas, multietapa	< 120 s por consulta	Pendiente

Cuadro 1: Fases del trabajo (detalle en `docs/monolithic_formulation_plan.md`).

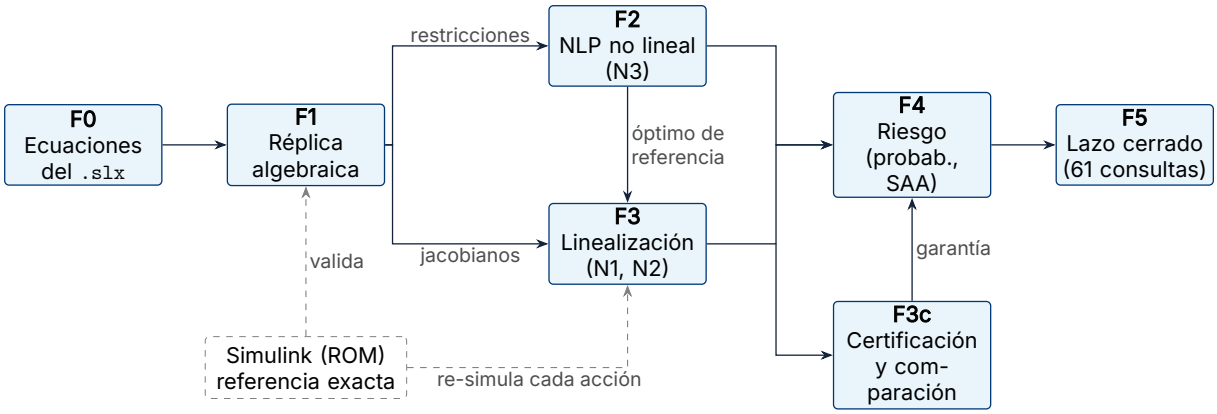


Figura 1: Cómo se encadenan las fases. F0 y F1 producen un modelo derivable y validado. F2 lo usa como restricción (el problema exacto) y F3 como fuente de derivadas (el problema lineal). F3c certifica la calidad de las soluciones. F4 y F5 construyen sobre un problema que ya es tratable y verificado. Las flechas discontinuas son validaciones contra Simulink.

Idea del documento. El controlador del reactor necesita resolver, cada 0.5 s, un problema de optimización sobre un modelo físico. Si el modelo se trata como caja negra, sólo se puede buscar a ciegas. Si se escribe como ecuaciones, se pueden usar derivadas: el problema se resuelve unas 10^4 veces más rápido, de forma reproducible y con garantías sobre la calidad de la solución.

Parte I

El problema físico

2 El reactor SMDFR y su física

Esta sección explica, desde cero, lo necesario para entender el modelo que usa el controlador: qué produce el calor en un reactor, cómo cambia la potencia, cómo viaja el calor hasta el refrigerante y cómo se resume todo en un sistema de ecuaciones diferenciales.

2.1 Qué hace un reactor nuclear

En un reactor de fisión, un neutrón choca con un núcleo pesado (uranio o plutonio), lo parte en dos fragmentos y libera energía (unos 200 MeV por fisión) y entre dos y tres neutrones nuevos. Si en promedio exactamente uno de esos neutrones provoca otra fisión, la reacción en cadena se mantiene estable y el reactor es *crítico*. El número medio de fisiones que produce cada fisión se llama factor de multiplicación k:

- $k = 1$: reactor crítico, potencia constante;
- $k > 1$: supercrítico, la potencia crece;
- $k < 1$: subcrítico, la potencia decae.

En lugar de k se usa la **reactividad** $\rho = (k - 1)/k$, que vale cero en el estado crítico y es pequeña, del orden de 10^{-3}, en las situaciones de interés. La energía de fisión aparece como calor en el combustible, y un fluido refrigerante la extrae y la lleva a donde se aprovecha [7].

2.2 El concepto Dual Fluid y el SMDFR

El *Dual Fluid Reactor* (DFR) fue propuesto como un reactor rápido de alta eficiencia [2]. Pertenece a la IV generación y combina ideas del reactor de sales fundidas y del reactor rápido refrigerado por metal líquido. Su rasgo distintivo es que usa **dos fluidos con funciones separadas**: uno es el combustible y el otro, el refrigerante. Así, cada uno puede optimizarse para su función. El SMDFR es su versión modular pequeña, de $P_0 = 100$ MW térmicos, estudiada por Liu, Luo y Macián-Juan [1]. Su comportamiento transitorio también fue analizado con modelos unidimensionales por Wang et al. [3]. El reactor tiene **tres circuitos** (figura 2):

1. **Combustible**: una sal fundida de tetracloruro de uranio y de plutonio, que circula por 1027 tubos de carburo de silicio. Su caudal es bajo (327.7 kg/s) y sirve para reprocesar el combustible en línea, no para extraer calor.
2. **Refrigerante primario**: plomo líquido, con un caudal de 5550.5 kg/s. Rodea los tubos de combustible y se lleva el calor de fisión. El plomo tiene una temperatura de ebullición muy alta, unos 2000 K, y por eso el circuito puede operar a presión casi atmosférica [6].
3. **Refrigerante secundario**: un segundo circuito de plomo recibe el calor y lo entrega a su uso final: electricidad, producción de hidrógeno o desalación.

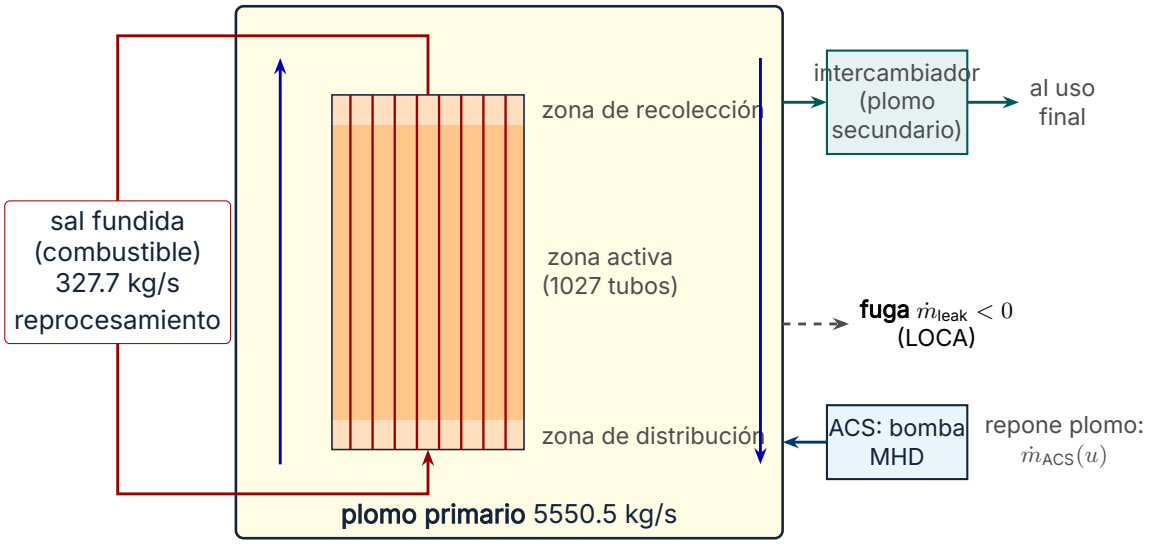


Figura 2: Esquema del SMDFR (adaptado de la descripción de Liu et al. [1]). La sal fundida (rojo) circula por los tubos del núcleo con un caudal bajo, sólo para reprocesarse. El plomo primario (azul) rodea los tubos y extrae el calor, que entrega al circuito de plomo secundario. En el accidente que estudia este trabajo, el circuito primario pierde plomo por una fuga, y el sistema auxiliar (ACS) lo repone con una bomba magnetohidrodinámica.

Parámetro de diseño	Valor
Potencia térmica nominal P_0	100 MW
Zona activa, diámetro $\times$ altura	0.95×2.0 m
Zonas de distribución y de recolección	0.95×0.2 m cada una
Tanque, diámetro $\times$ altura	1.65×3.4 m
Tubos de combustible; paso	1027; 0.025 m
Densidad lineal de potencia media	609 W/cm
Combustible: temperatura de entrada / salida	1300 / 1300 K
Refrigerante (plomo): temperatura de entrada / salida	973 / 1100 K
Caudal de combustible / de refrigerante	327.7 / 5550.5 kg/s
Calor específico del plomo $c_{p,c}$	140.2 J/(kg K)

Cuadro 2: Parámetros principales del SMDFR (Liu et al. [1], tablas 1 y 3).

Ejemplo 1 (¿Cuánto calor se lleva el plomo?)**.** Con la potencia nominal y el salto de temperatura de diseño, el balance de energía del refrigerante es $P_0 \approx \dot{m}_c\, c_{p,c}\,(T_{\text{sal}} - T_{\text{ent}}) = 5550.5 \times 140.2 \times (1100 - 973) \approx 98.8$ MW: el plomo primario se lleva prácticamente toda la potencia. Si el caudal se redujera a la mitad con la misma potencia, el salto de temperatura del plomo se duplicaría. Ése es, en esencia, el problema del accidente que se estudia (sección 3).

2.3 Neutrones y potencia: la cinética puntual

Neutrones inmediatos y retardados. Casi todos los neutrones de fisión nacen en el mismo instante de la fisión: son los neutrones *inmediatos*. Una fracción pequeña, $\beta = 3.02 \cdot 10^{-3}$ en el SMDFR, nace segundos después, cuando decaen ciertos fragmentos de fisión llamados *precursores*. Esos son los neutrones *retardados*. Los precursores se agrupan en seis familias según su vida media, con constantes de decaimiento λ_i que van de 0.0127 a 7.02 s^{-1}.

Aunque son pocos, los neutrones retardados hacen que un reactor sea controlable. El tiempo medio entre dos generaciones de neutrones inmediatos es $\Lambda = 1.05 \cdot 10^{-6}$ s. Si sólo existieran ellos, una reactividad de 10^{-3} haría crecer la potencia con una constante de tiempo del orden de $\Lambda/\rho \approx 1$ ms, demasiado rápido para cualquier sistema mecánico. Con los retardados, mientras $\rho < \beta$, la constante de tiempo pasa a ser del orden de segundos o más [8].

Las ecuaciones de cinética puntual. Si se supone que la forma espacial del flujo de neutrones no cambia, sólo su amplitud, la población de neutrones $N(t)$ y las concentraciones de precursores $C_i(t)$ cumplen

$$\dot{N} = \frac{\rho - \beta}{\Lambda} N + \sum_{i=1}^{6} \lambda_i C_i, \qquad \dot{C}_i = \frac{\beta_i}{\Lambda} N - \lambda_i C_i,$$

con $\beta = \sum_i \beta_i$. La primera ecuación dice que los neutrones aumentan por las fisiones netas (término $(\rho - \beta)N/\Lambda$) y por el decaimiento de los precursores. La segunda, que los precursores se crean en una fracción β_i de las fisiones y desaparecen al decaer. La potencia es proporcional a la población, $P = P_0 N / N_0$.

La deriva de precursores, propia de los reactores de combustible líquido. En el SMDFR el combustible circula, así que una parte de los precursores sale del núcleo antes de decaer

y emite sus neutrones afuera, donde no contribuyen a la reacción en cadena. Se modela con dos depósitos (figura 4 de [1]): C_i dentro del núcleo y C_i^e afuera. Los precursores salen con tasa $\lambda_c = 1/\tau_c$ y vuelven con tasa $\lambda_e = 1/\tau_e$, donde $\tau_c = 5.43$ s y $\tau_e = 10$ s son los tiempos de residencia dentro y fuera del núcleo:

$$\dot{N} = \tfrac{\rho-\beta}{\Lambda} N + \textstyle\sum_i \lambda_i C_i, \qquad \dot{C}_i = \tfrac{\beta_i}{\Lambda} N - (\lambda_i + \lambda_c) C_i + \lambda_e C_i^e, \qquad \dot{C}_i^e = \lambda_c C_i - (\lambda_i + \lambda_e) C_i^e.$$

Proposición 1 (Reactividad estacionaria por la deriva de precursores)**.** *En estado estacionario ($\dot{N} = \dot{C}_i = \dot{C}_i^e = 0$), la reactividad necesaria para mantener la criticidad es*

$$\rho_0 = \beta - \sum_{i=1}^{6} \beta_i \, \frac{\lambda_i}{\lambda_i + \lambda_c - \dfrac{\lambda_c \lambda_e}{\lambda_i + \lambda_e}} > 0.$$

Demostración. De $\dot{C}_i^e = 0$ se obtiene $C_i^e = \lambda_c C_i/(\lambda_i + \lambda_e)$. Sustituyendo en $\dot{C}_i = 0$: $\frac{\beta_i}{\Lambda} N = \big(\lambda_i + \lambda_c - \frac{\lambda_c\lambda_e}{\lambda_i+\lambda_e}\big) C_i$. Llevando C_i a $\dot{N} = 0$ resulta $(\beta - \rho_0) N/\Lambda = \sum_i \lambda_i C_i$, de donde sale la fórmula. Cada fracción es menor que uno, porque el denominador supera a λ_i, así que $\rho_0 > 0$. Simplificando el denominador, $\lambda_i/\big(\lambda_i + \lambda_c - \frac{\lambda_c\lambda_e}{\lambda_i+\lambda_e}\big) = (\lambda_i + \lambda_e)/(\lambda_i + \lambda_e + \lambda_c)$, que es la forma de la ecuación (5) de Liu et al. [1]. □

Con los datos del SMDFR, la fórmula da $\rho_0 = 1.1105 \cdot 10^{-3}$, que coincide con el valor $1.11 \cdot 10^{-3}$ del modelo. Esto es aproximadamente el 37 % de β: el reactor debe tener una reactividad de reserva de ese tamaño sólo para compensar los precursores que decaen fuera del núcleo.

Realimentación por temperatura. La reactividad no es una constante: depende de las temperaturas, porque al calentarse el combustible y el refrigerante cambian su densidad y sus secciones eficaces [7]. El modelo usa una relación lineal:

$$\rho = \rho_0 + \alpha_f \big(T_f - \bar{T}_{f0}\big) + \alpha_c \big(T_c - \bar{T}_{c0}\big) + \rho_{\text{ext}},$$

con $\alpha_f = -2.08 \cdot 10^{-4}$ K^{-1} para el combustible y $\alpha_c = -8.28 \cdot 10^{-6}$ K^{-1} para el refrigerante. Los dos coeficientes son negativos: si el núcleo se calienta, la reactividad baja y la potencia también. Es una realimentación *estabilizante*.

Ejemplo 2 (Peso de la realimentación del combustible)**.** Un aumento de 1 K en el combustible aporta $\Delta\rho = -2.08 \cdot 10^{-4}$, que es el 7 % de β. Uno de 10 K aporta el 69 % de β. Por eso, en el SMDFR, la temperatura del combustible gobierna en buena medida la potencia. Liu et al. encontraron precisamente que α_f es el parámetro incierto más influyente sobre el comportamiento del reactor [1].

2.4 Calor: del combustible al refrigerante

El camino del calor. El calor nace en el combustible, atraviesa la pared del tubo y pasa al plomo, que lo transporta fuera del núcleo (figura 3). En un modelo *concentrado* (*lumped*), cada material se representa por una temperatura media, y cada temperatura cambia según un balance de energía: masa $\times$ calor específico $\times$ derivada de la temperatura $=$ calor que entra $-$ calor que sale [9, 10].

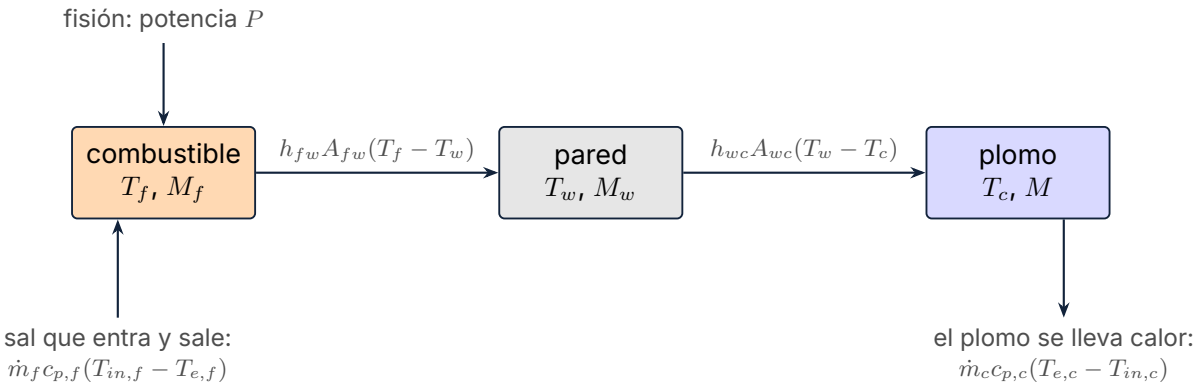


Figura 3: El camino del calor en un nodo. Cada flecha es un flujo de calor. Entre dos materiales, el flujo es proporcional a la diferencia de temperaturas, con un coeficiente de transferencia h por un área A. El plomo, además, transporta calor fuera del nodo con su caudal.

Por qué importa el caudal. El coeficiente de transferencia de calor entre la pared y un fluido que fluye por un conducto crece con el caudal. En flujo turbulento de fluidos ordinarios, la correlación de Dittus–Boelter da un número de Nusselt proporcional a $\mathrm{Re}^{0.8}$ [9]. Para metales líquidos, cuyo número de Prandtl es muy bajo, se usan correlaciones del tipo $\mathrm{Nu} = 7 + 0.025\,\mathrm{Pe}^{0.8}$, con el mismo exponente sobre el número de Péclet [10]. El modelo adopta la ley de potencia pura como aproximación:

$$h_{wc}(\dot{m}_c) = h_{wc0}\left(\frac{\dot{m}_c}{5550}\right)^{0.8}.$$

Si el caudal baja al 60 %, h_{wc} baja al $0.6^{0.8} \approx 66$ %: el plomo extrae peor el calor de la pared, y la pared se calienta.

2.5 El modelo de 12 nodos y su versión reducida

El modelo de alta resolución (HRM). Liu et al. dividen el núcleo en 12 nodos de 0.2 m: el nodo 1 es la zona de distribución, los nodos 2 a 11 la zona activa y el nodo 12 la de recolección. En cada nodo hay tres temperaturas, combustible, pared y refrigerante, con los balances de la figura 3, y el plomo que sale de un nodo entra al siguiente. Los parámetros vienen de un modelo tridimensional acoplado: neutrónica con Serpent y la biblioteca ENDF/B-VII, y termohidráulica con COMSOL [1]. En este proyecto, ese modelo de 12 nodos, implementado en Simulink, es la **planta**: hace las veces del reactor real.

El modelo reducido (ROM). Para predecir dentro del controlador se usa una versión más simple: **un solo nodo por material**. Las masas y las áreas son la suma de las de los 12 nodos; por ejemplo, $M_c = 10 \times 770.5 + 2 \times 219.9 = 8144.8$ kg y $A_{fw} = 10 \times 9.0 + 2 \times 13.6 = 117.2$ m^2. Los coeficientes de transferencia son el promedio de los de las tres zonas. Su estado tiene 17 componentes (tabla 3):

$$x = (N,\ C_{1..6},\ C^e_{1..6},\ T_f,\ T_w,\ T_c,\ \Delta M).$$

Estado	Significado	Valor en $t_q = 1180$ s
N	Población de neutrones (proporcional a la potencia)	$1.73 \cdot 10^{13}$ ($P = 115$ MW)
$C_{1..6}$	Precursores dentro del núcleo, 6 grupos	10^{15}–10^{16}
$C^e_{1..6}$	Precursores fuera del núcleo	10^{15}–10^{16}
T_f	Temperatura media del combustible	1265.4 K
T_w	Temperatura media de la pared de los tubos	1105.6 K
T_c	Temperatura media del plomo	1049.0 K
ΔM	Inventario de plomo ganado (negativo: perdido)	-3230 kg

Cuadro 3: Las 17 variables de estado del ROM. Los órdenes de magnitud van de 10^3 a 10^{16}, y eso obliga a escalar las variables en la optimización (sección 9).

Ecuaciones completas del ROM. La cinética es la de deriva de precursores. La termohidráulica, con un nodo promedio cuya temperatura de salida es $T_e = 2T - T_{in}$, es

$$\begin{aligned} M_f c_{pf} \dot{T}_f &= P + \dot{m}_f c_{pf}(T_{in,f} - T_{e,f}) - h_{fw} A_{fw}(T_f - T_w), \\ M_w c_{pw} \dot{T}_w &= h_{fw} A_{fw}(T_f - T_w) - h_{wc}(\dot{m}_c) A_{wc}(T_w - T_c), \\ (M_c + \Delta M)\, c_{pc} \dot{T}_c &= \dot{m}_c c_{pc}(T_{in,c} - T_{e,c}) + h_{wc}(\dot{m}_c) A_{wc}(T_w - T_c). \end{aligned}$$

El inventario y el caudal primario cumplen

$$\Delta \dot{M} = \dot{m}_{\text{leak}}(t) + \dot{m}_{\text{ACS}}, \qquad \dot{m}_c = \dot{m}_{\text{nom}} \frac{M_c + \Delta M}{M_c}.$$

La segunda relación dice que el caudal del circuito es proporcional al inventario de plomo: si queda el 60 % del plomo, circula el 60 % del caudal nominal.

La salida: la PCT estimada. El ROM da la temperatura *media* de la pared, pero la seguridad depende de la temperatura *máxima*, que está en el nodo más caliente del HRM. La diferencia se corrige con un polinomio de grado 4 ajustado por regresión a los datos del HRM:

$$\hat{y} = T_w + p_4(\dot{m}_{\text{leak}} + \dot{m}_{\text{ACS}} + 5550) + 0.4.$$

En las consultas, $T_w \approx 1106$ K y $p_4 \approx 73.6$ K, así que $\hat{y} \approx 1180$ K.

Forma compacta. Todo lo anterior se escribe como un sistema

$$\dot{x} = f(x, d, u), \qquad \hat{y} = h(x, d, u),$$

donde $d = \dot{m}_{\text{leak}}$ es la perturbación (la fuga) y $u = \dot{m}_{\text{ACS}}$ es la decisión del controlador. Toda la sección 9 trabaja con esta forma.

Para recordar. El ROM es un sistema de 17 ecuaciones diferenciales ordinarias no lineales. Los neutrones responden en milisegundos y las temperaturas, en segundos. El caudal del ACS entra *sólo* en el inventario ΔM: no enfría directamente, sino que aumenta la cantidad de plomo, eso aumenta el caudal primario y eso mejora la extracción de calor.

3 El accidente: pérdida de refrigerante (LOCA)

3.1 Qué es un LOCA y por qué es peligroso

Un LOCA (*loss-of-coolant accident*) es un accidente en el que el circuito de refrigeración pierde fluido por una ruptura. En este trabajo se estudia un LOCA de *pequeña ruptura* en el circuito de plomo primario del SMDFR: el plomo se escapa por una fuga de caudal $\dot{m}_{\text{leak}}(t) < 0$. El peligro no está en la fuga misma, sino en la cadena de efectos que desencadena (figura 4).

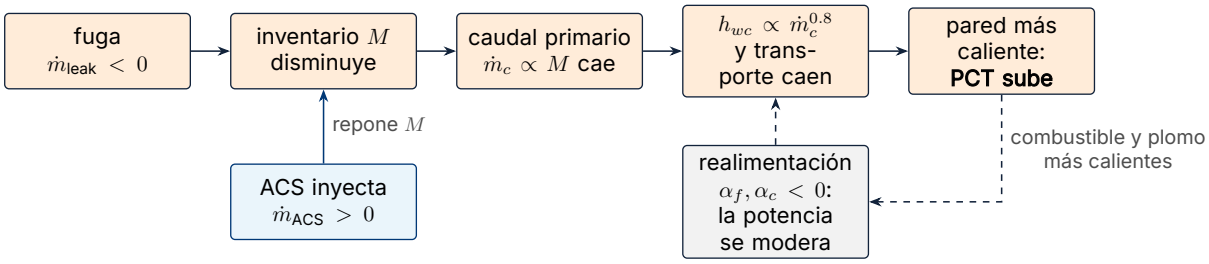


Figura 4: La cadena causal del accidente. La fuga reduce el inventario; con menos plomo circula menos caudal; con menos caudal el plomo extrae peor el calor de la pared, y la temperatura de la pared sube. El ACS actúa sobre el segundo eslabón, reponiendo inventario. La realimentación de reactividad modera la potencia, pero no detiene el calentamiento.

3.2 El accidente en el tiempo

La figura 5 muestra el transitorio completo, tal como lo simula el HRM (los datos son los del lazo archivado):

- **Antes de la ruptura** ($t < 500$ s), el reactor opera en régimen estacionario, con una PCT de unos 1142.7 K, 100 K por debajo del límite de seguridad.
- **En $t = 500$ s se produce la ruptura**: la fuga salta a -10 kg/s y luego decae lentamente, hasta unos -4.6 kg/s en $t = 1160$ s.
- **El inventario se pierde de forma sostenida**: hasta $t = 1160$ s se escapan unos 3350 kg, el 41 % del plomo del circuito ($M_c = 8144.8$ kg).
- **La PCT sube de forma casi lineal**, unos 0.06 K/s. Cruza el umbral de demanda del ACS (1180 K) en $t \approx 1142$ s.
- **El controlador actúa entre 1160 y 1190 s**: cada 0.5 s se hace una *consulta* al MPC, 61 en total.

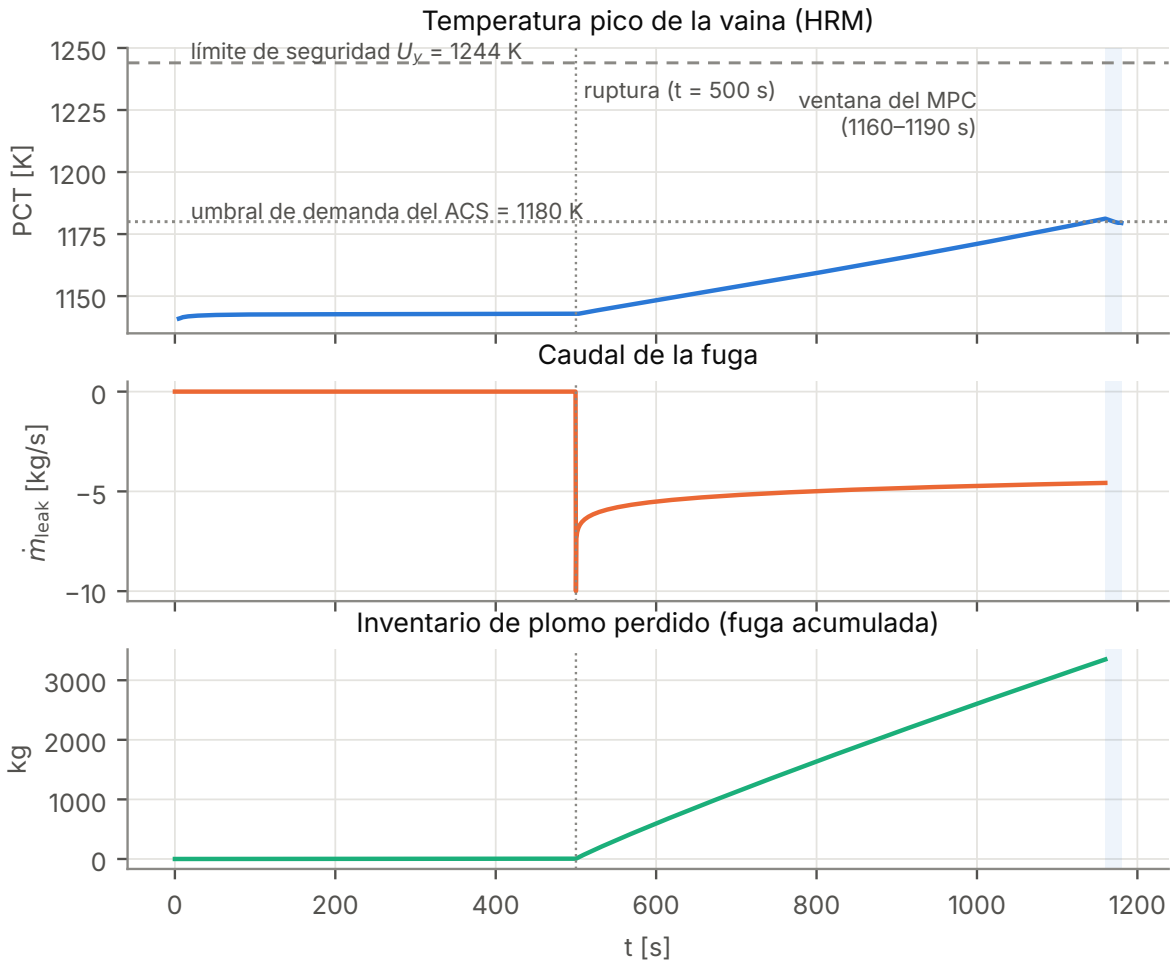


Figura 5: El accidente simulado por el HRM (datos del lazo archivado). Arriba, la PCT; al medio, el caudal de la fuga; abajo, el plomo perdido, que es la integral de la fuga. La franja azul marca el periodo en que actúa el controlador. Se omitieron los primeros 5 s (arranque de la simulación) y una muestra aislada en $t = 1160.5$ s, un artefacto del registro al reiniciar el HRM en la primera consulta. La fuga integrada hasta 1160 s (-3349 kg) coincide con el inventario perdido del estado de la consulta de 1161 s (-3337 kg): antes de 1160 s el ACS no inyectó.

3.3 Por qué sube la PCT: los números

En la consulta de 1180 s queda el 60 % del inventario, así que el caudal primario es $\dot{m}_c = 0.603\,\dot{m}_{\text{nom}} \approx 3349$ kg/s. Esto tiene dos efectos:

1. **El plomo extrae peor el calor de la pared**: h_{wc} cae al $0.603^{0.8} \approx 67$ % de su valor nominal.
2. **El plomo se calienta más al atravesar el núcleo**: con una potencia de 115 MW, el salto de temperatura del refrigerante es $P/(\dot{m}_c c_{p,c}) \approx 245$ K, frente a 128.5 K en condiciones nominales.

Para devolver el caudal al 80 % del nominal habría que reponer unos 1600 kg de plomo. Con el caudal máximo del ACS, unos 12.9 kg/s, menos la fuga de 4.6 kg/s, eso tomaría unos 190 s: mucho más que el horizonte de 12.5 s del controlador. Dentro de una consulta, el ACS sólo puede corregir la PCT en unos pocos kelvin (sección 3.6).

3.4 El actuador: la bomba magnetohidrodinámica del ACS

Principio de funcionamiento. El plomo líquido conduce la electricidad. Una bomba MHD de conducción hace circular una corriente eléctrica I a través del metal, dentro de un campo magnético B. La fuerza de Lorentz $\mathbf{f} = \mathbf{J} \times \mathbf{B}$ empuja el fluido sin piezas móviles [5].

El modelo de la bomba. El proyecto usa un modelo de circuito equivalente (ECM) de una bomba MHD de corriente continua para el DFR [5]:

$$\Delta P = C\,I - B\,Q - A\,Q^2,$$

donde Q es el caudal volumétrico. El término $C\,I$ es el empuje de Lorentz; $B\,Q$, las pérdidas electromagnéticas, que crecen con la velocidad del fluido; y $A\,Q^2$, la fricción hidráulica. La bomba debe vencer una contrapresión $\Delta P = 15$ kPa, así que sólo empieza a mover plomo cuando $C\,I > \Delta P$, es decir, a partir de $I_0 = \Delta P / C = 56.687$ A. Por encima de ese umbral, el caudal másico $\dot{m} = \rho Q$ crece unos 205 kg/s por cada amperio (figura 6).

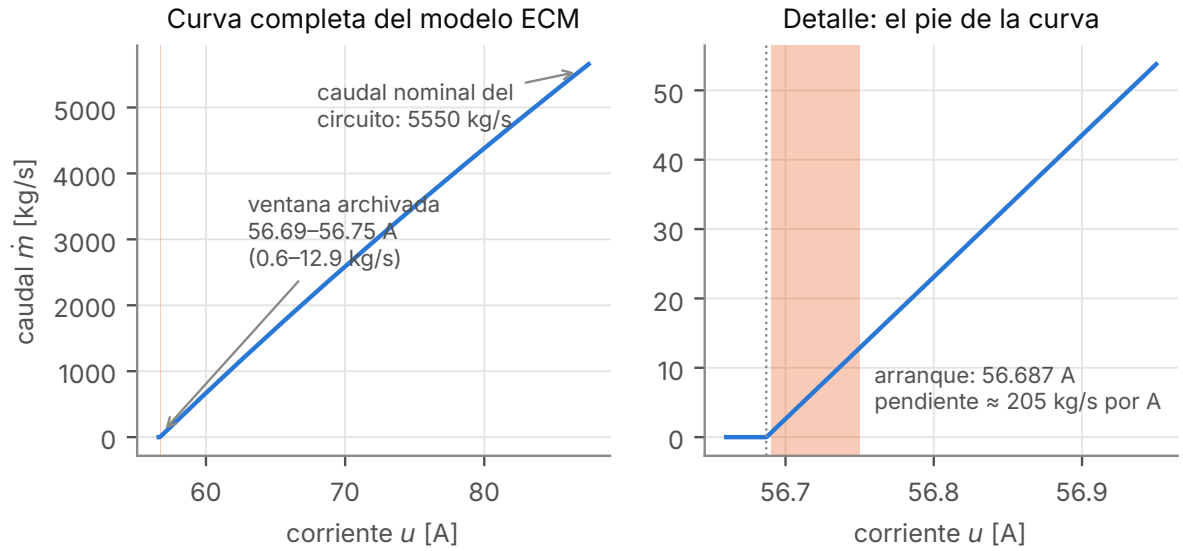


Figura 6: Curva de la bomba MHD según el modelo ECM. Izquierda: la curva completa; el caudal nominal del circuito primario (5550 kg/s) se alcanza con unos 87 A. Derecha: el detalle del pie de la curva. La ventana de operación del ACS en el lazo archivado, 56.69–56.75 A (franja naranja), corresponde a sólo 0.6–12.9 kg/s.

La figura deja ver algo importante para el resto del documento. La ventana de operación del ACS ocupa apenas 0.06 A del pie de una curva que llega a miles de kg/s. Con esa pendiente, 1 mA de corriente equivale a 0.2 kg/s de caudal. La sección 16 discute qué significa esto para las cotas del controlador.

3.5 Variables, límites y referencia

Magnitud	Significado	Valor
PCT, $\hat{y}$	Temperatura pico de la pared de los tubos, estimada por el ROM	~ 1180 K
U_y	Límite de seguridad de la PCT	1244 K
Umbral de demanda	PCT a partir de la cual se demanda el ACS	1180 K
y_{ref}	Referencia que persigue el controlador (64.7 K bajo el límite)	1179.27 K
$u = \dot{m}_{\text{ACS}}$	Caudal inyectado por el ACS (la decisión)	0.58–12.86 kg/s
Δt, K	Paso de decisión y número de pasos del horizonte	0.5 s, 26

Cuadro 4: Magnitudes del problema de control.

3.6 ¿Cuánto puede hacer el actuador en un horizonte?

La figura 7 responde con el modelo no lineal: simula la PCT durante los 12.5 s del horizonte con cinco caudales constantes del ACS, desde el mínimo hasta el máximo. Entre el caudal mínimo y el máximo, la PCT al final del horizonte difiere en unos 2.5 K. En 1180 s basta un caudal intermedio para llegar a la referencia. En 1161 s, en cambio, ni siquiera el caudal máximo alcanza la referencia en 12.5 s: el controlador sólo puede acercar la PCT, y la mejor decisión es inyectar al máximo.

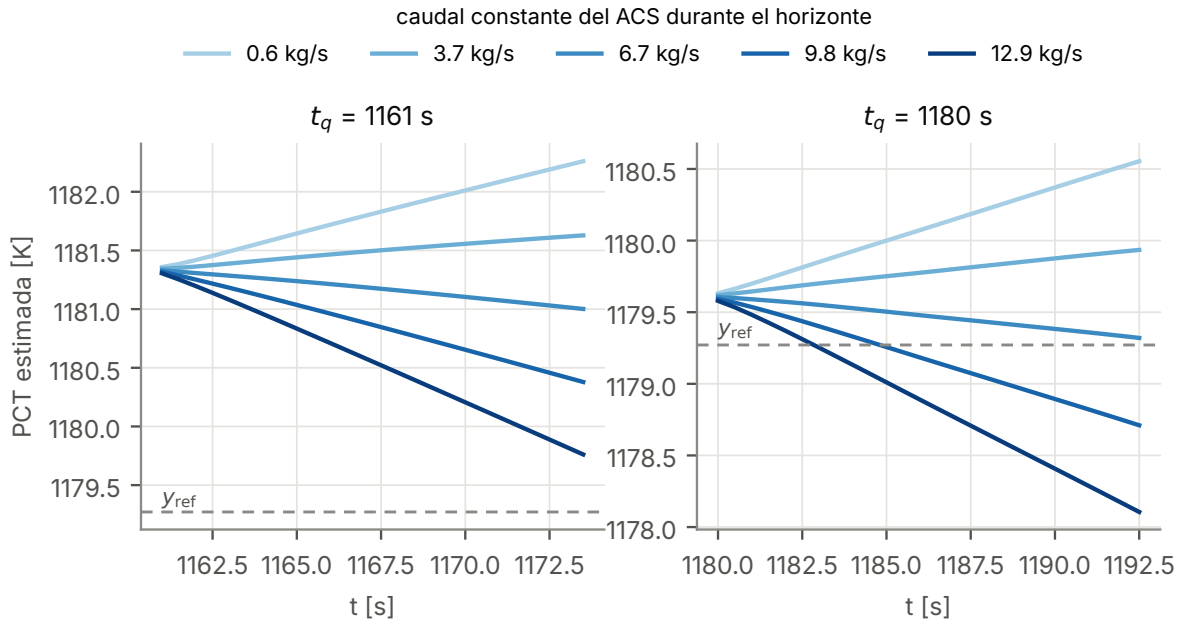


Figura 7: Autoridad del actuador. PCT estimada por el ROM no lineal durante el horizonte, para cinco caudales constantes del ACS. La diferencia entre el mínimo y el máximo al final del horizonte es de unos 2.5 K en las dos consultas.

Para recordar. En el accidente, la fuga vacía lentamente el circuito primario y la PCT sube unos 0.06 K/s. El ACS repone plomo, pero su efecto se acumula despacio: en un horizonte de 12.5 s mueve la PCT sólo unos 2.5 K. Decidir bien cuánto inyectar en cada instante es justamente el problema del controlador.

Parte II
El controlador

4 El control predictivo (MPC)

4.1 Controlar: lazo abierto y lazo cerrado

Controlar es elegir la entrada de un sistema, aquí el caudal del ACS, para que su salida, la PCT, se comporte como se desea. En *lazo abierto* la entrada se fija de antemano. En *lazo cerrado*, o con realimentación, la entrada se recalcula a partir de lo que se mide, y eso permite corregir perturbaciones y errores del modelo. El controlador PI de Liu et al. [1], por ejemplo, ajusta la reactividad en proporción al error de potencia y a su integral. Es simple y robusto, pero no anticipa: reacciona al error ya ocurrido y no tiene en cuenta las restricciones de forma explícita.

4.2 La idea del control predictivo

El **control predictivo basado en modelo** (MPC, *model predictive control*) [11, 12] resuelve, en cada instante de decisión, un problema de optimización:

1. **medir** o estimar el estado actual del sistema, $x_0 = \hat{x}(t_q)$;
2. **predecir**, con un modelo, cómo evolucionará la salida durante un horizonte futuro, para cada secuencia candidata de entradas $u_1, \ldots, u_K$;
3. **optimizar**: elegir la secuencia que minimiza un costo y cumple las restricciones;
4. **aplicar sólo la primera acción** $u_1^\star$;
5. **repetir** en el instante siguiente, con una nueva medición.

El horizonte se desplaza con el tiempo (figura 8), y por eso se habla de *horizonte deslizante*. Aunque cada problema se resuelve en lazo abierto, re-optimizar con cada medición nueva cierra el lazo: los errores del modelo o del pronóstico se corrigen en la consulta siguiente.

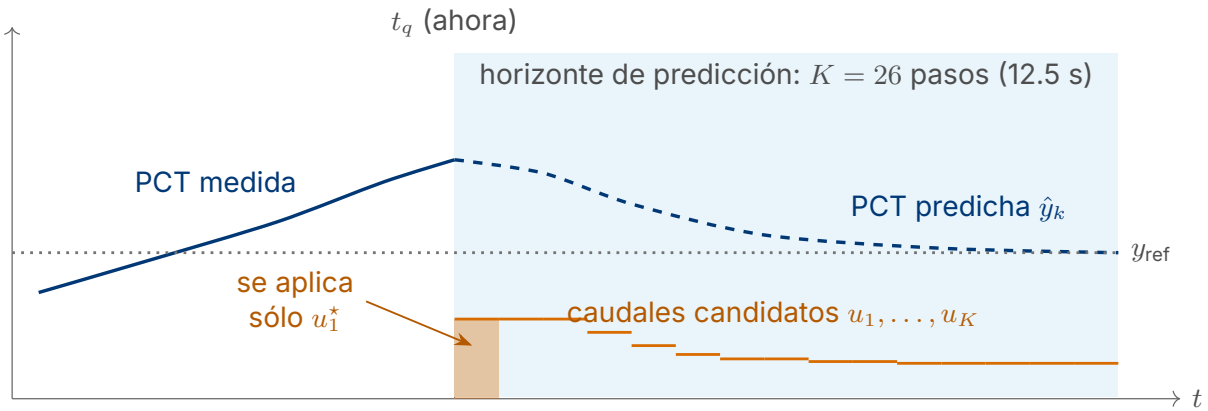


Figura 8: El horizonte deslizante. En el instante t_q, el MPC predice la PCT durante 12.5 s para una secuencia de caudales y elige la mejor. Aplica sólo el primer caudal (barra sombreada) y, 0.5 s después, repite todo con el horizonte desplazado.

Ejemplo 3 (Una analogía)**.** Al conducir se mira cien metros adelante, se planifica cómo frenar y girar, se ejecuta sólo el movimiento inmediato y se vuelve a mirar. Nadie ejecuta a ciegas el plan de los cien metros: la carretera cambia y el plan se rehace continuamente. El MPC hace lo mismo, con un modelo matemático en lugar de la intuición.

4.3 Los elementos de un MPC

- **Modelo de predicción**: el ROM de la sección 2, $\dot{x} = f(x, d, u)$, $\hat{y} = h(x, d, u)$.
- **Discretización**: el horizonte se divide en $K = 26$ pasos de $\Delta t = 0.5$ s. El caudal es constante dentro de cada paso.
- **Perturbación pronosticada**: la fuga futura $\hat{d}_1, \ldots, \hat{d}_K$, que no se conoce y se pronostica con una red neuronal (sección 5).
- **Costo**: lo que se quiere minimizar.
- **Restricciones**: lo que no se puede violar, como las cotas del actuador.

4.4 El problema de control P0, término por término

Con el estado estimado $x_0 = \hat{x}(t_q - \Delta t)$ y el pronóstico $\hat{d}_k$, el problema P0 elige los caudales $u_1, \ldots, u_K$:

$$\min_{u,\,x} \quad J = \underbrace{\sum_{k=1}^{K} (\hat{y}_k - y_{\text{ref}})^2}_{\text{(a) seguimiento}} + \underbrace{\lambda_m \sum_{k=1}^{K-1} \left[\,|u_{k+1} - u_k| - \Delta\dot{m}\right]_+^2}_{\text{(b) suavidad}} + \underbrace{\lambda_{\text{pct}} \sum_{k=1}^{K} \left[\hat{y}_k - U_y\right]_+^2}_{\text{(c) seguridad}}$$

$$\text{s.a.} \quad x_k = x_{k-1} + \Delta t\, f(x_k, \hat{d}_k, u_k), \qquad k = 1, \ldots, K \qquad \text{(dinámica)},$$

$$\dot{m}_{\min} \le u_k \le \dot{m}_{\max} \qquad \text{(cotas del actuador)},$$

donde $[z]_+ = \max(z, 0)$ es la *bisagra*: vale cero si $z \le 0$ y z si $z > 0$.

(a) **Seguimiento.** Penaliza el cuadrado de la distancia entre la PCT predicha y la referencia. Un error de 0.1 K en los 26 pasos cuesta $26 \times 0.01 = 0.26$; uno de 1 K cuesta 26. El cuadrado castiga más los errores grandes.

(b) **Suavidad.** Penaliza los saltos de caudal mayores que $\Delta\dot{m} = 5$ kg/s entre pasos consecutivos. Como $\lambda_m = 10^{-4}$, es una penalización muy suave: un salto de 10 kg/s cuesta $10^{-4} \times 5^2 = 0.0025$.

(c) **Seguridad.** Penaliza cualquier PCT por encima de $U_y = 1244$ K, con un peso grande ($\lambda_{\text{pct}} = 10$). Como la referencia está 64.7 K por debajo del límite, en las consultas estudiadas este término vale cero.

La restricción de dinámica usa Euler implícito, igual que el integrador de Simulink; la sección 7 explica por qué.

Parámetro	Valor	Origen
Horizonte K, paso Δt	26 pasos de 0.5 s (12.5 s)	lazo archivado
Referencia de PCT y_{ref}	1179.271 K	lazo archivado
Límite de PCT U_y	1244 K	`fitness_cost.m`
Pesos λ_m, λ_{pct}; rampa $\Delta\dot{m}$	10^{-4} y 10; 5 kg/s por paso	`fitness_cost.m`
Cotas del actuador	$u \in [56.69, 56.75]$ A, es decir, $\dot{m} \in [0.58, 12.86]$ kg/s	lazo archivado (sec. 16)

Cuadro 5: Parámetros de P0 usados en todo el documento.

4.5 Las dos consultas de prueba

Todo el análisis de este documento se hace sobre dos consultas del lazo archivado, que representan dos situaciones distintas:

	$t_q = 1161$ s (fase aguda)	$t_q = 1180$ s
PCT estimada al inicio	1181.35 K (2.1 K sobre la referencia)	1179.61 K (0.34 K sobre la referencia)
Fuga	-4.58 kg/s	-4.56 kg/s
Inventario perdido	3337 kg (41 %)	3230 kg (40 %)
Caudal primario	0.590 del nominal	0.603 del nominal
Potencia	114 MW	115 MW
Pronóstico de fuga usado	fuga real del HRM (pronóstico perfecto)	una muestra de la BiLSTM (archivo)

Cuadro 6: Estado del reactor en las dos consultas.

En 1161 s la PCT está lejos de la referencia y el actuador no alcanza a corregirla: la decisión correcta es inyectar al máximo. En 1180 s está cerca, y la decisión es más fina: inyectar al máximo unos segundos y luego bajar el caudal para no sobrepasar la referencia.

4.6 Por qué este problema es difícil

- **No lineal**: el caudal primario multiplica temperaturas, h_{wc} depende de $\dot{m}_c^{0.8}$ y la cinética multiplica reactividad por población.
- **Rígido**: los neutrones evolucionan en milisegundos y el inventario en minutos.
- **Mal escalado**: las variables van de 10^3 a 10^{16}.
- **Incierto**: la fuga futura se pronostica, y el ACS puede fallar.
- **En tiempo real**: hay que decidir en una fracción del intervalo entre consultas.

Para recordar. En cada consulta, el MPC resuelve P0: elegir 26 caudales que mantengan la PCT predicha cerca de la referencia, sin saltos bruscos y sin superar el límite, respetando las ecuaciones del reactor. Sólo se aplica el primer caudal, y 0.5 s después se vuelve a resolver.

5 El método actual: gemelo digital con árbol de eventos y metaheurística

Esta sección describe lo que el método del proyecto hace hoy, antes de los cambios que propone este documento. Un *gemelo digital* es un modelo que corre en paralelo con la planta, alimentado por sus mediciones, y que se usa para predecir y decidir. Aquí tiene cuatro piezas: un pronóstico de la fuga, un predictor con fallas del ACS, un optimizador y una evaluación de riesgo (figura 9).

5.1 Arquitectura del gemelo digital

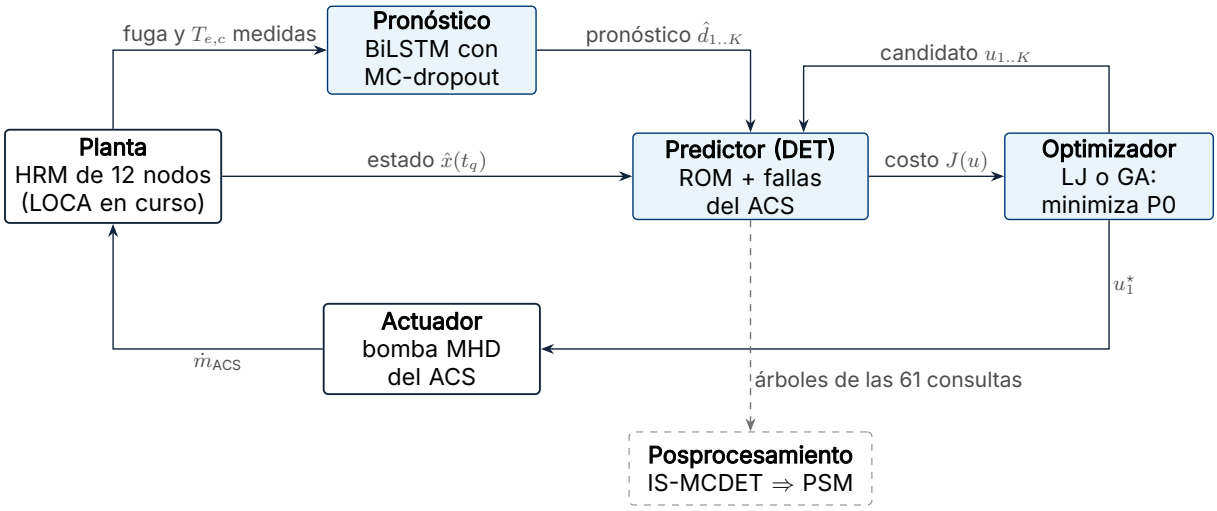


Figura 9: El lazo del gemelo digital. En cada consulta t_q (cada 0.5 s entre 1160 y 1190 s), el optimizador propone secuencias de caudal, el predictor las evalúa simulando el árbol de eventos y se aplica la primera acción de la mejor. El riesgo (PSM) se calcula después, en el posprocesamiento.

5.2 El pronóstico de la fuga: una red BiLSTM con MC-dropout

El problema. El controlador necesita la fuga futura $\hat{d}_1, \ldots, \hat{d}_K$, que no se conoce. Se pronostica a partir de su historia reciente.

La red. Una red neuronal recurrente procesa una serie de tiempo paso a paso, manteniendo una memoria interna. Las redes LSTM (*long short-term memory*) añaden compuertas que deciden qué recordar y qué olvidar, lo que les permite capturar dependencias largas [29]. Una red *bidireccional* (BiLSTM) recorre la ventana en los dos sentidos. La red del proyecto tiene 2 capas de 32 unidades en cada sentido y una capa de salida de 64 a 10 a 2 neuronas. Recibe las últimas 200 muestras de la fuga medida y de la temperatura de salida del refrigerante, normalizadas, y devuelve la fuga pronosticada.

La incertidumbre: MC-dropout. El *dropout* apaga al azar una fracción de las neuronas durante el entrenamiento. Si se mantiene activo también al predecir, cada inferencia da un resultado distinto. Gal y Ghahramani mostraron que el conjunto de esas predicciones aproxima la distribución predictiva de una red bayesiana [30]. Repitiendo la inferencia N_{par} veces se obtiene un *ensamble* de trayectorias de fuga.

¿Por qué 59 trayectorias? El diseño del proyecto usa $N_{\text{par}} = 59$, la misma cantidad de corridas que Liu et al. para cuantificar incertidumbre [1]. El número viene de la regla de Wilks para límites de tolerancia [31, 32].

Proposición 2 (Regla de Wilks de primer orden, unilateral)**.** *Sea $Y_1, \ldots, Y_N$ una muestra independiente de una variable continua Y y $q_{0.95}$ su cuantil 95 %. El máximo de la muestra supera a $q_{0.95}$ con probabilidad $1 - 0.95^N$. Esa probabilidad es al menos 0.95 si y sólo si $N \geq 59$.*

Demostración. Cada Y_i queda por debajo de $q_{0.95}$ con probabilidad 0.95, y por independencia todos quedan por debajo con probabilidad 0.95^N. El máximo supera el cuantil en el

caso complementario. La condición $1 - 0.95^N \geq 0.95$ equivale a $N \geq \ln 0.05 / \ln 0.95 = 58.4$; el primer entero es 59, con $0.95^{59} = 0.0485$. □

Con 59 trayectorias, el valor más alto del ensamble es entonces una cota superior del 95 % de los casos con un 95 % de confianza (criterio 95/95). En P0 se usa la mediana del ensamble. El lazo archivado, sin embargo, corría con $N_{\text{par}} = 1$: decidía con una sola realización aleatoria (sección 15).

5.3 El predictor: árbol dinámico de eventos (DET)

Idea. Un árbol de eventos clásico enumera de antemano las secuencias de fallas posibles. Un *árbol dinámico de eventos* las genera durante la simulación: cuando el sistema llega a un punto en el que un componente puede fallar o repararse, la simulación se ramifica, y cada rama continúa con su propia física [33]. MCDET combina esa idea con muestreo de Monte Carlo de las tasas y de los instantes de transición [34].

En este proyecto. El ACS tiene 5 componentes. Cada componente j puede fallar con tasa λ_j^{A} y repararse con tasa μ_j^{A}. El estado del ACS es un par (demanda, disponibilidad), que da tres modos: sin demanda; demandado y disponible; demandado y fallado. Cuando la PCT supera 1180 K el ACS se demanda, y a partir de ahí las transiciones de falla y reparación ramifican la trayectoria (figura 10):

- el nodo raíz simula el ROM desde la consulta;
- en cada instante de transición nace un nodo hijo, que continúa la simulación con el nuevo modo del ACS (si falla, deja de inyectar);
- cada juego de tasas remuestreadas produce un árbol, y los árboles de una consulta forman su *bosque*.

Cada nodo es una simulación del ROM en Simulink, que arranca del estado final de su nodo padre.

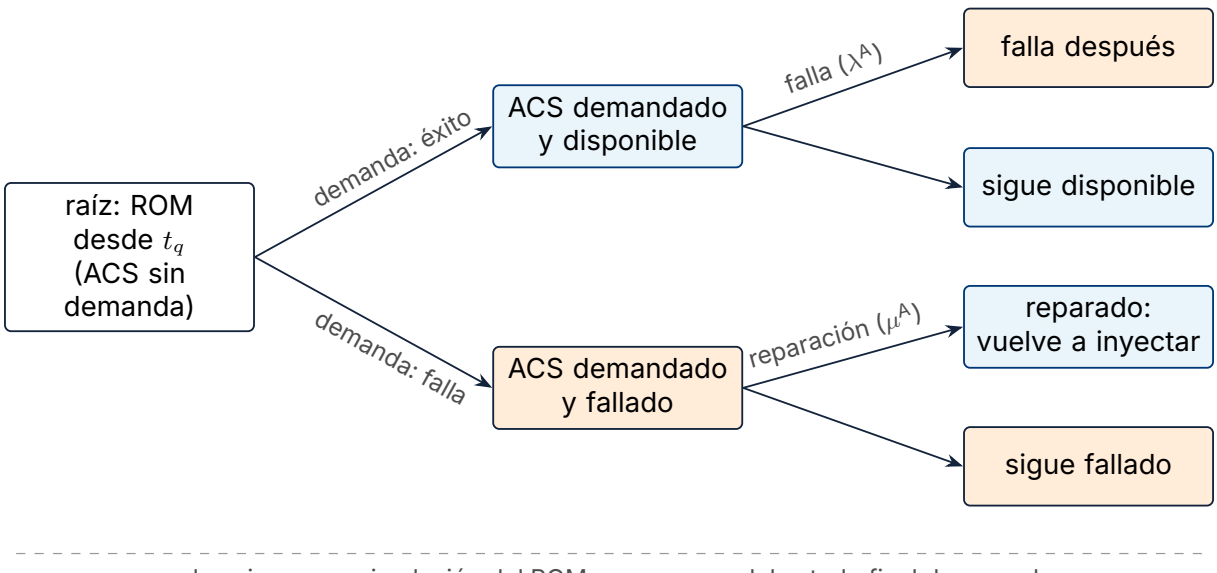


Figura 10: Esquema de un árbol dinámico de eventos para el ACS. Las ramas nacen cuando el ACS se demanda y cuando sus componentes fallan o se reparan; las probabilidades de cada rama dependen de las tasas λ^{A} y μ^{A}. En las consultas estudiadas, ninguna transición cae dentro del horizonte de 12.5 s y el árbol se reduce a la raíz.

5.4 El problema de optimización del MPC actual (P0-DET)

Para un candidato $u = (u_1, \ldots, u_K)$, expresado en corrientes y convertido en caudal con el mapa de la bomba, $\dot{m}_k = f_{\mathsf{ACS}}(u_k)$, la función `fitness_cost.m` reconstruye la PCT de *todos* los nodos del árbol y calcula

$$J_{\mathsf{DET}}(u) = \sum_{j \in \mathcal{I}(u)} \big(\hat{y}_j - y_{\mathsf{ref}}\big)^2 + \lambda_m \sum_{k=1}^{K-1} \big[|\dot{m}_{k+1} - \dot{m}_k| - \Delta\dot{m}\big]_+^2 + \lambda_{\mathsf{pct}} \sum_{j \in \mathcal{I}(u)} \big[\hat{y}_j - U_y\big]_+^2,$$

sujeto a $u_{\mathsf{min}} \le u_k \le u_{\mathsf{max}}$. Aquí $\mathcal{I}(u)$ es el conjunto de muestras de PCT de todos los nodos del árbol, concatenadas. Ese conjunto depende de u, porque las ramas dependen de cuándo la PCT cruza el umbral. Hay una variante opcional que penaliza el margen determinista $\mathrm{DSM}_j = (\hat{y}_j - y_{\mathsf{ref}})/(U_y - y_{\mathsf{ref}})$ por encima de un umbral. El MPC aplica sólo $u_1^\star$ y repite en la consulta siguiente. Cuando el árbol queda en la raíz, J_{DET} coincide con el costo de P0 de la sección 4.4.

5.5 Por qué se usaba una metaheurística

Una *metaheurística* es un método de búsqueda general que sólo necesita poder *evaluar* el costo, sin derivadas ni fórmulas. Era la opción natural por cuatro razones:

1. **Caja negra sin derivadas.** Evaluar J_{DET} exige simular el árbol en Simulink, con funciones S compiladas, y no hay gradientes disponibles.
2. **Costo discontinuo.** El número de nodos y sus instantes de ramificación cambian con u. J_{DET} es continuo sólo por tramos, y un método de gradiente podría fallar en los saltos.
3. **Ruido.** El remuestreo de tasas y el MC-dropout hacen que dos evaluaciones del mismo u puedan diferir.
4. **Paralelismo.** Los candidatos se evalúan de forma independiente (`parfor`).

Luus–Jaakola (LJ). Es una búsqueda aleatoria con región de búsqueda que se contrae [25]:

Algoritmo LJ (`luus_jaakola_det.m`; configuración: $R = 24$ candidatos por iteración, $M = 5$ iteraciones por pasada, $\gamma = 0.9$).

1. Partir de un candidato u^{mejor} y de un radio inicial r_0 por variable.
2. En cada pasada $p = 1, 2, \ldots$:
   a) fijar el radio: $r = \mathrm{mín}\left(|u^{\mathsf{mejor}} - u^{\mathsf{mejor}}_{\mathsf{anterior}}|,\ r_0\gamma^{p-1}\right)$, es decir, seguir el movimiento del óptimo, pero con un techo que decrece geométricamente;
   b) repetir M veces: sortear R candidatos $u = u^{\mathsf{mejor}} + r \odot \xi$, con ξ uniforme en $[-1, 1]^{26}$, recortados a las cotas; evaluar J_{DET} de cada uno, en paralelo y con una simulación del árbol por candidato; si el mejor mejora, reemplazar u^{mejor}, y si no, contraer el radio, $r \leftarrow \gamma\, r$.
3. Detenerse cuando 5 pasadas seguidas mejoran el costo menos del 0.1 %.

Cada iteración cuesta $R = 24$ simulaciones y cada pasada, $M \times R = 120$. En la consulta de 1180 s, la búsqueda se detuvo tras 6 pasadas: $1 + 6 \times 120 = 721$ evaluaciones, unos 800 s.

Algoritmo genético (GA). Imita la selección natural [26]:

Algoritmo GA (`ga_det.m`; población 20, 20 generaciones).

1. Crear 20 secuencias de corriente perturbando al azar el candidato inicial, y evaluar su costo.
2. En cada generación, crear 20 hijos:
   a) elegir dos padres por *ruleta*, con probabilidad proporcional a $1/(1+J)$;
   b) con probabilidad 0.8, cruzarlos: cada uno de los 26 genes viene de uno u otro padre al azar;
   c) mutar cada gen con probabilidad 0.3, reemplazándolo por un valor uniforme entre las cotas;
   d) conservar sin cambios al mejor individuo (elitismo) y evaluar la nueva población.
3. Devolver el mejor individuo encontrado.

Cada consulta exige $20 + 20 \times 20 = 420$ evaluaciones, unos 615 s.

Los dos métodos son robustos y fáciles de paralelizar, pero no garantizan encontrar el óptimo. Su resultado cambia con la semilla aleatoria, y cuestan cientos de simulaciones por consulta.

5.6 La métrica de riesgo

El riesgo se resume con dos márgenes:

- el **margen determinista** de cada muestra, $\mathrm{DSM}_j = (\hat{y}_j - y_{\mathrm{ref}})/(U_y - y_{\mathrm{ref}})$, que es la fracción del margen disponible ya consumida;
- el **margen probabilístico de seguridad**,

$$\mathrm{PSM} = \frac{U_y - q_{0.95}\big(\max_k \hat{y}_k\big)}{U_y - y_{\mathrm{nom}}},$$

donde $q_{0.95}$ es el cuantil 95 % de la PCT máxima sobre las ramas del árbol. Un PSM cercano a 1 indica mucho margen; uno negativo, que el 5 % peor de los casos supera el límite.

Muestreo por importancia. Las fallas del ACS son poco probables. Si se simularan con sus tasas reales, casi todas las ramas serían "sin falla" y el cuantil de la cola quedaría mal estimado. El *muestreo por importancia* sortea las tasas de una distribución de propuesta q, que exagera las fallas, y corrige con pesos [35]:

$$\mathbb{E}_p[g] = \mathbb{E}_q\Big[g\,\frac{p}{q}\Big] \approx \frac{\sum_i w_i\, g(\omega_i)}{\sum_i w_i}, \qquad w_i = \frac{p(\omega_i)}{q(\omega_i)},$$

donde p es la distribución real y ω_i cada camino del árbol. En el proyecto, $w = \prod p_{\mathrm{objetivo}} / \prod q_{\mathrm{muestra}}$ a lo largo de cada camino. Esto es IS-MCDET. El PSM se calcula en el *posprocesamiento*, con los árboles de las 61 consultas, y no interviene en la decisión.

5.7 Brechas del método actual

Brecha	Evidencia	Consecuencia
El costo no es una esperanza	J_{DET} suma las muestras de todos los nodos sin su probabilidad	Candidatos con distinto árbol se comparan sobre bases distintas
El riesgo llega tarde	El PSM se calcula en el posprocesamiento	El riesgo no influye en la acción
Horizonte corto	En 12.5 s el árbol casi siempre queda en la raíz	La falla del ACS es invisible para el optimizador
Margen de una trayectoria	La penalización usa el DSM, no la probabilidad	No mide probabilidad ni severidad de exceder U_y
Optimizador lento y aleatorio	721 simulaciones por consulta; acción según la semilla	~ 800 s por consulta y sin garantía de optimalidad

Cuadro 7: Brechas identificadas en el método actual (detalle en `docs/implementation_route.md`).

5.8 Qué cambia este trabajo

La observación clave es la tercera brecha. En las consultas estudiadas, ninguna transición del ACS cae dentro del horizonte de 12.5 s, así que el árbol se reduce a la raíz. Entonces J_{DET} es una función *determinista y suave* de u a través del ROM, y los motivos para usar una metaheurística desaparecen. Este documento:

1. escribe el ROM como ecuaciones algebraicas derivables (sección 2);
2. formula P0 de forma monolítica y con derivadas exactas, en varias versiones (sección 9);
3. certifica la calidad de las soluciones y compara todos los métodos con la misma vara (secciones 13 y 14);
4. reintroduce el riesgo como capas estructuradas sobre ese problema tratable: primero el pronóstico de fuga (sección 15) y después, como trabajo pendiente, las fallas del ACS.

Para recordar. El método actual evalúa cada candidato simulando un árbol de eventos en Simulink y busca el mejor con una metaheurística. Eso es razonable cuando el costo es una caja negra discontinua y ruidosa. En el horizonte del MPC, sin embargo, el árbol se reduce a la raíz y el costo es una función suave: se puede optimizar con derivadas.

Parte III
Las herramientas

6 Fundamentos de optimización

Esta sección reúne los conceptos de optimización que usa el resto del documento, desde lo más básico. Las referencias generales son Nocedal y Wright [13], para la optimización no lineal, y Boyd y Vandenberghe [14], para la optimización convexa.

6.1 Qué es un problema de optimización

Un problema de optimización tiene tres ingredientes:

- **variables de decisión** $z \in \mathbb{R}^n$: lo que se elige (aquí, los 26 caudales del ACS, y a veces también los estados);
- **función objetivo** o costo $\phi(z)$: lo que se quiere hacer pequeño;
- **restricciones**: igualdades $c(z) = 0$ y desigualdades $g(z) \leq 0$ que definen el *conjunto factible* $\mathcal{F} = \{z : \ c(z) = 0,\ g(z) \leq 0\}$.

Se escribe $\min_{z \in \mathcal{F}} \phi(z)$. Un problema es *lineal* si el costo y las restricciones son lineales; *cuadrático* (QP) si el costo es cuadrático y las restricciones lineales; y *no lineal* (NLP) en el caso general.

6.2 Mínimo local, mínimo global y convexidad

Definición 1 (Mínimos local y global)**.** $z^\star \in \mathcal{F}$ es un *mínimo global* si $\phi(z^\star) \leq \phi(z)$ para todo $z \in \mathcal{F}$. Es un *mínimo local* si la desigualdad se cumple sólo para los z factibles de algún entorno de $z^\star$.

Los métodos numéricos con derivadas son *locales*: miran el costo cerca del punto actual y bajan. Encuentran un mínimo local, pero no saben si hay otro mejor más lejos (figura 11). La propiedad que elimina esa incertidumbre es la convexidad.

Definición 2 (Convexidad)**.** Un conjunto $\mathcal{F}$ es convexo si el segmento entre dos de sus puntos está contenido en él. Una función ϕ es convexa si $\phi(\theta z + (1-\theta)w) \leq \theta\phi(z) + (1-\theta)\phi(w)$ para todo $\theta \in [0,1]$: su gráfico queda por debajo de cualquier cuerda. Si ϕ es dos veces diferenciable, es convexa si y sólo si su hessiana $\nabla^2\phi$ es semidefinida positiva en todo punto.

Proposición 3 (En un problema convexo, todo mínimo local es global)**.** *Si $\mathcal{F}$ y ϕ son convexos, todo mínimo local de ϕ en $\mathcal{F}$ es global.*

Demostración. Sea $z^\star$ un mínimo local y supóngase que existe $w \in \mathcal{F}$ con $\phi(w) < \phi(z^\star)$. Para $\theta \in (0,1)$, el punto $z_\theta = (1-\theta)z^\star + \theta w$ es factible por convexidad de $\mathcal{F}$, y $\phi(z_\theta) \leq (1-\theta)\phi(z^\star) + \theta\phi(w) < \phi(z^\star)$. Como $z_\theta \to z^\star$ cuando $\theta \to 0$, hay puntos arbitrariamente cerca de $z^\star$ con menor costo, lo que contradice que sea un mínimo local. □

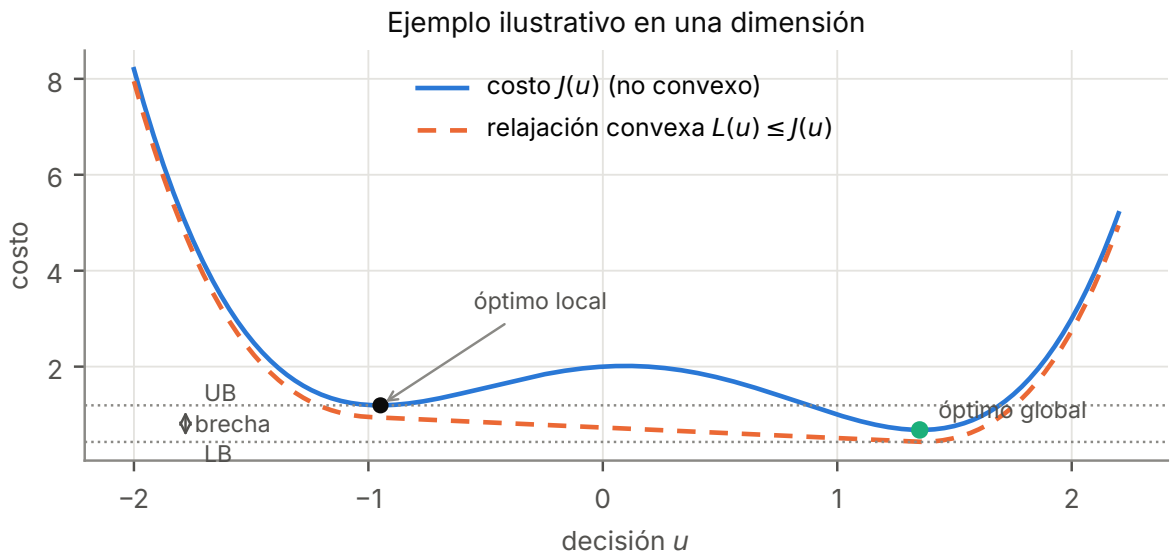


Figura 11: Ejemplo ilustrativo en una dimensión. El costo J (azul) no es convexo y tiene dos mínimos. Un método local que arranque a la izquierda se detiene en el mínimo local, cuyo costo es una cota superior (UB) del óptimo. Una función convexa $L \le J$ (naranja) tiene un único mínimo, que es una cota inferior (LB). El óptimo global está atrapado entre UB y LB; la diferencia es la *brecha de optimalidad* (sección 10).

6.3 Condiciones de optimalidad

En una variable sin restricciones. En un mínimo interior, la derivada se anula, $\phi'(z^\star) = 0$: es la condición necesaria de *primer orden*. Pero también se anula en máximos y en puntos de inflexión. Si además $\phi''(z^\star) > 0$, la función es localmente una parábola hacia arriba y $z^\star$ es un mínimo local estricto: es la condición suficiente de *segundo orden*.

Con cotas. Si z debe estar en $[\ell, \upsilon]$ y el mínimo está en la cota superior $z^\star = \upsilon$, la derivada no tiene por qué anularse: basta que sea negativa, porque el costo bajaría si se pudiera seguir subiendo z, y la cota lo impide. Ese valor $\mu = -\phi'(\upsilon) \ge 0$ es el *multiplicador* de la cota: mide cuánto bajaría el costo si la cota se aflojara un poco. Ésta es la situación del ACS en 1161 s, donde el caudal óptimo es el máximo permitido.

El caso general: condiciones KKT. Para $\min\{\phi(z) : c(z) = 0,\ g(z) \le 0\}$, en todo mínimo local regular existen multiplicadores λ y μ que cumplen las condiciones de Karush–Kuhn–Tucker [13]:

$$\nabla\phi + \nabla c^\top \lambda + \nabla g^\top \mu = 0, \quad c = 0, \quad g \le 0, \quad \mu \ge 0, \quad \mu_i g_i = 0.$$

La primera ecuación es el equilibrio de fuerzas: el gradiente del costo se compensa con los gradientes de las restricciones, ponderados por sus multiplicadores. La última, la *complementariedad*, dice que una desigualdad inactiva ($g_i < 0$) tiene multiplicador nulo. Las KKT son necesarias, pero no suficientes, y por eso hace falta una condición de segundo orden.

Proposición 4 (Condición suficiente de mínimo local con cotas de caja)**.** *Sea J dos veces diferenciable y $u^\star \in [\ell, \upsilon]$. Supóngase que (i) $\partial J/\partial u_k = 0$ en las componentes libres ($\ell_k < u_k^\star < \upsilon_k$); (ii) $\partial J/\partial u_k < 0$ si $u_k^\star = \upsilon_k$ y $\partial J/\partial u_k > 0$ si $u_k^\star = \ell_k$ (complementariedad estricta); (iii) la hessiana restringida a las componentes libres es definida positiva. Entonces $u^\star$ es un mínimo local estricto.*

Demostración. Sea $u = u^\star + v$ factible y pequeño. Las componentes activas sólo pueden moverse hacia el interior, y por (ii) el término lineal $\nabla J^\top v$ es estrictamente positivo si alguna de ellas se mueve, y domina al término cuadrático para v pequeño. Si sólo se mueven las libres, el término lineal es nulo por (i), y por (iii) $J(u) - J(u^\star) = \frac{1}{2} v^\top \nabla^2 J\, v + o(\|v\|^2) > 0$. □

6.4 Métodos con derivadas: Newton y punto interior

El método de Newton. Para resolver $\nabla\phi(z) = 0$, Newton aproxima ϕ por su expansión de Taylor de segundo orden en el punto actual y salta al mínimo de esa parábola:

$$z^{(i+1)} = z^{(i)} - \left[\nabla^2\phi(z^{(i)})\right]^{-1} \nabla\phi(z^{(i)}).$$

Cerca de un mínimo con hessiana definida positiva, el error se eleva al cuadrado en cada iteración (convergencia *cuadrática*): si una iteración tiene un error de 10^{-3}, la siguiente tiene uno del orden de 10^{-6}. Por eso unas pocas iteraciones bastan. El precio es que hacen falta primeras y segundas derivadas.

Método de punto interior. Las desigualdades complican Newton, porque no se sabe de antemano cuáles estarán activas. Los métodos de punto interior las reemplazan por una *barrera logarítmica* [13]:

$$\min_z \ \phi(z) - \mu_b \sum_i \ln\big(-g_i(z)\big), \qquad \mu_b \to 0.$$

La barrera vale infinito en el borde del conjunto factible y mantiene los iterados en su interior. Para cada μ_b se resuelve el problema con pasos de Newton, y μ_b se reduce hacia cero. En una variable con la cota $z \le v$, por ejemplo, el término $-\mu_b \ln(v - z)$ empuja a z lejos de v, con una fuerza que se debilita a medida que $\mu_b \to 0$, hasta que el iterado puede apoyarse en la cota. **Ipopt**, el solver que usa este trabajo para los problemas no lineales, es un método de punto interior primal-dual con búsqueda lineal de filtro [19]. Para problemas no convexos garantiza un mínimo local, no global.

6.5 Cómo se obtienen las derivadas: diferenciación automática

Hay tres maneras de obtener derivadas:

1. **Diferencias finitas**: $\phi'(z) \approx (\phi(z+\varepsilon) - \phi(z-\varepsilon))/(2\varepsilon)$. Es simple, pero tiene un compromiso. Con ε grande hay error de truncamiento; con ε pequeño, error de redondeo. Además, cada derivada parcial cuesta dos evaluaciones.
2. **Derivación simbólica**: derivar las fórmulas a mano o con un programa de álgebra. Es exacta, pero las expresiones crecen sin control en un modelo de 17 ecuaciones.
3. **Diferenciación automática** (AD) [24]: el programa que evalúa ϕ se ejecuta con un tipo de número extendido que lleva, junto a cada valor, su derivada. Aplicando la regla de la cadena operación por operación, el resultado es exacto hasta el redondeo.

Ejemplo 4 (Números duales)**.** Un número dual es $a + b\,\epsilon$ con $\epsilon^2 = 0$. Si se evalúa una función en $z + \epsilon$, el coeficiente de ϵ es su derivada: $f(z+\epsilon) = f(z) + f'(z)\,\epsilon$. Por ejemplo, para $f(z) = z^2 \sin z$ en $z = 2$:

$$(2+\epsilon)^2 = 4 + 4\epsilon, \qquad \sin(2+\epsilon) = \sin 2 + \cos 2\,\epsilon,$$

$$(4+4\epsilon)(\sin 2 + \cos 2\,\epsilon) = 4\sin 2 + (4\sin 2 + 4\cos 2)\,\epsilon,$$

y en efecto $f'(2) = 2 \cdot 2 \sin 2 + 2^2 \cos 2 = 4\sin 2 + 4\cos 2$. Ninguna fórmula de la derivada se escribió: salió de propagar ϵ por las operaciones.

Esto es la *diferenciación automática en modo directo*, que implementa ForwardDiff [23] en Julia [22]. Con un dual por variable de entrada se obtiene el gradiente o el jacobiano completo. Anidando duales dentro de duales se obtienen segundas derivadas. JuMP [21], el lenguaje de modelado que se usa para escribir los problemas, calcula internamente el gradiente y la hessiana exactos de la función lagrangiana para Ipopt.

6.6 Métodos sin derivadas

Cuando la función es una caja negra, o es discontinua, se usan métodos que sólo la evalúan. Los cuatro que aparecen en este documento son:

- **Luus–Jaakola**: búsqueda aleatoria con región que se contrae [25] (sección 5);
- **algoritmo genético**: población que evoluciona por selección, cruce y mutación [26];
- **evolución diferencial** (DE): cada candidato se perturba con la diferencia entre otros dos de la población [27]. Se usa en este trabajo como "adversario", para buscar un óptimo mejor que el de Ipopt;
- **enjambre de partículas** (PSO), que usan Liu et al. para ajustar el controlador PI [28, 1].

	Con derivadas (Newton, punto interior)	Sin derivadas (LJ, GA, DE, PSO)
Qué necesita	Valor, gradiente y hessiana	Sólo el valor
Evaluaciones típicas	Decenas de iteraciones	Cientos a decenas de miles
Resultado	Mínimo local preciso, con certificado (KKT)	Buena solución aproximada, sin certificado
Reproducibilidad	Determinista	Depende de la semilla aleatoria
Funciona con discontinuidades	Mal	Bien
Escala con la dimensión	Bien (cientos o miles de variables)	Mal (la búsqueda se vuelve ciega)

Cuadro 8: Métodos con y sin derivadas.

Para recordar. Un método con derivadas encuentra un mínimo local de forma rápida, precisa y reproducible, pero necesita una función suave y sus derivadas, que la diferenciación automática obtiene de forma exacta. Un método sin derivadas sólo necesita evaluar la función, pero cuesta muchas más evaluaciones y no garantiza nada. Ninguno de los dos, por sí solo, garantiza el óptimo *global* de un problema no convexo.

7 Del modelo continuo al problema de optimización

El ROM es un sistema de ecuaciones diferenciales en tiempo continuo, y el optimizador trabaja con un número finito de variables. Esta sección explica cómo se pasa de uno a otro: primero se *discretiza* el tiempo, y luego se decide cómo entran esas ecuaciones discretas en el problema de optimización.

7.1 Integrar una ecuación diferencial: Euler explícito e implícito

Para $\dot{x} = f(x)$ con paso h, los dos esquemas más simples son:

$$\text{Euler explícito:}\quad x_k = x_{k-1} + h\, f(x_{k-1}), \qquad \text{Euler implícito:}\quad x_k = x_{k-1} + h\, f(x_k).$$

El explícito usa la pendiente del punto conocido y da x_k directamente. El implícito usa la pendiente del punto nuevo, así que x_k aparece a ambos lados y hay que resolver una ecuación, normalmente con Newton, en cada paso. La ventaja del implícito es la estabilidad.

Proposición 5 (Estabilidad en la ecuación de prueba). *Para $\dot{x} = \lambda x$ con $\lambda < 0$, cuya solución exacta decae, Euler explícito produce $x_k = (1 + h\lambda)^k x_0$, que decae sólo si $h < 2/|\lambda|$. Euler implícito produce $x_k = (1 - h\lambda)^{-k} x_0$, que decae para todo $h > 0$.*

Demostración. Explícito: $x_k = x_{k-1} + h\lambda x_{k-1} = (1 + h\lambda)x_{k-1}$, y $|1 + h\lambda| < 1$ si y sólo si $0 < h|\lambda| < 2$. Implícito: $x_k = x_{k-1} + h\lambda x_k$, así que $x_k = x_{k-1}/(1 - h\lambda)$, y como $1 - h\lambda = 1 + h|\lambda| > 1$, el factor es menor que uno para cualquier $h > 0$. □

Un esquema con esa propiedad para todo λ de parte real negativa se llama *A-estable* [18]. La figura 12 lo muestra en un ejemplo ilustrativo: con $h\lambda = 2.5$, Euler explícito oscila y explota, mientras que Euler implícito sigue la solución.

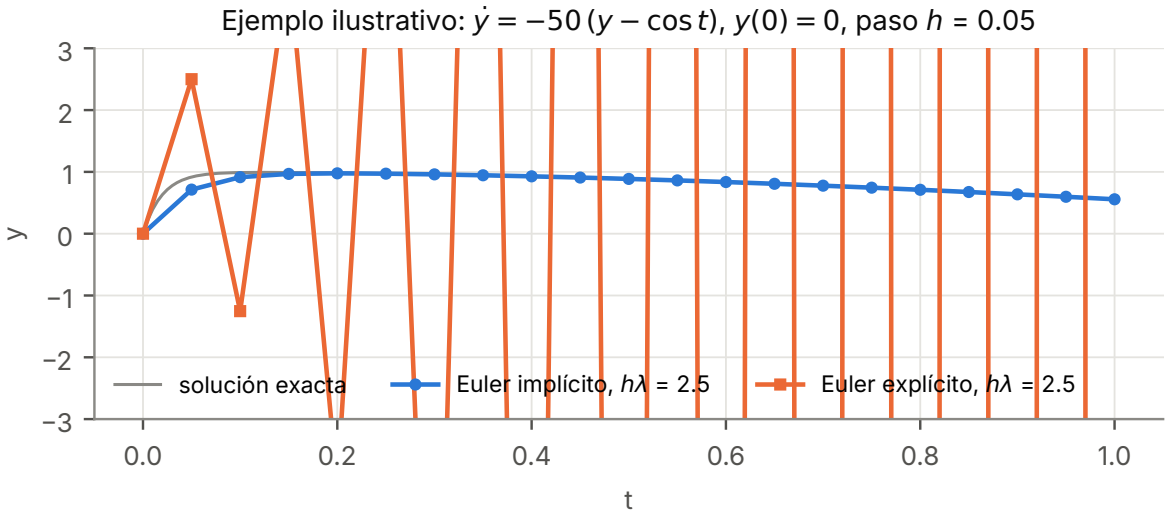


Figura 12: Ejemplo ilustrativo de rigidez: $\dot{y} = -50\,(y - \cos t)$, $y(0) = 0$, con paso $h = 0.05$. La solución se acerca a $\cos t$ en una escala de tiempo de $1/50$ s. Con $h\lambda = 2.5 > 2$, Euler explícito (naranja) es inestable; Euler implícito (azul) es estable con el mismo paso.

7.2 La rigidez del ROM

Un sistema es *rígido* cuando tiene modos con escalas de tiempo muy distintas. Para $\dot{x} = f(x)$, las escalas son los inversos de los valores propios del jacobiano $A = \partial f/\partial x$. La figura 13 muestra los 17 valores propios del ROM en las dos consultas:

- el modo más rápido, $\lambda \approx -1.7 \cdot 10^3$ s^{-1}, es la cinética neutrónica inmediata, con una escala de 0.6 ms;
- los de los precursores y las temperaturas van de -20 a -0.01 s^{-1};
- hay un valor propio *exactamente cero*: el inventario ΔM, que es un integrador puro de los caudales.

Con $\Delta t = 0.5$ s, Euler explícito sería inestable en los cinco modos con $|\lambda| > 2/\Delta t = 4$ s^{-1} (proposición 5). Para ser estable necesitaría un paso de $2/1700 \approx 1.2$ ms, unas 400 veces menor. Euler implícito permite el paso de 0.5 s del controlador, y por eso Simulink lo usa.

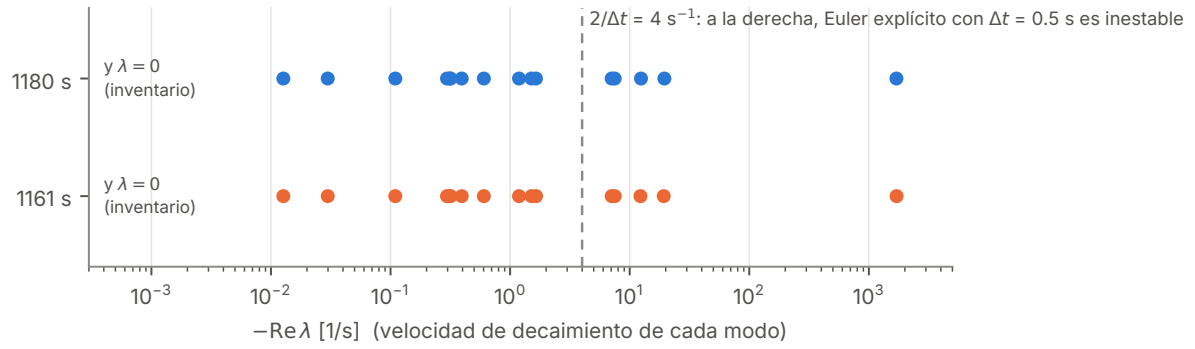


Figura 13: Valores propios del jacobiano del ROM en las dos consultas, en escala logarítmica de la tasa de decaimiento. Cubren cinco órdenes de magnitud: el sistema es rígido. La línea discontinua marca el límite de estabilidad de Euler explícito con el paso del controlador.

7.3 Euler implícito convergido y `ode1be`

Resolver exactamente la ecuación implícita en cada paso exige iterar Newton hasta la convergencia: es **Euler implícito convergido** (BE). Simulink, con el integrador `ode1be`, hace *una sola* iteración de Newton desde el punto anterior:

$$x_k = x_{k-1} + \big(I - \Delta t\, A(x_{k-1})\big)^{-1} \Delta t\, f(x_{k-1}, d_k, u_k).$$

Las dos versiones difieren poco: el error está en el transitorio inicial de cada simulación y no en el horizonte (sección 11). El problema monolítico usa BE, porque es una ecuación exacta que puede imponerse como restricción. La sección 13 comprueba que el óptimo no cambia al usar `ode1be`.

7.4 Cómo entra la dinámica en la optimización

Una vez discretizado, P0 tiene los caudales $u_1, \ldots, u_K$ como decisión y los estados $x_1, \ldots, x_K$ determinados por ellos. Hay dos maneras de plantearlo (figura 14) [16, 15]:

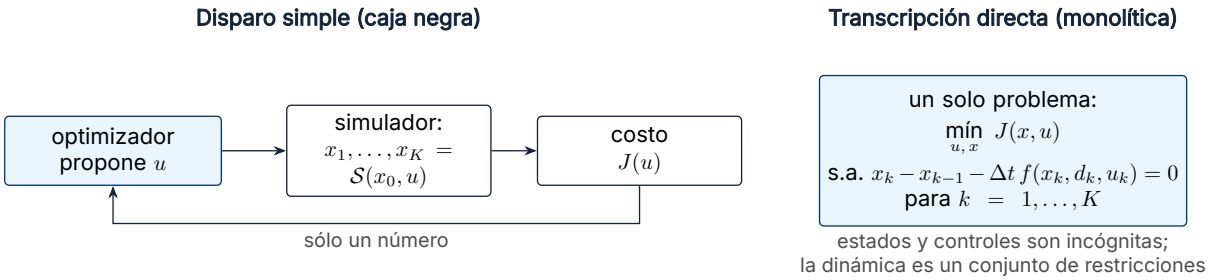


Figura 14: Dos formas de poner la dinámica en un problema de optimización. Izquierda: el optimizador sólo ve los controles, y cada evaluación del costo es una simulación completa. Derecha: estados y controles son variables del mismo problema, y las ecuaciones del modelo son restricciones.

Disparo simple. Las únicas variables son los controles. Para evaluar el costo se simula todo el horizonte. Es lo que hacen LJ y GA, sin derivadas. También puede hacerse con derivadas, propagándolas a través de la simulación (*espacio reducido*). El problema tiene pocas variables, pero cada evaluación es costosa, y un error al inicio del horizonte se propaga a todo el resto.

Transcripción directa simultánea. Los estados también son variables, y la dinámica discretizada entra como restricciones de igualdad, llamadas *defectos*. El problema es más grande (aquí, 519 variables), pero tiene ventajas decisivas:

- cada restricción enlaza sólo dos instantes consecutivos, así que las matrices son *dispersas* y se factorizan en tiempo casi lineal en K;
- las derivadas de cada restricción son locales y se obtienen con exactitud;
- el optimizador no necesita que la trayectoria sea factible en cada iteración, lo que ayuda con dinámicas rígidas o inestables.

Una variante intermedia, el *disparo múltiple*, divide el horizonte en tramos simulados y une sus extremos con restricciones [17]. En este documento se llama **formulación monolítica** a la transcripción directa: el simulador y el optimizador quedan fusionados en un solo problema.

7.5 Escalado

Las variables del ROM van de 10^3 (temperaturas) a 10^{16} (precursores). Si se usan tal cual, las matrices de Newton quedan mal condicionadas: sus elementos difieren en muchos órdenes de magnitud, y el redondeo destruye la precisión. Por eso cada estado se escribe como $x_j = S_j z_j$, con $S_j = \max(|x_{0,j}|, 1)$, y el optimizador trabaja con z, cuyas componentes son de orden uno.

Para recordar. El ROM es rígido, y por eso se integra con Euler implícito, que es estable con el paso de 0.5 s. La formulación monolítica no simula para evaluar el costo: escribe cada paso de Euler implícito como una restricción, de modo que estados y controles se optimizan juntos, con derivadas exactas y matrices dispersas.

8 Linealización, sistemas lineales e incertidumbre

8.1 Linealizar: la expansión de Taylor de la dinámica

Cerca de un punto de operación $(\bar{x}, \bar{d}, \bar{u})$, la dinámica no lineal se reemplaza por su aproximación de primer orden:

$$f(x, d, u) \approx \bar{f} + A(x - \bar{x}) + B(u - \bar{u}) + E(d - \bar{d}), \qquad A = \tfrac{\partial f}{\partial x},\ B = \tfrac{\partial f}{\partial u},\ E = \tfrac{\partial f}{\partial d}.$$

Las matrices A (17×17), B y E (17×1) son jacobianos, y aquí se calculan con diferenciación automática a partir de la misma función del ROM. En el ROM, $B = e_{\Delta M}$: el caudal del ACS sólo aparece en la ecuación del inventario. El error de la aproximación es de segundo orden en la distancia al punto: es pequeño mientras la trayectoria no se aleje mucho. Conviene escribir el modelo lineal en *desviaciones*, $\delta = x - \bar{x}$, para no restar números enormes, del orden de 10^{16}.

8.2 Sistemas lineales y función de transferencia

Si A, B y la salida $\hat{y} = C\delta + D\,\Delta u$ son constantes, el sistema es lineal e invariante en el tiempo (LTI). Su respuesta a una entrada sinusoidal de frecuencia ω se describe con la **función de transferencia**

$$G(s) = C(sI - A)^{-1}B + D, \qquad s = i\omega,$$

que da la ganancia $|G(i\omega)|$ y el desfase $\arg G(i\omega)$ entre la entrada y la salida. Es la herramienta clásica del análisis de reactores; por ejemplo, Zhang et al. construyen funciones

de transferencia de un reactor de agua a presión linealizando sus ecuaciones de conservación [4]. Para el SMDFR, la figura 15 muestra G desde el caudal del ACS hasta la PCT.

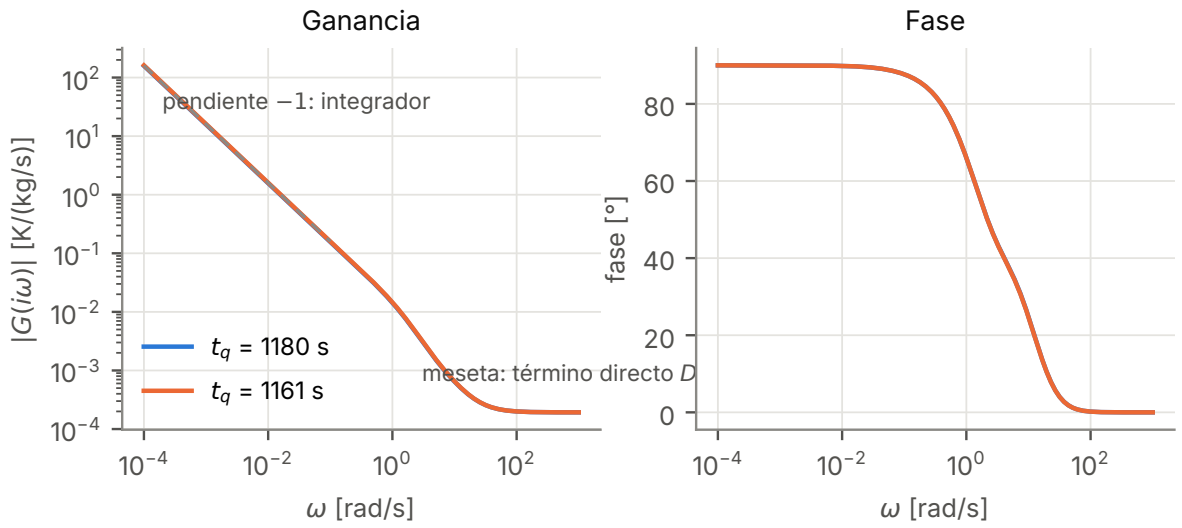


Figura 15: Respuesta en frecuencia del ROM linealizado, desde el caudal del ACS hasta la PCT. A bajas frecuencias la ganancia cae con pendiente -1 y la fase es de $+90°$: es la firma de un integrador. A altas frecuencias queda una meseta pequeña, el efecto directo del caudal sobre la corrección p_4. Las dos consultas son casi idénticas.

La lectura física es directa. El caudal del ACS no enfría por sí mismo: suma inventario, y el inventario es la integral del caudal. Con $\partial\hat{y}/\partial\Delta M \approx -1.6 \cdot 10^{-2}$ K/kg, resulta $G(s) \approx G_M/s$: inyectar 1 kg/s adicional durante t segundos baja la PCT unos $0.016\,t$ K. Es una regla útil para verificar órdenes de magnitud. La diferencia entre el caudal máximo y el mínimo del ACS es de 12.3 kg/s, que durante los 12.5 s del horizonte suman unos 150 kg y bajan la PCT unos 2.4 K. Es lo mismo que mide el modelo no lineal en la figura 7. Y de aquí sale la estrategia óptima: *acumular inventario lo antes posible*, porque el caudal inyectado al principio del horizonte sigue actuando durante todo el resto.

8.3 Programación cuadrática y dualidad

Con el modelo lineal, el costo cuadrático y las restricciones lineales, P0 se convierte en un **programa cuadrático** (QP). Si su hessiana es semidefinida positiva, el QP es convexo y, por la proposición 3, todo mínimo local es global. Los QP convexos se resuelven con métodos de punto interior especializados, como Clarabel [20], que además entregan un certificado.

Proposición 6 (Dualidad débil y certificado del QP)**.** *Para un QP convexo* $p^\star = \min\{\tfrac{1}{2}z^\top Pz + q^\top z : \; Az \le b,\; Fz = g\}$ *y su función dual* $g(\lambda,\nu) = \inf_z L(z,\lambda,\nu)$*, con* $L = \tfrac{1}{2}z^\top Pz + q^\top z + \lambda^\top(Az-b) + \nu^\top(Fz-g)$*, se cumple* $g(\lambda,\nu) \le p^\star$ *para todo* $\lambda \ge 0$*. Por lo tanto, si un par primal-dual factible tiene brecha* $p(z) - g(\lambda,\nu) \le \eta$*, la solución* z *es óptima con error a lo más* η*.*

Demostración. Para todo z factible y $\lambda \ge 0$ se tiene $L(z,\lambda,\nu) \le p(z)$, porque $\lambda^\top(Az-b) \le 0$ y $Fz - g = 0$. Minimizando en z, $g(\lambda,\nu) \le L(z,\lambda,\nu) \le p(z)$, y tomando el ínfimo sobre z factible, $g \le p^\star \le p(z)$ [14]. □

Este certificado vale para el *modelo lineal*: dice que el QP quedó bien resuelto, no que su decisión sea buena para el problema no lineal. Esa pregunta se responde en la sección 10.

8.4 Incertidumbre: de dónde viene y cómo se representa

El controlador decide sin conocer el futuro. Hay dos tipos de incertidumbre:

- **continua**: la fuga futura, que se pronostica con error, y el error del propio ROM frente a la planta;
- **discreta**: si el ACS fallará o no, y cuándo.

Las herramientas para incorporarla en la decisión, de menor a mayor costo, son tres.

Restricción probabilística. En lugar de exigir $\hat{y}_k \le U_y$, que no tiene sentido si $\hat{y}_k$ es aleatoria, se exige que la probabilidad de violarla sea pequeña, $\mathbb{P}(\hat{y}_k > U_y) \le \varepsilon$ [36].

Proposición 7 (Restricción probabilística gaussiana)**.** *Si $\hat{y}_k = \bar{y}_k(u) + c_k^\top w$ con $w \sim \mathcal{N}(0, \Sigma)$, entonces $\mathbb{P}(\hat{y}_k > U_y) \le \varepsilon$ si y sólo si $\bar{y}_k(u) + z_{1-\varepsilon}\sigma_k \le U_y$, con $\sigma_k^2 = c_k^\top \Sigma c_k$ y $z_{1-\varepsilon}$ el cuantil de la normal estándar.*

Demostración. $\hat{y}_k \sim \mathcal{N}(\bar{y}_k, \sigma_k^2)$, así que $\mathbb{P}(\hat{y}_k > U_y) = 1 - \Phi\big((U_y - \bar{y}_k)/\sigma_k\big) \le \varepsilon$ equivale a $(U_y - \bar{y}_k)/\sigma_k \ge z_{1-\varepsilon}$. □

Con el modelo lineal, la fuga entra de forma aditiva y σ_k no depende de u: la restricción probabilística es una restricción lineal más ajustada, y el QP sigue siendo un QP. Con $\varepsilon = 0.05$, por ejemplo, se exige $\bar{y}_k + 1.645\sigma_k \le U_y$.

Aproximación por promedio muestral (SAA). Si la distribución no es gaussiana o el modelo no es lineal, se reemplaza la esperanza por el promedio sobre M escenarios muestreados $\hat{d}^{(1)}, \dots, \hat{d}^{(M)}$ [37]:

$$\min_u \ \mathbb{E}\big[J(u;\hat{d})\big] \approx \min_u \ \frac{1}{M}\sum_{j=1}^{M} J(u;\hat{d}^{(j)}).$$

Al crecer M, el valor y las soluciones convergen a los del problema verdadero. Con M finito, el óptimo dentro de la muestra es optimista: está sesgado hacia abajo. Por eso las decisiones se evalúan *fuera de muestra*, con escenarios que no se usaron para optimizar.

Dos etapas y no anticipación. En el MPC sólo se aplica la primera acción, y las siguientes se re-optimizarán con información nueva. La versión de *dos etapas* del SAA refleja eso: la primera acción u_1 es común a todos los escenarios, porque se decide antes de saber cuál ocurrirá (*no anticipación*), y las siguientes pueden adaptarse a cada escenario (*recurso*).

El escenario óptimo. Homem-de-Mello et al. demostraron que, en una clase de programas estocásticos de dos etapas con recurso fijo y segunda etapa lineal, existe un *único escenario* cuyo problema determinista reproduce la decisión estocástica [38]. Ese escenario no tiene por qué ser único ni pertenecer al soporte de la distribución. El ejemplo clásico es el del vendedor de diarios (*newsvendor*), que debe decidir cuántos diarios comprar sin conocer la demanda. La compra óptima es un *cuantil* de la demanda, así que basta resolver el problema determinista con ese cuantil como demanda. Si un resultado así valiera para el MPC, el riesgo de pronóstico podría tratarse resolviendo el problema con un pronóstico bien elegido, sin multiplicar los escenarios. Para eso el problema debe ser lineal, y ésa es otra razón para disponer de una versión lineal de P0.

Para recordar. Linealizar convierte P0 en un QP convexo, con óptimo global, certificado dual y una función de transferencia que explica la física: el ACS actúa a través de un integrador. La incertidumbre se incorpora con restricciones probabilísticas, que siguen siendo lineales si el modelo es lineal, o con escenarios (SAA), en cuyo caso el tamaño del problema crece con su número.

9 Formulaciones propuestas

Todas las formulaciones de esta sección atacan el mismo problema: P0 determinista, con el árbol reducido a la raíz, el mismo costo y las mismas cotas del actuador. Difieren en tres cosas: qué son las incógnitas, cómo entra la dinámica y si el problema resultante es convexo. A ellas se suman tres formulaciones auxiliares, una para el riesgo y dos para la certificación. La tabla 9 las resume, y la figura 16 ilustra la diferencia entre los tres niveles del modelo.

Formulación	Incógnitas	Dinámica	¿Convexa?	Algoritmo	Para qué
P0-DET (actual)	26 corrientes	simulación del árbol en Simulink (caja negra)	no; discontinua	LJ, GA	referencia histórica
N3 monolítica	26 caudales, 442 estados, 51 holguras	Euler implícito convergido como igualdades	no	Ipopt, hessiana exacta	el problema exacto
N3 reducida	26 caudales	simulación derivable (BE o `ode1be`)	no	Ipopt, gradiente exacto	certificación; versión Simulink
N1 dispersa / condensada	519 / 77 variables	lineal, una sola linealización	sí (QP)	Clarabel	tiempo real, certificado dual
N2	77 por iteración	lineal por paso, re-linealizada	sí, en cada iteración	SQP + Clarabel	converge a N3
SAA de dos etapas	26 + 25 por escenario	N3 en cada escenario de fuga	no	Ipopt	riesgo de pronóstico (F4)
QP con restricción probabilística	como N1	lineal	sí	QP	capa 1 de riesgo (propuesta)
Relajación de cota inferior	26 caudales y holguras	modelo afín más cota del residuo	sí (QP)	Clarabel	cota inferior certificada (F3c)

Cuadro 9: Formulaciones del problema de control y para qué sirve cada una.

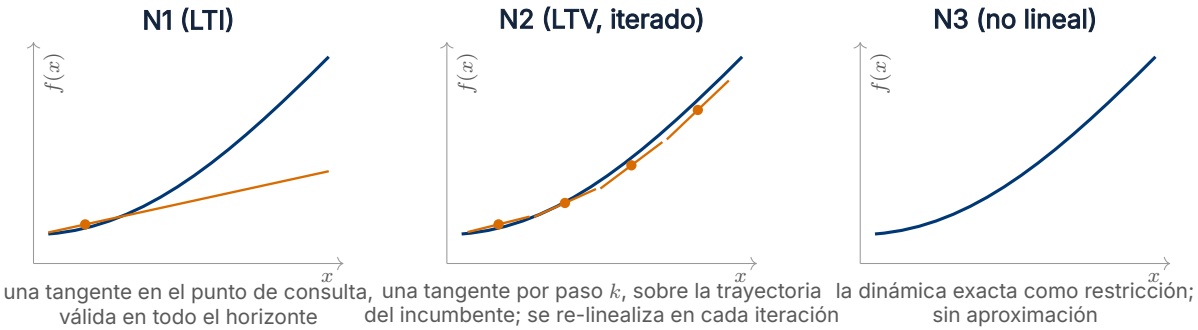


Figura 16: Los tres niveles del modelo. La curva azul es la dinámica no lineal y en naranja están sus aproximaciones lineales.

9.1 P0-DET: la formulación actual (disparo simple de caja negra)

Es el problema de la sección 5: las incógnitas son las 26 corrientes, y el costo $J_{\text{DET}}(u)$ se obtiene simulando el árbol de eventos en Simulink. No hay ecuaciones explícitas ni derivadas, y por eso se resuelve con búsqueda aleatoria (Luus–Jaakola) o evolutiva (GA). Cuando el árbol queda en la raíz, J_{DET} coincide con el costo determinista P0 de la sección 4.4, que es lo que resuelven las formulaciones siguientes.

9.2 N3 monolítica: el NLP exacto

Las incógnitas son los caudales u_k, los estados escalados z_k ($x_k = S \circ z_k$, con $S_j = \text{máx}(|x_{0,j}|, 1)$) y dos juegos de holguras. El problema es

$$
\begin{aligned}
\min_{u,\,z,\,s,\,r} \quad & \sum_{k=1}^{K} (\hat{y}_k - y_{\text{ref}})^2 + \lambda_m \sum_{k=1}^{K-1} s_k^2 + \lambda_{\text{pct}} \sum_{k=1}^{K} r_k^2 \\
\text{s.a.} \quad & S \circ (z_k - z_{k-1}) = \Delta t\, f\big(S \circ z_k, \hat{d}_k, u_k\big), \qquad z_0 = x_0 \oslash S, \qquad k = 1, \dots, K, \\
& \hat{y}_k = S_{T_w} z_{k,T_w} + p_4(\hat{d}_k + u_k + 5550) + 0.4, \\
& u_{k+1} - u_k \le \Delta\dot{m} + s_k, \qquad u_k - u_{k+1} \le \Delta\dot{m} + s_k, \qquad \hat{y}_k - U_y \le r_k, \qquad s, r \ge 0, \\
& \dot{m}_{\text{min}} \le u_k \le \dot{m}_{\text{max}}.
\end{aligned}
$$

Tiene 519 variables libres (442 de estado, 26 de control y 51 holguras) y 442 igualdades no lineales, con estructura bloque-bidiagonal. El escalado es imprescindible, porque $N \sim 10^{13}$ y $C_i \sim 10^{16}$ conviven con temperaturas de $\sim 10^3$ K. Se resuelve con Ipopt, usando la hessiana exacta del lagrangiano, que JuMP obtiene por diferenciación automática.

Proposición 8 (Las holguras reproducen las bisagras exactamente)**.** *En todo óptimo de N3, $s_k = \big[|u_{k+1} - u_k| - \Delta\dot{m}\big]_+$ y $r_k = [\hat{y}_k - U_y]_+$. Por lo tanto, N3 tiene el mismo óptimo que P0 con las bisagras originales, pero es dos veces diferenciable.*

Demostración. Fijados u y z, s_k sólo aparece en el costo $\lambda_m s_k^2$, que crece con $s_k \ge 0$, y en las restricciones $s_k \ge |u_{k+1} - u_k| - \Delta\dot{m}$. El menor s_k factible es $\text{máx}(0, |u_{k+1} - u_k| - \Delta\dot{m})$, y su costo es exactamente la bisagra al cuadrado. El argumento para r_k es el mismo. □

9.3 N3 reducida: el mismo problema sólo en los controles

Los estados se eliminan con la simulación, $x_k = \Phi(x_{k-1}, \hat{d}_k, u_k)$, y queda

$$
\min_{\dot{m}_{\text{min}} \le u \le \dot{m}_{\text{max}}} \; J(u) = \sum_k \big(\hat{y}_k(u) - y_{\text{ref}}\big)^2 + \lambda_m \sum_k \big[|u_{k+1} - u_k| - \Delta\dot{m}\big]_+^2 + \lambda_{\text{pct}} \sum_k \big[\hat{y}_k(u) - U_y\big]_+^2.
$$

Se usa con dos pasos de integración:

- **BE convergido**: Φ resuelve $x_k = x_{k-1} + \Delta t\, f(x_k, \hat{d}_k, u_k)$ hasta la convergencia de Newton. Es el mismo modelo que N3 monolítica.
- `ode1be`: una sola iteración de Newton desde x_{k-1},

  $$x_k = x_{k-1} + \big(I - \Delta t\, A(x_{k-1})\big)^{-1} \Delta t\, f(x_{k-1}, \hat{d}_k, u_k).$$

  Es exactamente lo que calcula Simulink.

Sólo tiene 26 variables, con cotas de caja. A cambio, cada evaluación exige una simulación. El gradiente se obtiene derivando a través de la simulación con ForwardDiff. Es la forma natural para la certificación de la sección 13, porque sus condiciones de optimalidad se escriben sólo en u.

9.4 N1: una sola linealización (QP-LTI)

Se linealiza una vez en $(\bar{x}, \bar{d}, \bar{u}) = (x_0,\ d(t_q - \Delta t),\ \text{caudal medio})$. El modelo se escribe en *desviaciones*, $\delta_k = x_k - \bar{x}_k$, $\Delta u_k = u_k - \bar{u}_k$ y $\Delta d_k = d_k - \bar{d}_k$, para no restar números del orden de 10^{16}. Con Euler implícito,

$$M_k\,\delta_k = \delta_{k-1} + r_k + \Delta t\,B\,\Delta u_k + \Delta t\,E_k\,\Delta d_k, \qquad M_k = I - \Delta t\,A_k, \qquad r_k = \bar{x}_{k-1} - \bar{x}_k + \Delta t\,\bar{f}_k,$$
$$\hat{y}_k = \bar{y}_k + \delta_k[T_w] + D_k\,(\Delta d_k + \Delta u_k),$$

con $A_k \equiv A$ y $\bar{x}_k \equiv \bar{x}$. Aquí $B = e_{\Delta M}$ es constante, porque el control sólo entra en el inventario, y $D_k = p_4'(\cdot)$. Hay dos formas equivalentes:

- **Dispersa (monolítica)**: las desviaciones $\delta_{1..K}$ son variables y las ecuaciones anteriores son restricciones lineales. Tiene 519 variables.
- **Condensada**: los estados se eliminan recursivamente, y la salida queda afín en el control, $\hat{y} = \hat{y}^0 + G\,u$, con

$$G_{kj} = e_{T_w}^{\top} M_k^{-1} M_{k-1}^{-1} \cdots M_j^{-1}\,\Delta t\,B \quad (j < k),$$
$$G_{kk} = e_{T_w}^{\top} M_k^{-1} \Delta t\,B + D_k, \qquad G_{kj} = 0 \quad (j > k).$$

  G es triangular inferior: u_j sólo afecta a $\hat{y}_k$ con $k \geq j$. El problema queda en 77 variables:

$$\min_{u,s,r}\ \|\hat{y}^0 + Gu - y_{\text{ref}}\mathbf{1}\|^2 + \lambda_m\|s\|^2 + \lambda_{\text{pct}}\|r\|^2,$$

  sujeto a las restricciones lineales de rampa, de límite de PCT y de cotas.

Es un QP convexo, y Clarabel lo resuelve con certificado dual (proposición 6).

9.5 N2: una linealización por paso, iterada (QP-LTV secuencial)

En N2 conviven dos índices: $k = 1, \ldots, 26$ es el paso del horizonte e $i = 1, 2, \ldots$ es la iteración. En la iteración i, los jacobianos del paso k se evalúan en el estado del *mismo* paso k de la trayectoria no lineal producida por el control incumbente de la iteración anterior:

$$A_k^{(i)} = \frac{\partial f}{\partial x}\Big(\bar{x}_k^{(i-1)}, d_k, u_k^{(i-1)}\Big), \qquad \bar{x}^{(i-1)} = \mathcal{S}\big(x_0, u^{(i-1)}, d\big),$$

donde $\mathcal{S}$ es la simulación no lineal. Los 26 jacobianos se calculan juntos, *antes* de resolver el QP, que tiene la misma forma condensada que N1 pero con matrices $M_k^{(i)}$ distintas en cada paso (figura 17).

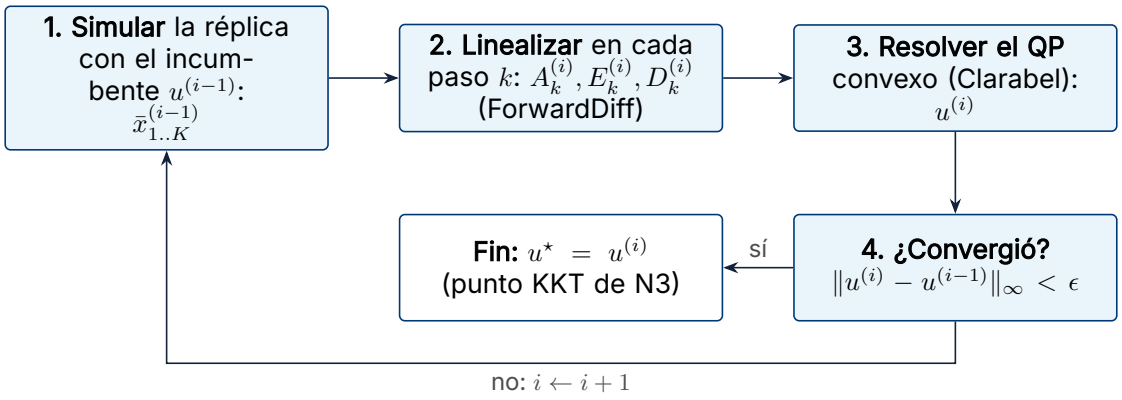


Figura 17: Iteración de N2: programación cuadrática secuencial. El modelo exacto sólo se usa para simular y derivar; la optimización se hace siempre sobre un QP convexo.

Proposición 9 (El punto fijo de N2 es un punto KKT de N3)**.** *Si la iteración converge a u^∞ y la trayectoria nominal es la solución exacta de Euler implícito ($r_k = 0$), entonces u^∞ cumple las condiciones KKT de N3 reducida.*

Demostración. En el punto fijo, la trayectoria nominal es la del propio u^∞. El modelo lineal reproduce entonces el valor exacto $\hat{y}(u^\infty)$ y, por construcción, su jacobiano respecto de u. Como el costo y las restricciones dependen de u sólo a través de $\hat{y}(u)$ y de restricciones lineales, las KKT del QP en u^∞ coinciden con las de N3 reducida. □

9.6 Formulaciones auxiliares

SAA de dos etapas (riesgo de pronóstico, F4). Con M trayectorias de fuga $\hat{d}^{(j)}$ del ensamble MC-dropout, la primera acción es común a todos los escenarios y las siguientes se adaptan a cada uno:

$$\min_{u_1,\, u_{2..K}^{(j)}} \ \frac{1}{M}\sum_{j=1}^{M} J\big(u_1, u_{2..K}^{(j)}; \hat{d}^{(j)}\big),$$

con la dinámica de N3 en cada escenario. Con $M = 59$ son unas 30 000 variables, y aun así se resuelve en ~ 2 s.

QP con restricción probabilística (capa 1 de riesgo, propuesta). Sobre N1, la restricción $\mathbb{P}(\hat{y}_k > U_y) \le \varepsilon$ se reemplaza por la restricción lineal equivalente $\hat{y}_k^0 + (Gu)_k + z_{1-\varepsilon}\sigma_k \le U_y$ (proposición 7). El problema sigue siendo un QP.

Relajación convexa para la cota inferior (F3c). Para certificar N3 se resuelve el QP $\min_u L(u)$ de la proposición 12. Su valor óptimo es una cota inferior del óptimo global de N3.

10 ¿Cómo se demuestra que una solución es buena? Teoría de la certificación

Un método local entrega una solución y un certificado *local* (las condiciones KKT). En un problema no convexo eso no basta: puede haber otro mínimo mejor en otra parte. Esta sección presenta las herramientas para obtener una garantía *global*.

10.1 Cotas superior e inferior y brecha de optimalidad

Definición 3 (Brecha de optimalidad)**.** Para $J^\star = \min_{u\in\mathcal{U}} J(u)$:

- una *cota superior* es $UB = J(\tilde{u})$ para cualquier $\tilde{u} \in \mathcal{U}$: un control concreto cuyo costo se conoce;
- una *cota inferior* es un número LB *demostrado* tal que $J(u) \ge LB$ para todo $u \in \mathcal{U}$.

Entonces $LB \le J^\star \le UB$, y la *brecha* $(UB - LB)/UB$ acota cuánto podría mejorarse $\tilde{u}$.

Encontrar una cota superior es fácil: cualquier solución factible sirve. Lo difícil es la cota inferior, porque es una afirmación sobre *todos* los controles posibles, incluidos los que nunca se evaluaron.

Hay que distinguir dos brechas que suelen confundirse:

- la **brecha del solver** (residuos KKT, brecha dual de un QP) dice si un algoritmo resolvió bien *su propio* problema;

- la **brecha de optimalidad** dice qué tan buena es una decisión frente a la mejor posible en el problema que de verdad importa.

Sólo la segunda permite comparar métodos que resuelven modelos distintos.

Proposición 10 (Intervalo de exceso garantizado)**.** *Si $LB \le J^\star \le UB$ con $LB > 0$, el exceso relativo de cualquier decisión u sobre el óptimo global cumple*

$$\frac{J(u) - UB}{UB} \;\le\; \frac{J(u) - J^\star}{J^\star} \;\le\; \frac{J(u) - LB}{LB}.$$

Demostración. La función $s \mapsto (J(u) - s)/s = J(u)/s - 1$ es decreciente en $s > 0$. Basta evaluarla en $s = UB \ge J^\star$ y en $s = LB \le J^\star$. □

10.2 Relajaciones convexas

La idea general para obtener una cota inferior es construir una función $L \le J$ en todo el conjunto factible que sea fácil de minimizar globalmente, típicamente convexa. Su mínimo es entonces una cota inferior de $J^\star$ (figura 11). Las relajaciones clásicas reemplazan cada término no convexo por una envolvente convexa [39].

Ejemplo 5 (Envolvente de McCormick)**.** Para el término bilineal $w = xy$ con $x \in [x^L, x^U]$ e $y \in [y^L, y^U]$, desarrollando $(x - x^L)(y - y^L) \ge 0$ y $(x - x^U)(y - y^U) \ge 0$ se obtiene

$$w \ge x^L y + y^L x - x^L y^L, \qquad w \ge x^U y + y^U x - x^U y^U.$$

Son dos desigualdades lineales válidas en toda la caja. Cuanto más pequeña la caja, más ajustada la envolvente.

Esa última observación es la base de la **ramificación y acotamiento** (*branch and bound*) [40]: se divide la caja en subcajas, se calcula una cota inferior en cada una, se descartan las subcajas cuya cota supera la mejor solución conocida, y se subdividen las restantes hasta que la brecha es tan pequeña como se quiera. El costo es que, en muchas dimensiones, el número de subcajas puede crecer exponencialmente.

10.3 Aritmética de intervalos

Para construir cotas *demostradas* sobre funciones complicadas, como la salida de una simulación, se usa la aritmética de intervalos [41]. Un intervalo es $[a] = [\underline{a}, \overline{a}]$, y las operaciones se definen para que el resultado contenga todos los valores posibles:

$$[a] + [b] = [\underline{a} + \underline{b},\ \overline{a} + \overline{b}], \qquad [a] - [b] = [\underline{a} - \overline{b},\ \overline{a} - \underline{b}], \qquad [a] \cdot [b] = [\min P,\ \max P],$$

con $P = \{\underline{a}\underline{b},\ \underline{a}\overline{b},\ \overline{a}\underline{b},\ \overline{a}\overline{b}\}$.

Proposición 11 (Propiedad de inclusión)**.** *Si una función F se evalúa con aritmética de intervalos sobre $[x]$, el intervalo resultante contiene $\{F(x) : x \in [x]\}$.*

La demostración se hace operación por operación: cada operación contiene todos sus resultados posibles, y la composición conserva esa propiedad. Si además cada extremo se redondea *hacia afuera*, el redondeo de la computadora también queda cubierto, y el resultado es una cota *rigurosa*. El paquete `IntervalArithmetic.jl` [44] implementa todo esto en Julia.

Ejemplo 6 (El problema de dependencia)**.** Con $[x] = [1, 2]$, la expresión $x - x$ vale exactamente cero, pero la aritmética de intervalos da $[1, 2] - [1, 2] = [-1, 1]$: no sabe que los dos x son el mismo número. La cota es correcta, pero pesimista. En una simulación de 26 pasos y 17 estados, esa sobreestimación se acumula paso a paso y puede volver inútil la cota.

El remedio clásico es la **forma del valor medio**: en lugar de evaluar $F([x])$, se evalúa

$$F([x]) \subseteq F(\check{x}) + [F']([x])\,([x] - \check{x}),$$

con $\check{x}$ el centro del intervalo y $[F']$ la derivada evaluada con intervalos. Para $F(x) = x - x$, la derivada es cero y la forma da exactamente $[0, 0]$. Más en general, los **modelos de Taylor** representan cada cantidad como un polinomio con coeficientes numéricos, que conserva la correlación entre variables, más un *resto* encerrado en un intervalo [42]. Ésa es la estrategia del paso 4b (sección 13): la parte lineal de la respuesta del reactor se calcula exactamente, y sólo el resto no lineal se encierra con intervalos.

10.4 Verificar que una solución existe: punto fijo

Cuando una cantidad se define implícitamente, como el estado de un paso de Euler implícito, que aparece a ambos lados de su ecuación, hay que demostrar además que la solución existe dentro de la caja propuesta. La herramienta es el teorema de punto fijo de Brouwer: si una función continua lleva una caja dentro de sí misma, tiene un punto fijo en ella. El operador de Krawczyk [43] convierte esa idea en una prueba computable para sistemas de ecuaciones: si el operador, evaluado con intervalos sobre la caja, cae estrictamente dentro de ella, la caja contiene una solución y ésta es única.

Para recordar. Una garantía global requiere una cota inferior demostrada. Se obtiene con una relajación convexa del problema. Cuando el problema contiene una simulación, la relajación necesita acotar con rigor cuánto se aparta el modelo no lineal de una aproximación simple, y eso se hace con aritmética de intervalos y modelos de Taylor, verificando por punto fijo que las cajas propuestas contienen la solución.

Parte IV
Resultados

Esta parte presenta los resultados en el orden de las preguntas de la sección 1. Cada sección explica qué se hizo y cómo leer sus figuras, y termina con un recuadro que responde una pregunta. Todos los resultados se obtuvieron sobre las dos consultas de prueba (1161 y 1180 s), con las cotas archivadas del actuador, salvo cuando se indica otra cosa.

11 La réplica del ROM es exacta (F1)

Qué se hizo y por qué. Para optimizar con derivadas hace falta el modelo escrito como ecuaciones en un lenguaje que pueda derivarlas, y no como un diagrama de bloques en Simulink. F0 extrajo el ROM término a término desde los bloques del archivo de Simulink, y F1 lo programó en Julia (`julia/SMDFRROM.jl`). Antes de usar esa réplica hay que demostrar que calcula *lo mismo* que Simulink.

Cómo se validó. La validación reconstruye una consulta igual que el lazo: se inyecta el estado del HRM en $t_q - 10$ s, se simulan 10 s de calentamiento y luego los 26 pasos del horizonte, con las mismas entradas. Se compararon tres variantes del integrador:

Esquema de la réplica	Error máx. en el horizonte	Error máx. en toda la ventana
`ode1be` (una iteración de Newton), entradas en t_{n+1}	**$2.2 \cdot 10^{-6}$ K**	$1.1 \cdot 10^{-4}$ K
`ode1be`, entradas en t_n	$7.2 \cdot 10^{-2}$ K	$7.2 \cdot 10^{-2}$ K
Euler implícito convergido, entradas en t_{n+1}	$3.7 \cdot 10^{-4}$ K	0.88 K

Cuadro 10: Error de la réplica frente a Simulink en la consulta de 1180 s.

La tabla enseña dos cosas. Primero, los detalles numéricos importan: tomar las entradas al principio del paso en lugar de al final cambia el resultado en 0.07 K, casi cinco órdenes de magnitud más que el error de la versión correcta. Segundo, Euler implícito convergido se aparta de `ode1be` en el transitorio de calentamiento, donde el estado inyectado desde el HRM produce un salto rápido, pero no en el horizonte. Por eso el NLP parte del estado en $t_q - \Delta t$, ya pasado el calentamiento.

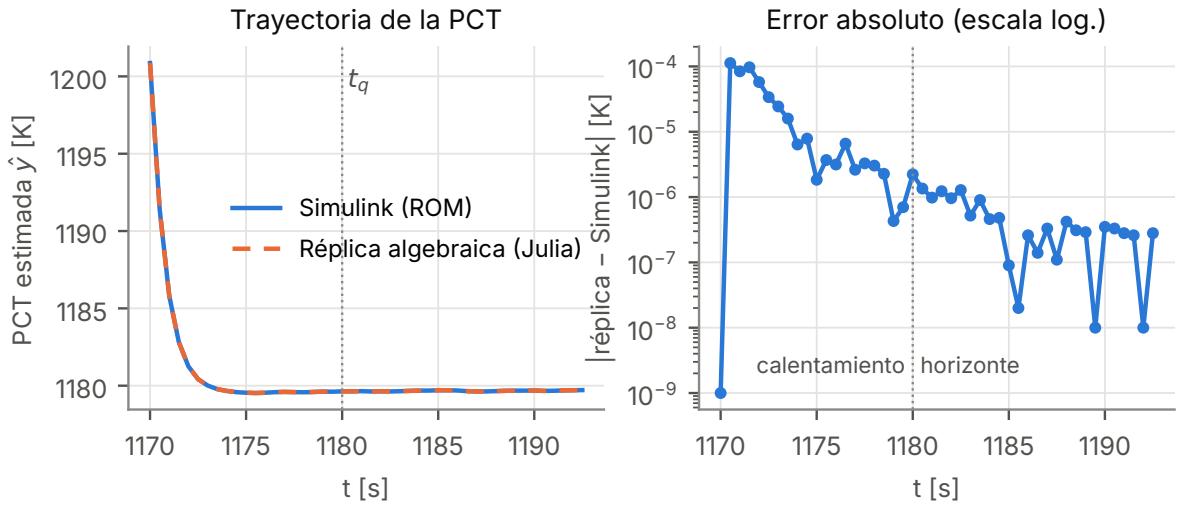


Figura 18: Consulta de 1180 s. Izquierda: PCT estimada por Simulink y por la réplica. Derecha: error absoluto. Con el mismo esquema que Simulink (`ode1be`, una iteración de Newton, entradas en t_{n+1}), el error es de $2 \cdot 10^{-6}$ K en el horizonte y de 10^{-4} K en el transitorio del calentamiento. En 1161 s es de $1.6 \cdot 10^{-6}$ K.

La réplica es un sustituto exacto de Simulink, con derivadas disponibles. Todo lo que sigue se apoya en ella.

12 El problema determinista se resuelve en tiempo real (F2, F3)

12.1 La solución del NLP

El NLP (N3) se resuelve en ~ 0.05 s. Las cuatro inicializaciones probadas (acción de LJ, cota inferior, cota superior y punto medio) llegan al mismo óptimo.

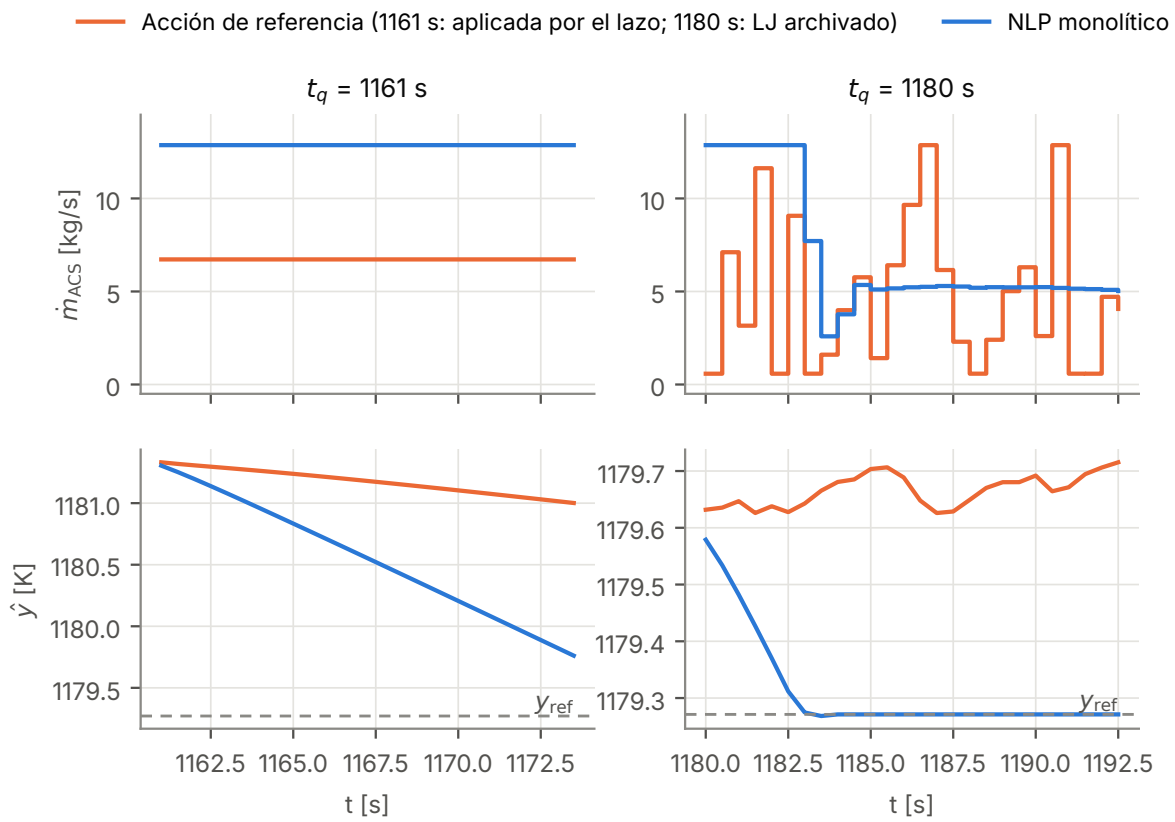


Figura 19: Acción (arriba) y PCT estimada (abajo) del NLP frente a la acción de referencia archivada. En 1180 s el NLP satura durante 3 s y luego sigue la referencia exactamente. En 1161 s el óptimo es la esquina $u = u_{\max}$ durante todo el horizonte, y aun así la PCT no alcanza la referencia: la cota del actuador limita el resultado.

Por qué "saturar y luego seguir". La función de transferencia del modelo lineal, de $\dot{m}_{ACS}$ a $\hat{y}$, es $G(s) \approx G_M/s$, con $\partial\hat{y}/\partial\Delta M = -1.6\cdot10^{-2}$ K/kg: el ACS actúa a través de un integrador puro, el inventario. Conviene acumular inventario lo antes posible. Con la cota archivada, la autoridad sobre el horizonte es de unos 150 kg, es decir, ≈ -2.4 K como máximo sobre la PCT.

12.2 N1 y N2 frente a N3

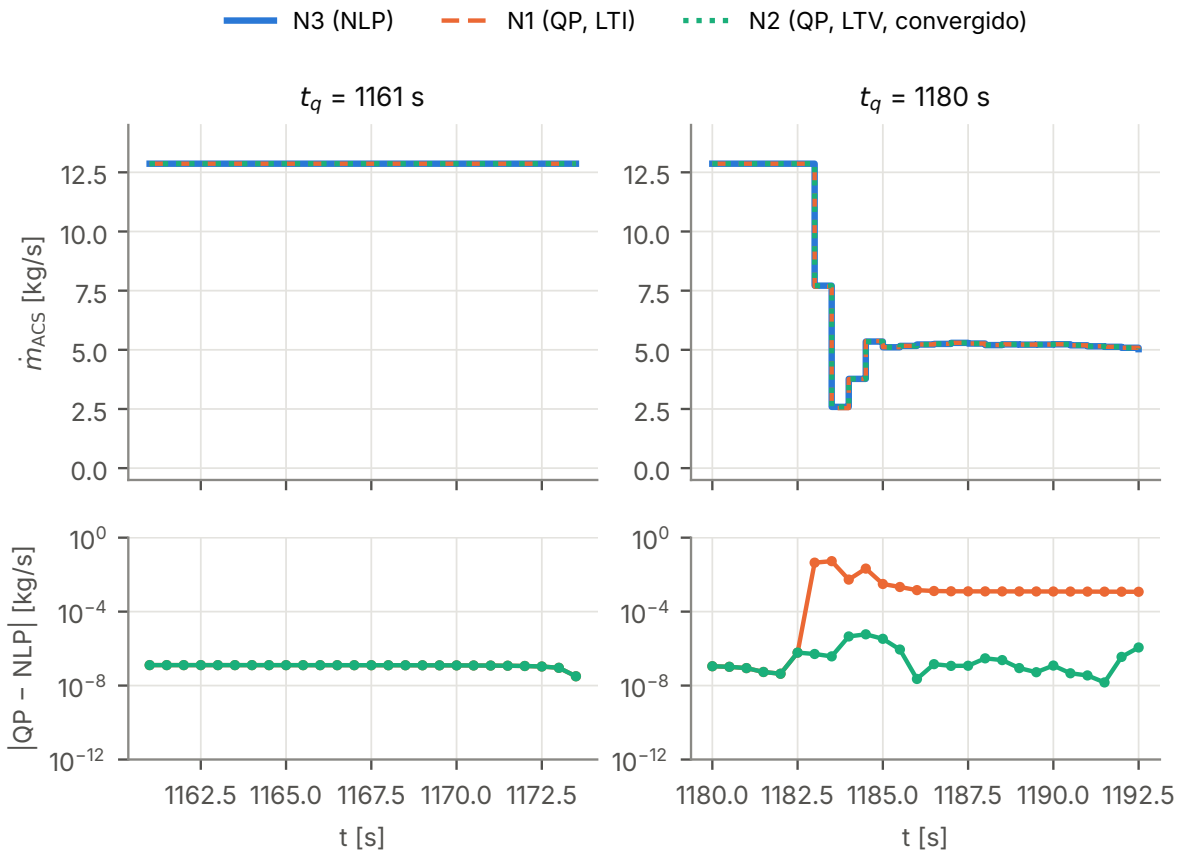


Figura 20: Arriba: acciones de N3 (NLP), N1 y N2 convergido. Abajo: diferencia con el NLP, en escala logarítmica. En 1161 s coinciden a 10^{-7} kg/s. En 1180 s, N1 se separa hasta 0.054 kg/s justo donde el óptimo deja de saturar, mientras que N2 converge al NLP a $6 \cdot 10^{-6}$ kg/s.

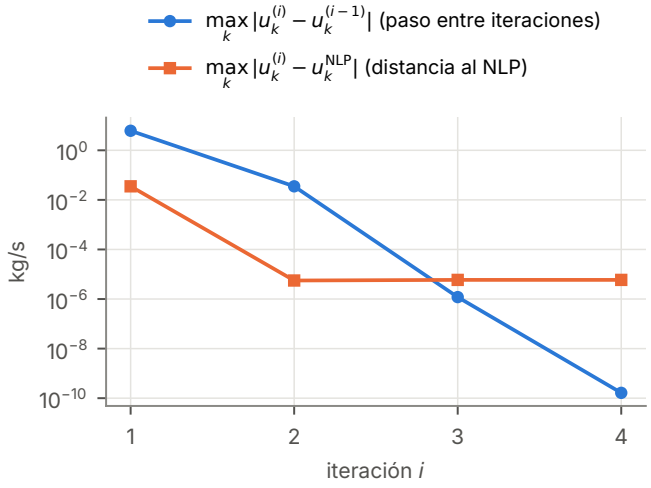


Figura 21: Convergencia de N2 en 1180 s. El paso entre iteraciones cae de forma superlineal (6.1, $3.5 \cdot 10^{-2}$, $1.2 \cdot 10^{-6}$, $1.6 \cdot 10^{-10}$ kg/s), y la distancia al NLP se estabiliza en $6 \cdot 10^{-6}$ kg/s, que es la tolerancia del propio NLP. En 1161 s converge en una iteración.

Modelo	Forma, solver	Var.	Tiempo [s]	Brecha dual	Máx. dif. con NLP [kg/s]
$t_q = 1180$ *s*					
N3	disperso, Ipopt	519	0.055	—	—
N1	disperso / condensado, Clarabel	519 / 77	0.037 / 0.010	$\sim 10^{-12}$	$5.4 \cdot 10^{-2}$
N2	condensado, Clarabel (por QP)	77	0.010	$< 10^{-11}$	$5.9 \cdot 10^{-6}$
$t_q = 1161$ *s*					
N3	disperso, Ipopt	519	0.048	—	—
N1, N2	condensado, Clarabel	77	0.009	$\sim 4 \cdot 10^{-11}$	$1.3 \cdot 10^{-7}$

Cuadro 11: Resolución de los QP. La brecha dual certifica que cada QP quedó resuelto (proposición 6).

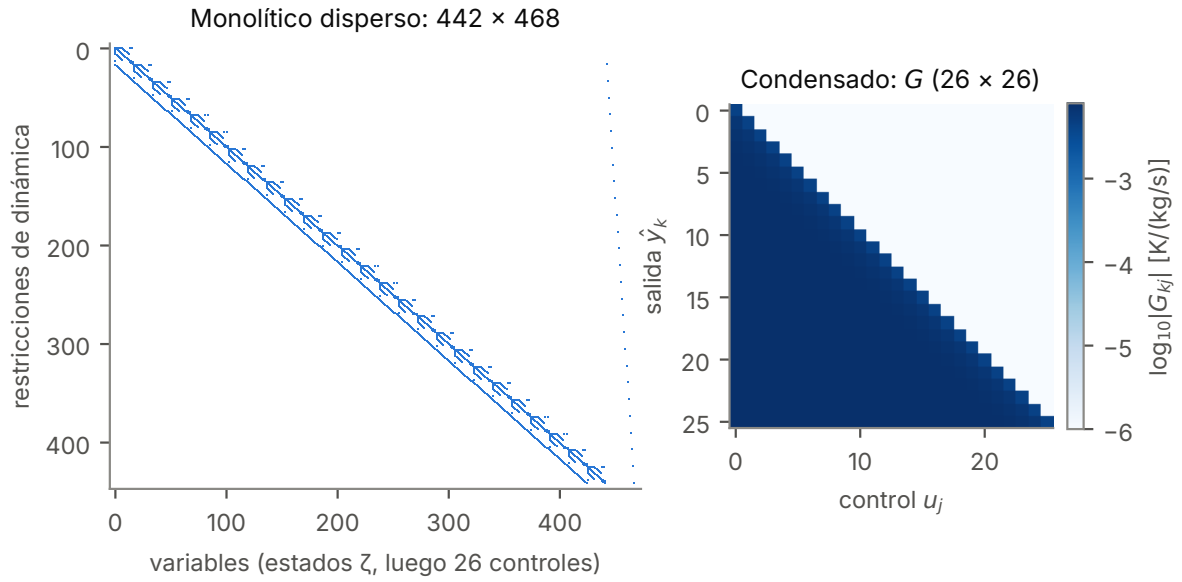


Figura 22: Estructura del QP de N1. Izquierda: restricciones de la forma dispersa, con bloques $(I - \Delta t A)$ en la diagonal, $-I$ en la subdiagonal y una columna por control. Derecha: matriz condensada G, triangular inferior y con columnas casi constantes, que son la huella del integrador del inventario.

Respuesta a Q1. Sí. El NLP resuelve P0 en ~ 0.05 s y el QP condensado en ~ 10 ms, frente a ~ 800 s de LJ, y la solución no depende de semillas. La linealización reproduce la decisión del NLP: N2 coincide con él y N1 se aparta poco. Una versión anterior de N2 se estancaba a 0.02 kg/s del NLP. La causa estaba en su implementación, que trabajaba con términos constantes del orden de 10^{16}; la formulación en desviaciones lo corrigió.

13 ¿Es el óptimo global? Certificación del P0 no lineal (F3c)

13.1 Planteamiento

El problema que se certifica es N3 en *espacio reducido*. Los estados se eliminan con la simulación, $x_k = \Phi(x_{k-1}, u_k)$, y el costo queda como función sólo del control: $J^\star = \min_{u \in \mathcal{U}} J(u)$, con $\mathcal{U} = [\dot{m}_{\text{min}}, \dot{m}_{\text{max}}]^{26}$. J se programó de forma genérica, de modo que se deriva *a través de la simulación*. En el paso implícito se resuelve Newton sobre valores y luego se hacen tres refinamientos con números duales, lo que da derivadas primeras y segundas exactas. El costo reducido en la solución coincide con el objetivo del NLP monolítico a $4 \cdot 10^{-8}$.

Paso	Pregunta	Tipo de resultado
1	¿La solución de Ipopt es un mínimo y no un punto de silla?	Prueba local
2	¿Cambia el óptimo con la discretización exacta de Simulink?	Consistencia
3	¿Hay otro óptimo mejor en la caja de control?	Evidencia global
4a	¿Cuánto podría mejorarse, si el residuo no lineal está bien estimado?	Brecha semi-rigurosa
4b	¿Cuánto podría mejorarse, con demostración?	**Brecha certificada**

Cuadro 12: Las pruebas de la certificación.

13.2 Paso 1: la solución es un mínimo local estricto

Se verificaron las tres condiciones de la proposición 4, con la hessiana calculada por diferencias centrales del gradiente exacto.

	$t_q = 1180$ s	$t_q = 1161$ s
Cotas activas / variables libres	6 superiores / 20	26 superiores / 0
Máx. $\lvert\partial J/\partial u\rvert$ en las libres	$8.7 \cdot 10^{-10}$	—
Menor multiplicador de cota activa	$3.2 \cdot 10^{-4}$	$4.2 \cdot 10^{-3}$
$\lambda_{\min}$ de la hessiana reducida	$4.3 \cdot 10^{-6}$ (condición $4.6 \cdot 10^{3}$)	— (vértice)
Conclusión	mínimo local estricto	mínimo local estricto en un vértice

Cuadro 13: Paso 1: condiciones de la proposición 4.

13.3 Paso 2: la discretización de Simulink da el mismo óptimo

Se resolvió P0 con la discretización `ode1be` (Ipopt en espacio reducido, con gradiente exacto). Su óptimo está a $4.5 \cdot 10^{-9}$ (1180 s) y $6.8 \cdot 10^{-7}$ (1161 s) del obtenido con Euler implícito convergido, con la misma primera acción. Las dos definiciones de P0 son equivalentes a efectos prácticos.

13.4 Paso 3: no aparece ningún óptimo mejor

- **Multistart** del NLP desde unos 590 arranques: aleatorios uniformes, caminatas aleatorias, constantes, bang-bang, alternados y, en 1180 s, las soluciones de LJ y GA. Todos convergen al mismo óptimo, a $\leq 5 \cdot 10^{-6}$ kg/s.
- **Evolución diferencial** sin derivadas (población 60, 1500 generaciones, 90 060 evaluaciones): queda a $+2.4 \cdot 10^{-7}$ del NLP en 1180 s y lo iguala en 1161 s.
- **Convexidad**: valores propios de $\nabla^2 J$ en 300 puntos de la caja (figura 23).

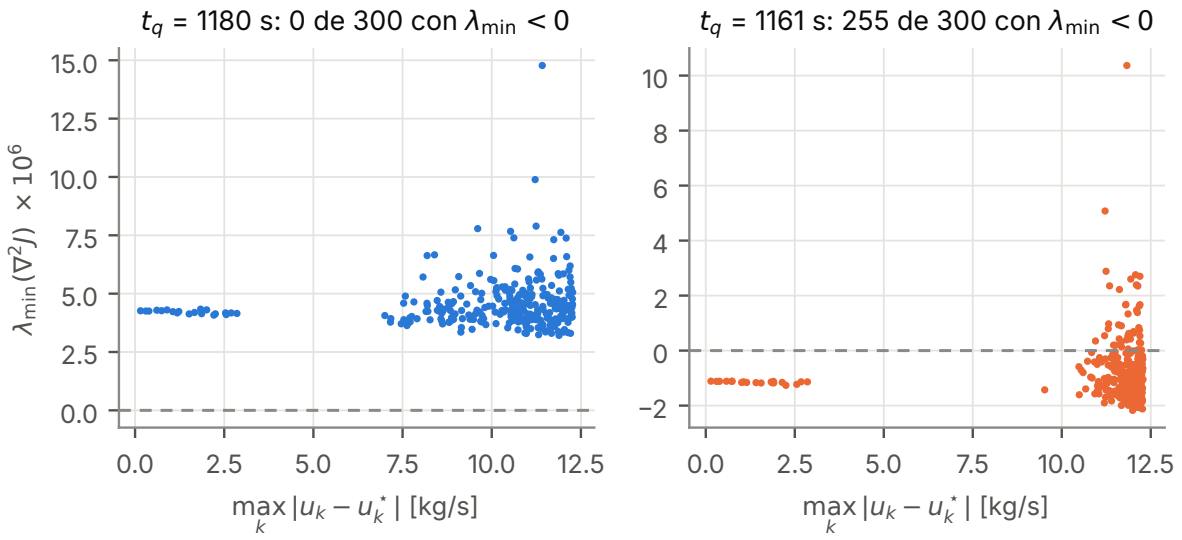


Figura 23: Menor valor propio de la hessiana del costo en 300 puntos de la caja. En 1180 s es positivo en todos. En 1161 s es levemente negativo en 255 puntos (hasta $-2 \cdot 10^{-6}$, un 0.006 % de $\lambda_{\max}$), también cerca del óptimo. Eso no contradice el paso 1: allí las 26 variables están en su cota con multiplicadores positivos, y las cotas bloquean la dirección de curvatura negativa.

La evidencia es fuerte, pero no es una prueba, y la no convexidad de 1161 s muestra que no se puede suponer convexidad. Hace falta una cota inferior.

13.5 Paso 4: una cota inferior del óptimo global

La idea es construir una función $L(u)$ que quede por debajo de $J(u)$ en *toda* la caja y que sea convexa. Su mínimo es una cota inferior de $J^\star$.

Proposición 12 (Cota inferior por relajación del residuo)**.** *Sea $a(u) = \hat{y}(u_c) + G(u - u_c)$ un modelo afín cualquiera de la salida y $e(u) = \hat{y}(u) - a(u)$ su residuo. Si $|e_k(u)| \le \varepsilon_k$ para todo $u \in \mathcal{U}$, entonces la función*

$$L(u) = \sum_k \left(|a_k(u) - y_{\text{ref}}| - \varepsilon_k\right)_+^2 + \lambda_m \sum_k \left[|u_{k+1} - u_k| - \Delta\dot{m}\right]_+^2 + \lambda_{\text{pct}} \sum_k \left[a_k(u) - \varepsilon_k - U_y\right]_+^2$$

es convexa, cumple $L(u) \le J(u)$ en $\mathcal{U}$, y $LB = \min_{u \in \mathcal{U}} L(u) \le J^\star$.

Demostración. Como $\hat{y}_k = a_k + e_k$ con $|e_k| \le \varepsilon_k$, se tiene $|\hat{y}_k - y_{\text{ref}}| \ge |a_k - y_{\text{ref}}| - \varepsilon_k$, y como el lado izquierdo es no negativo, $(\hat{y}_k - y_{\text{ref}})^2 \ge (|a_k - y_{\text{ref}}| - \varepsilon_k)_+^2$. También $\hat{y}_k - U_y \ge a_k - \varepsilon_k - U_y$ y $[\cdot]_+^2$ es creciente. El término de la rampa depende sólo de u y es idéntico. Sumando, $L \le J$. Cada término es la composición de una función convexa no decreciente, $t \mapsto (t)_+^2$, con una función convexa de u (el valor absoluto de una función afín, o una función afín), así que L es convexa. Por último, $LB = \min L \le L(u^\star) \le J(u^\star) = J^\star$, con $u^\star$ el óptimo global. □

$\min L$ se escribe como un QP: $t_k \ge 0$, $t_k \ge \pm(a_k - y_{\text{ref}}) - \varepsilon_k$ y se minimiza $\sum t_k^2$. Clarabel lo resuelve con su cota dual. Lo único difícil es obtener ε_k.

13.5.1 Paso 4a: residuo estimado por muestreo (semi-riguroso)

ε_k se estima con 3000 puntos aleatorios, 63 patrones extremos y una maximización adversaria de $\pm e_k$ con Ipopt. La búsqueda adversaria no superó al muestreo en ningún

paso. Con $u_c = u^\star$, la brecha es de **0.30 % (1180 s) y 1.2 % (1161 s)**, y de 0.59 % y 2.4 % si ε se duplica por seguridad. Es semi-rigurosa porque el muestreo podría no encontrar el peor residuo.

13.5.2 Paso 4b: residuo demostrado con aritmética de intervalos

Proposición 13 (Encierro del resto no lineal)**.** *Sea $\delta_k(u) = x_k(u) - x_k^c = T_k\Delta u + r_k$, con T_k la parte lineal exacta. Si en el paso k una caja de intervalos R cumple $\mathcal{F}_k(R) \subseteq R$, donde*

$$\mathcal{F}_k(R) = C_k\Big(r_{k-1} + h\big([A](Z_k) - A_k^c\big)\big(T_k[\Delta u] + R\big) - \mathrm{res}_k - D_k[\Delta u]\Big) + (I - C_k M_k^c)R,$$

$Z_k = x_k^c + T_k[\Delta u] + R$, $M_k^c = I - hA_k^c$ y $C_k \approx (M_k^c)^{-1}$, y si cada paso de Euler implícito tiene solución única cerca de la nominal, entonces $r_k(u) \in \mathcal{F}_k(R)$ para todo $u \in \mathcal{U}$.

Idea de la demostración. Restando el paso implícito de la trayectoria real y el de la nominal, y aplicando el teorema del valor medio a f fila por fila, $M_k^c\delta_k = \delta_{k-1} + hB\Delta u_k + h(A(\xi) - A_k^c)\delta_k - \mathrm{res}_k$, con $A(\xi)$ evaluado en puntos del segmento que une ambas trayectorias. Si $\delta_k \in T_k[\Delta u] + R$, esos puntos están en Z_k y $A(\xi) \in [A](Z_k)$. Restando la parte lineal, el resto cumple $r_k \in \mathcal{F}_k(R)$. Como $\mathcal{F}_k$ lleva R dentro de sí misma, el teorema de Brouwer asegura que existe una solución en R, y por unicidad es la verdadera. Los defectos de punto flotante (res_k, D_k y $I - C_kM_k^c$) se encierran con intervalos de redondeo dirigido. □

El residuo de salida es entonces $e_k \in S_{T_w} r_k[T_w] + \frac{1}{2}[p_4'](\cdot)\Delta u_k^2$, y ε_k es su mayor valor absoluto. Se verificó que el jacobiano por intervalos contiene los 1300 jacobianos muestreados por consulta, sin ninguna violación; que la caja R se acepta en los 26 pasos con dos iteraciones; y que el ε riguroso supera siempre al residuo muestreado del mismo modelo afín.

Centro u_c del modelo afín	ε_{26} riguroso / muestreado	Brecha 1180 s	Brecha 1161 s
$u^\star$ (solución del NLP)	0.50 / 0.010 K; 1.32 / 0.038 K	4.86 %	20.85 %
Punto medio de la caja	0.47 / 0.009 K; 0.48 / 0.010 K	**2.34 %**	**11.44 %**

Cuadro 14: Brecha certificada $(UB - LB)/UB$ sobre toda la caja de control. Con el centro en el punto medio, $LB = 0.23834$ (1180 s) y $LB = 42.533$ (1161 s).

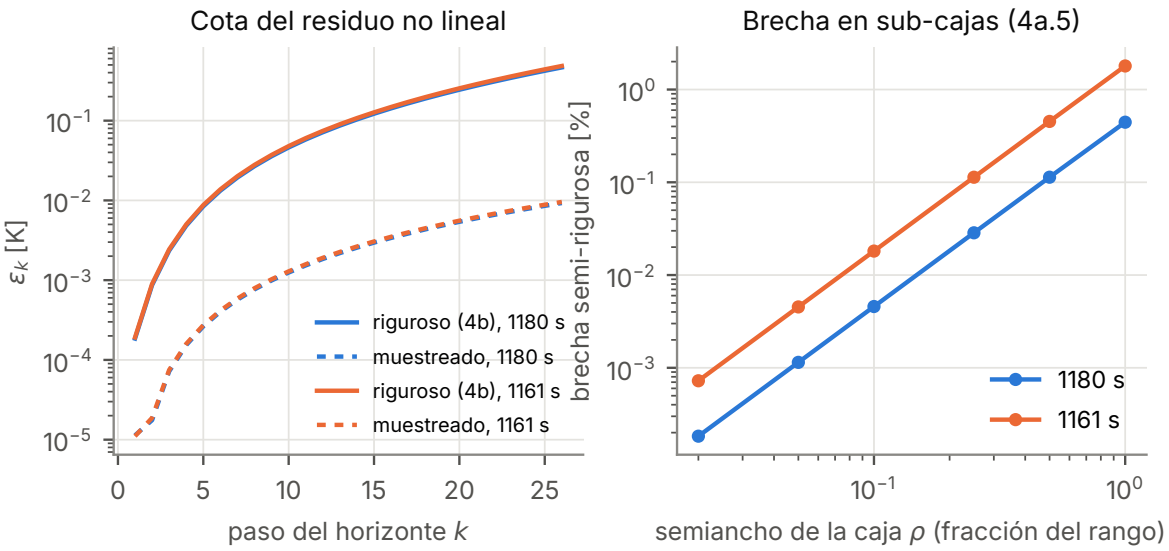


Figura 24: Izquierda: cota del residuo por paso del horizonte, rigurosa frente a muestreada. Derecha: brecha semi-rigurosa en sub-cajas de semiancho ρ alrededor de $u^\star$, que baja como ρ^2, como el resto de una expansión de Taylor.

Respuesta a Q2. La solución del NLP es un mínimo local estricto, es el único óptimo encontrado, y el óptimo global está demostradamente en $[0.23834,\ 0.24403]$ (1180 s) y en $[42.53,\ 48.03]$ (1161 s). Es decir, la solución está a menos del 2.3 % y del 11.4 % del óptimo global. La cota rigurosa sobreestima el residuo real entre 16 y 50 veces, porque acota el término de segundo orden como un producto de cajas e ignora que las 26 direcciones de control mueven el estado casi en una sola dirección. Ajustarla es el próximo paso; la evidencia de los pasos 1–3 indica que la brecha real es ≈ 0.

14 ¿Cuál método es mejor, y por cuánto?

14.1 Métodos comparados

Método	Modelo con el que decide	Formulación	Algoritmo	Tiempo
N3, NLP	ROM no lineal, Euler implícito	Monolítica dispersa, 519 variables	Ipopt, hessiana exacta	0.05 s
N3 sobre `ode1be`	ROM no lineal, `ode1be`	Espacio reducido, 26 variables	Ipopt, gradiente exacto, L-BFGS	2.5–10 s
N2	ROM linealizado por paso, iterado	QP condensado, 77 variables	SQP + Clarabel	10 ms por QP
N1	ROM linealizado en un punto	QP condensado, 77 variables	Clarabel	0.01 s
Evolución diferencial	ROM no lineal	26 variables	Sin derivadas, 90 060 evaluaciones	90 s
LJ corregido	ROM en Simulink	26 corrientes	Luus–Jaakola ($R = 24$, $\gamma = 0.9$, $M = 5$), 721 evaluaciones	≈ 800 s
GA	ROM en Simulink	26 corrientes	Genético 20×20, 420 evaluaciones	≈ 615 s
Lazo archivado	Lazo original, previo a la corrección de LJ	—	—	—

Cuadro 15: Métodos comparados. Los tiempos de LJ y GA son de MATLAB/Simulink; los demás, de Julia.

14.2 Cómo se compara

1. **Misma vara.** El control de cada método se evalúa con el costo P0 sobre el ROM *no lineal*, en las dos discretizaciones (dan el mismo ordenamiento). Nunca se usa el objetivo interno de cada solver: por ejemplo, el QP N1 predice 47.81 en 1161 s, pero su control cuesta 48.03 en el modelo no lineal.
2. **Mismas condiciones.** Mismo estado inicial, mismo pronóstico de fuga, misma referencia, mismas cotas del actuador y misma rampa. Las corrientes de LJ y GA se convierten a caudal con el mapa de la bomba, y su costo recalculado coincide con el medido en Simulink.
3. **Calidad garantizada.** Con la cota certificada de la sección anterior, el exceso real de cada decisión sobre el óptimo global queda en el intervalo de la proposición 10.

14.3 Resultados

	$t_q = 1180$ s			$t_q = 1161$ s	
Método	Costo	Exceso/mejor	Exceso garantizado	Costo	Exceso/mejor
N3, NLP	0.244034	0	0 – 2.4 %	48.028	0
N3 sobre `ode1be`	0.244034	0	0 – 2.4 %	48.028	0
N2, QP iterado	0.244034	0	0 – 2.4 %	48.028	0
N1, QP	0.244040	+0.0026 %	0.0026 – 2.4 %	48.028	0
Evolución diferencial	0.244034	+0.0001 %	0.0001 – 2.4 %	48.028	0
LJ corregido (3 semillas)	0.313 – 0.381	+28 a +56 %	28 – 60 %	—	—
GA (2 semillas)	0.349 – 0.353	+43 a +45 %	43 – 48 %	—	—
Lazo archivado	4.081	+1572 %	1572 – 1612 %	94.45	+97 %

Cuadro 16: Costo sobre el ROM no lineal de la decisión de cada método. En 1161 s el exceso garantizado de N1–N3 es 0–12.9 % y el del lazo archivado, 97–122 %; LJ y GA no tienen corridas completas en esa consulta.

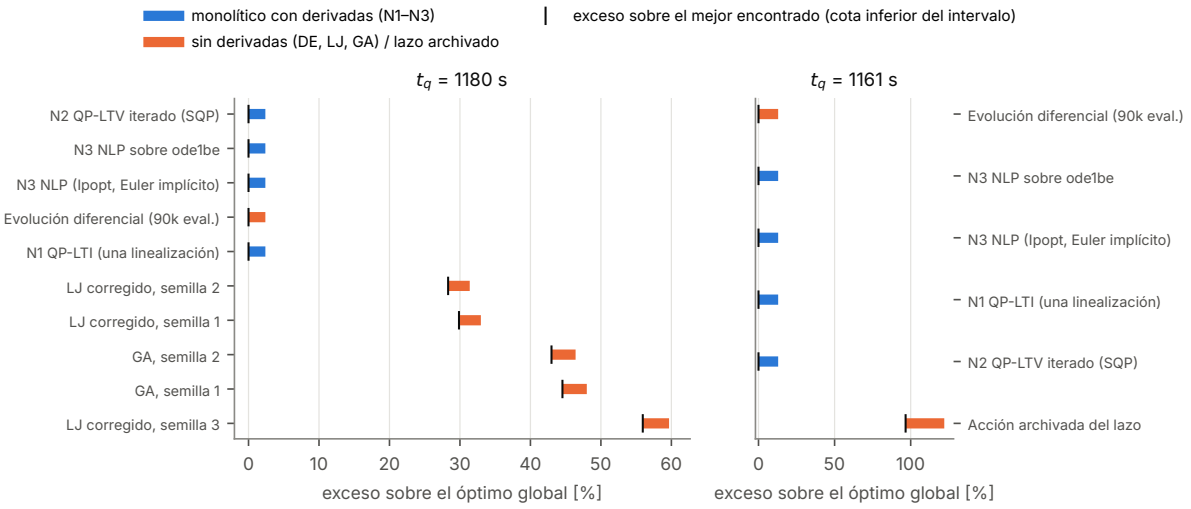


Figura 25: Intervalo de exceso garantizado de cada decisión. La marca negra es el exceso sobre el mejor encontrado y la barra llega hasta el límite que fija la cota certificada. En 1180 s se omite el lazo archivado (1572–1612 %).

Respuesta a Q3. N3 y N2 son los mejores y empatan: dan la misma decisión. N1 cuesta un 0.0026 % más en 1180 s y lo mismo en 1161 s; es el más rápido y el único QP convexo certificable, así que es el candidato natural para tiempo real. Los cuatro aplican la misma primera acción (56.75 A). LJ y GA quedan dominados con garantía: su exceso sobre el óptimo global es de al menos 28 % y 43 %, y tardan unas 10^4 veces más. La acción del lazo archivado era la peor: +1572 % en 1180 s y +97 % en 1161 s.

15 ¿El riesgo del pronóstico cambia la decisión? (F4)

El ensamble MC-dropout de la BiLSTM se regeneró sin MATLAB, reconstruyendo su ventana de entrada desde las trayectorias archivadas. La muestra que usó el lazo archivado cae dentro del ensamble. Además se halló que el lazo usaba `N_par = 1`: decidía con *una* realización aleatoria del dropout.

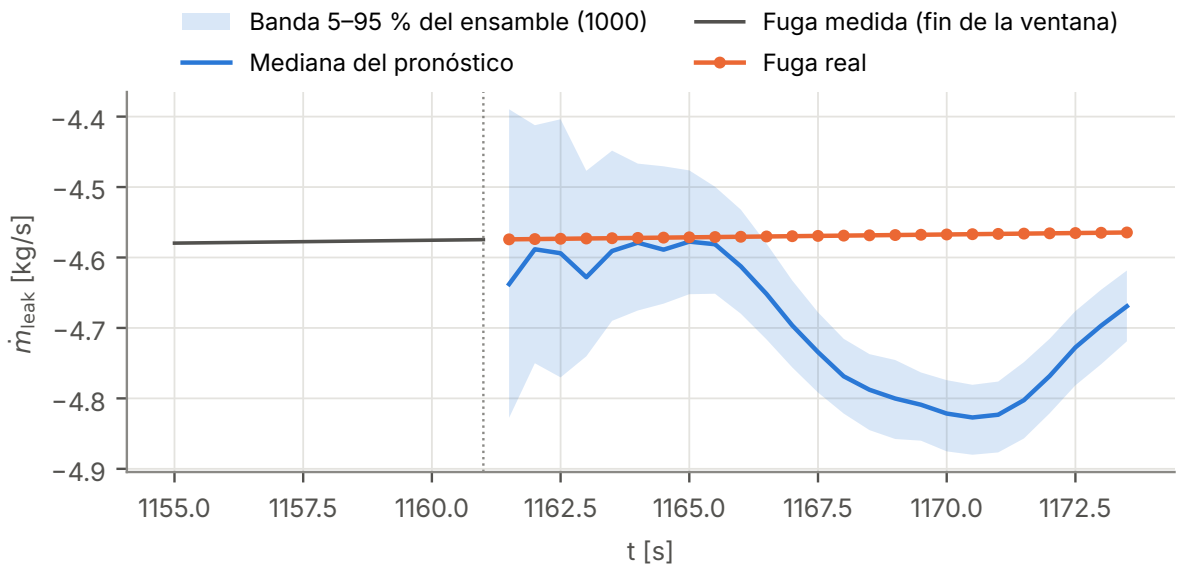


Figura 26: Pronóstico de la fuga en 1161 s frente a la fuga real del HRM, que queda en el borde superior de la banda del 90 % o fuera de ella.

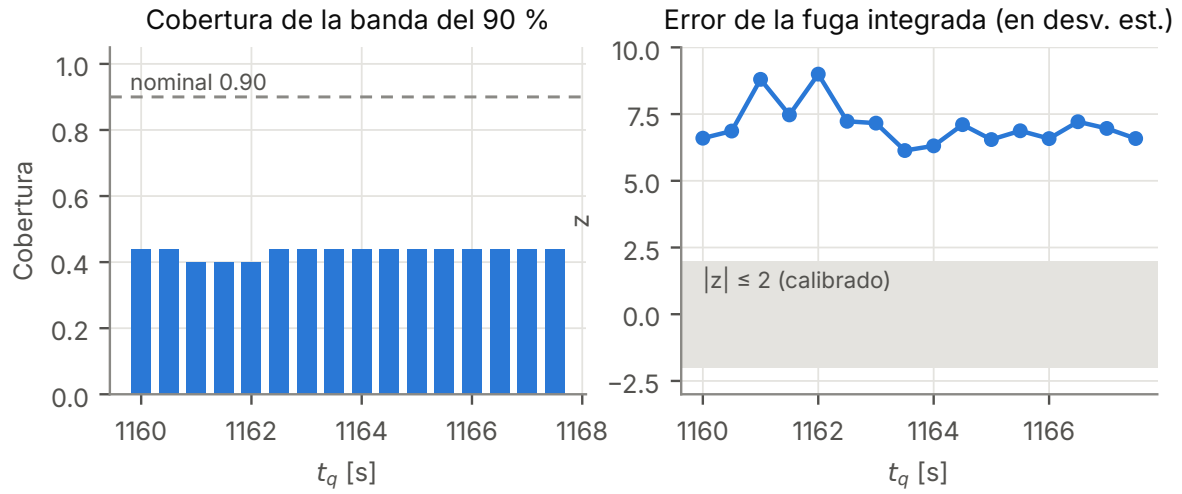


Figura 27: Calibración en 16 consultas. La banda del 90 % cubre la fuga real sólo el 44 % de las veces, y el error de la fuga integrada es de unas 7 desviaciones estándar.

El pronóstico está **sesgado** (unos 0.12 kg/s) y es **sobreconfiado**. Pero su efecto sobre la PCT es mínimo: el error, integrado en el horizonte (1.5 kg), equivale a ≈ 0.025 K, y la dispersión del ensamble a ≈ 0.003 K, frente a una autoridad del actuador de ≈ 2.4 K.

	$t_q = 1161$ s	$t_q = 1180$ s
u_0 con fuga p05, p50, p95, sin dropout, real y SAA de 59 escenarios	todas 56.750 A	todas 56.750 A
Costo medio fuera de muestra (941 escenarios), rango entre variantes	48.350 (idéntico)	0.2443–0.2480
Tiempo: NLP determinista / SAA de dos etapas	0.03 / 2.2 s	0.03 / 2.3 s

Cuadro 17: Decisiones bajo incertidumbre de pronóstico.

Respuesta a Q4. No. Ninguna variante del riesgo de pronóstico cambia la primera acción, ni siquiera cuando se amplía la autoridad del actuador para que no sature. El SAA de dos etapas es viable en tiempo real (~ 2 s). El riesgo que sí podría mover la decisión está en las fallas del ACS y en el desajuste entre el ROM y el HRM.

16 ¿Tienen base física las cotas del actuador?

Todos los resultados anteriores usan la cota archivada $u \in [56.69, 56.75]$ A. Al revisarla aparecieron tres hechos:

1. El ACS es una inyección de reposición de inventario. La banda exploratoria de ± 20 % sobre el caudal primario nominal no sirve como restricción de la consulta: el propio LOCA ya la violó ($\dot{m}_c \approx 0.6\,\dot{m}_{\text{nom}}$), y recuperar $0.8\,\dot{m}_{\text{nom}}$ exigiría unos 1700 kg.
2. El modelo de la bomba (ECM) corresponde a una *bomba principal*: ducto de 0.515×0.515 m, 15 kPa y 5543 kg/s a 2 m/s. El ACS usa el pie de su curva: 0–13 kg/s en 0.06 A, con 1 mA equivalente a 0.2 kg/s.
3. Por lo tanto, la cota en amperios no tiene significado físico. La cota defendible se expresa en kg/s, y debe acompañarse de un límite de rampa.

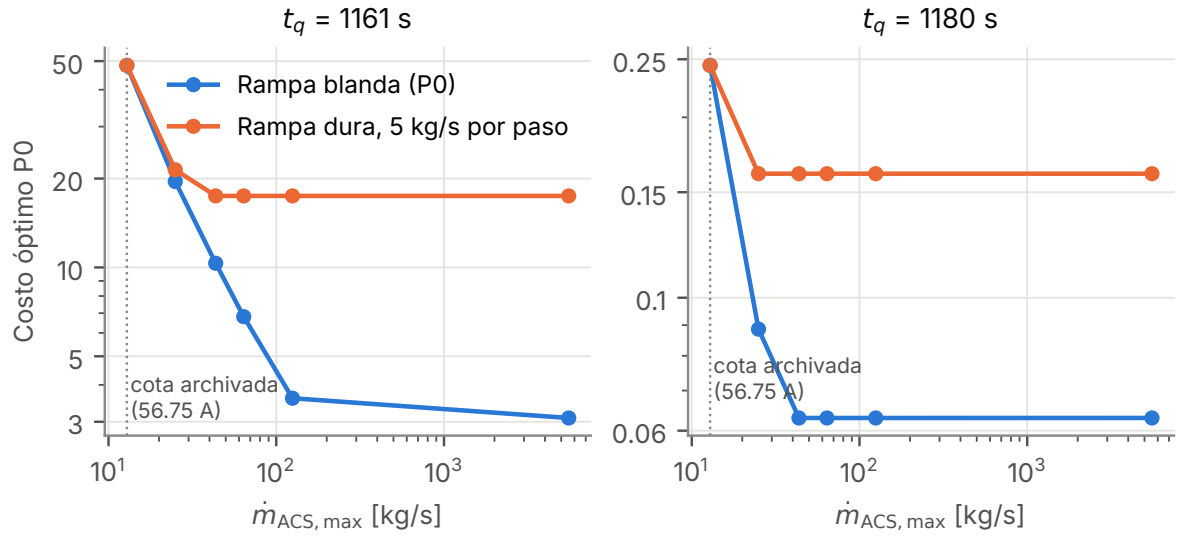


Figura 28: Costo óptimo según la cota de caudal, con la rampa blanda de P0 o con una rampa dura de 5 kg/s por paso.

Respuesta a Q5. No. Con una rampa dura, la cota de caudal deja de importar desde 25–44 kg/s: la autoridad la fija la rampa. La pregunta física pasa de "¿qué corriente máxima?" a "¿qué rampa admite la inyección?". El costo óptimo en 1161 s va de 3.1 a 48.4 según la cota y la rampa, así que este parámetro debe fijarse con el equipo antes de sacar conclusiones operativas.

17 Conclusiones

17.1 Respuestas a las preguntas

Q1. ¿Se puede resolver P0 con exactitud y en tiempo real? Sí. La formulación monolítica resuelve P0 en ~ 0.05 s (NLP) o ~ 10 ms (QP condensado), unas 10^4 veces más rápido que LJ y de forma reproducible.

Q2. ¿Es el óptimo global? La solución es un mínimo local estricto y el único óptimo hallado, y está demostradamente a menos del 2.3 % (1180 s) y del 11.4 % (1161 s) del óptimo global. La evidencia indica que la brecha real es ≈ 0.

Q3. ¿Cuál método es mejor? N3 y N2, empatados; N1 queda a 0.0026 %. LJ y GA cuestan al menos un 28 % y un 43 % más que el óptimo global.

Q4. ¿El riesgo de pronóstico cambia la decisión? No: su efecto sobre la PCT es unas 100 veces menor que la autoridad del actuador.

Q5. ¿Las cotas del actuador son físicas? No. Deben fijarse en kg/s, junto con una rampa admisible.

Método	Tiempo por consulta	Costo en 1180 s	Garantía
LJ corregido (mejor semilla)	≈ 800 s	0.313	ninguna; depende de la semilla
GA (mejor semilla)	≈ 615 s	0.349	ninguna; depende de la semilla
N3, NLP monolítico	0.05 s	0.24403	mínimo local estricto; a ≤ 2.3 % del óptimo global
N2, QP iterado	4 QP de 10 ms	0.24403	converge a un punto KKT de N3
N1, QP con una linealización	0.01 s	0.24404	óptimo global de su QP (brecha dual 10^{-12})

Cuadro 18: Resumen de los métodos en la consulta de 1180 s.

17.2 Lo que enseña este caso

1. **Conocer la estructura del problema vale más que la fuerza bruta.** Las metaheurísticas tratan el modelo como caja negra, y eso tiene sentido cuando el costo es discontinuo o ruidoso. En el horizonte del MPC, sin embargo, el costo es una función suave, y escribir el modelo como ecuaciones permite usar derivadas exactas.
2. **La física explica la solución.** La función de transferencia muestra que el ACS actúa a través de un integrador. Eso explica por qué la decisión óptima es saturar al principio y luego seguir la referencia, y por qué el actuador tiene tan poca autoridad en 12.5 s.
3. **Un modelo más simple puede bastar.** El QP con una sola linealización da prácticamente la misma decisión que el modelo no lineal completo, en una fracción del tiempo y con un certificado de optimalidad global para su propio problema.
4. **Resolver bien un problema no es lo mismo que resolver el problema correcto.** La brecha de un solver dice si cumplió con su modelo. Para comparar decisiones hace falta una vara común, el costo no lineal, y una cota inferior demostrada.
5. **Las garantías se construyen por capas**: condiciones locales, evidencia global y, por último, una cota inferior rigurosa con aritmética de intervalos.
6. **Los supuestos heredados deben revisarse.** La cota del actuador en amperios parecía un dato, y resultó ser un artefacto del modelo de la bomba.

17.3 Limitaciones

- Todo se demostró en dos consultas. Las conclusiones deben extenderse a las 61.

- La certificación vale para P0 sobre el ROM. No dice nada sobre el desajuste entre el ROM y el HRM, ni sobre el reactor real.
- Las cotas del actuador usadas son las archivadas, sin base física.
- La brecha certificada es conservadora, sobre todo en 1161 s.
- El riesgo por fallas del ACS, que es el que podría cambiar la decisión, todavía no se incorporó.

17.4 Próximos pasos, por prioridad

1. **Fijar el actuador con el equipo**: rampa admisible, caudal máximo y si el ACS repone inventario o impulsa el caudal primario. Es lo que más cambia los resultados: el costo óptimo en 1161 s va de 3.1 a 48.4 según la cota y la rampa.
2. **Riesgo por fallas del ACS** (leo_acer): SAA o MPC multietapa con no anticipación sobre los modos de falla y reparación del DET. Es la fuente de incertidumbre que podría mover la primera acción.
3. **Desajuste ROM–HRM** (leo_asus): re-simular en el HRM las acciones del NLP. Si el error es del orden de 1 K, es la incertidumbre que debería alimentar la restricción probabilística.
4. **Recalibrar el pronóstico** y usar $\texttt{N_par} > 1$ en el lazo: un pronóstico sobreconfiado invalida cualquier restricción probabilística basada en él.
5. **Más consultas** (leo_asus) y **lazo cerrado** sobre las 61 (F5).
6. **Ajustar la cota certificada** (paso 4b.5): partición por masa inyectada o modelo de Taylor de segundo orden.

A Notación

Símbolo	Significado
Reactor	
N, C_i, C_i^e	Población de neutrones; precursores dentro y fuera del núcleo (6 grupos)
ρ, ρ_0, β, Λ	Reactividad; reactividad estacionaria; fracción de neutrones retardados; tiempo de generación
λ_i, λ_c, λ_e	Constantes de decaimiento de los precursores; tasas de salida y de regreso al núcleo
α_f, α_c	Coeficientes de realimentación de temperatura del combustible y del refrigerante
T_f, T_w, T_c	Temperaturas medias del combustible, la pared y el plomo
M_c, ΔM	Inventario nominal de plomo; inventario ganado (negativo: perdido)
$\dot{m}_c$, $\dot{m}_{\text{nom}}$	Caudal primario actual y nominal (5550.5 kg/s)
h_{fw}, h_{wc}, A_{fw}, A_{wc}	Coeficientes y áreas de transferencia de calor combustible–pared y pared–plomo
p_4	Polinomio de corrección de la PCT (de la media al pico)
Control	
x, δ_k	Estado del ROM (17 componentes); desviación respecto de una trayectoria nominal
$u_k = \dot{m}_{\text{ACS},k}$	Caudal del ACS en el paso k (la decisión), en kg/s
$\hat{d}_k = \dot{m}_{\text{leak},k}$	Pronóstico de la fuga
$\hat{y}_k$, y_{ref}, U_y	PCT estimada, referencia y límite de seguridad
K, Δt (h), t_q	Horizonte (26 pasos), paso de tiempo (0.5 s), instante de la consulta
λ_m, λ_{pct}, $\Delta\dot{m}$	Pesos de las penalizaciones de suavidad y de seguridad; salto de caudal admitido
λ_j^{A}, μ_j^{A}	Tasas de falla y de reparación de los componentes del ACS
Optimización	
J, $J^\star$	Costo P0 y su óptimo global
UB, LB	Cotas superior e inferior de $J^\star$
A, B, E, D	Jacobianos de la dinámica respecto del estado, el control y la fuga; derivada de p_4
G, $G(s)$	Matriz condensada de sensibilidad de la salida al control (26×26); función de transferencia
$[A](Z)$	Jacobiano evaluado con aritmética de intervalos sobre la caja Z
ε_k	Cota del residuo no lineal en el paso k
N1, N2, N3	Formulaciones LTI, LTV iterada y no lineal
BE, `ode1be`	Euler implícito convergido; Euler implícito con una iteración de Newton (Simulink)

B Glosario

ACS
Sistema auxiliar de enfriamiento: repone plomo en el circuito primario con una bomba MHD.

A-estable
Propiedad de un integrador numérico que no amplifica los modos que decaen, cualquiera sea el paso.

BiLSTM
Red neuronal recurrente bidireccional con celdas de memoria de corto y largo plazo; aquí pronostica la fuga.

Brecha de optimalidad
Diferencia relativa entre una cota superior (el costo de una solución) y una cota inferior demostrada del óptimo global.

Cinética puntual
Modelo de la población de neutrones que supone una forma espacial fija del flujo.

Condiciones KKT
Condiciones de primer orden que cumple todo mínimo local regular de un problema con restricciones.

Convexo
Problema cuyo conjunto factible y costo son convexos; en él, todo mínimo local es global.

DET
Árbol dinámico de eventos: simulación que se ramifica cuando un componente falla o se repara.

Diferenciación automática
Cálculo exacto de derivadas propagando la regla de la cadena por las operaciones de un programa.

Disparo simple
Formulación de control óptimo en la que sólo los controles son variables y el costo se obtiene simulando.

HRM
Modelo de alta resolución (12 nodos) del SMDFR; hace de planta.

LOCA
Accidente con pérdida de refrigerante.

Metaheurística
Método de búsqueda general que sólo evalúa el costo (LJ, GA, DE, PSO).

MC-dropout
Estimación de la incertidumbre de una red neuronal repitiendo la inferencia con dropout activo.

MPC
Control predictivo basado en modelo: optimiza un horizonte futuro, aplica la primera acción y repite.

NLP / QP
Programa no lineal / programa cuadrático.

PCT
Temperatura pico de la vaina (aquí, de la pared de los tubos): el indicador de seguridad.

Precursores
Fragmentos de fisión que emiten neutrones retardados al decaer.

PSM / DSM
Margen probabilístico / determinista de seguridad.

Reactividad
Medida de cuánto se aparta el reactor de la criticidad, $\rho = (k-1)/k$.

ROM
Modelo reducido (un nodo por material) usado por el controlador para predecir.

SAA
Aproximación de una esperanza por el promedio sobre escenarios muestreados.

Transcripción directa
Formulación monolítica: estados y controles son variables, y la dinámica discretizada es un conjunto de restricciones.

C Reproducibilidad

- **Réplica y NLP**: `julia/SMDFRROM.jl`, `validate_replica.jl`, `f2_monolithic_nlp.jl`.
- **QP, certificados y forma condensada**: `julia/f3_certificates_condensed.jl`.
- **Certificación**: `julia/ReducedP0.jl`, `f3c_optimality.jl` (pasos 1–3), `f3c_lower_bound.jl` (4a), `f3c_rigorous.jl` (4b; centro con `F3C_CENTER=mid`), `f3c_compare_decisions.jl`.
- **Riesgo y actuador**: `python/f4_leak_ensemble.py`, `f4_forecast_calibration.py`, `julia/f4_risk_decisions.jl`, `f4_actuator_sweep.jl`.
- **Análisis didácticos** (valores propios, respuesta en frecuencia, curva de la bomba, autoridad): `julia/didactic_analysis.jl` ⇒ `results/didactic/`.
- **Resultados**: `results/f1_rom_replica/`, `f3_certificates/`, `f3c_optimality/`, `f4_risk/`, `didactic/`.
- **Figuras**: `python/make_status_figures.py` (resultados) y `python/make_didactic_figures.py` (capítulos introductorios). Las figuras de rigidez y de brecha de optimalidad en una dimensión son ejemplos ilustrativos, no resultados del modelo.
- **Documento**: `tectonic -X compile estado_mpc_monolitico.tex` desde `docs/`; los capítulos están en `docs/estado/`.

Referencias

[1] C. Liu, R. Luo, R. Macián-Juan. A new uncertainty-based control scheme of the small modular dual fluid reactor and its optimization. *Energies* 14 (2021) 6708. doi:10.3390/en14206708. Copia local: `docs/references/liuetal_smdfr.pdf`.

[2] A. Huke, G. Ruprecht, D. Weißbach, S. Gottlieb, A. Hussein, K. Czerski. The Dual Fluid Reactor — a novel concept for a fast nuclear reactor of high efficiency. *Annals of Nuclear Energy* 80 (2015) 225–235.

[3] M. Wang, X. He, R. Macián-Juan, X. Wang. One-dimensional transient analysis of the dual-fluid reactor system. *Annals of Nuclear Energy* 162 (2021) 108481. doi:10.1016/j.anucene.2021.108481.

[4] X. Zhang, P. Sun, L. Qiu, S. Pu, X. Wei. Transfer function modeling and simulation of HPR1000. *Annals of Nuclear Energy* 166 (2022) 108689. doi:10.1016/j.anucene.2021.108689.

[5] M. Nowak, M. Spirzewski, K. Czerski. Estudio sobre la optimización de bombas MHD de corriente continua para el Dual Fluid Reactor. *Annals of Nuclear Energy* (2022). doi:10.1016/j.anucene.2022.109142. (Referencia tomada de la documentación del proyecto, como fuente del modelo ECM de `CurrentToMassFlow.m`; título original no verificado aquí.)

[6] OECD/NEA. *Handbook on Lead-bismuth Eutectic Alloy and Lead Properties, Materials Compatibility, Thermal-hydraulics and Technologies*. NEA No. 7268, 2015.

[7] J. J. Duderstadt, L. J. Hamilton. *Nuclear Reactor Analysis*. Wiley, 1976.

[8] D. L. Hetrick. *Dynamics of Nuclear Reactors*. University of Chicago Press, 1971.

[9] F. P. Incropera, D. P. DeWitt, T. L. Bergman, A. S. Lavine. *Fundamentals of Heat and Mass Transfer*, 6.ª ed. Wiley, 2007.

[10] N. E. Todreas, M. S. Kazimi. *Nuclear Systems, Vol. I: Thermal Hydraulic Fundamentals*, 2.ª ed. CRC Press, 2011.

[11] J. B. Rawlings, D. Q. Mayne, M. M. Diehl. *Model Predictive Control: Theory, Computation, and Design*, 2.ª ed. Nob Hill Publishing, 2017.

[12] E. F. Camacho, C. Bordons. *Model Predictive Control*, 2.ª ed. Springer, 2007.

[13] J. Nocedal, S. J. Wright. *Numerical Optimization*, 2.ª ed. Springer, 2006.

[14] S. Boyd, L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004.

[15] L. T. Biegler. *Nonlinear Programming: Concepts, Algorithms, and Applications to Chemical Processes*. SIAM, 2010.

[16] J. T. Betts. *Practical Methods for Optimal Control and Estimation Using Nonlinear Programming*, 2.ª ed. SIAM, 2010.

[17] H. G. Bock, K. J. Plitt. A multiple shooting algorithm for direct solution of optimal control problems. *IFAC Proceedings Volumes* 17(2) (1984) 1603–1608.

[18] E. Hairer, G. Wanner. *Solving Ordinary Differential Equations II: Stiff and Differential-Algebraic Problems*, 2.ª ed. Springer, 1996.

[19] A. Wächter, L. T. Biegler. On the implementation of an interior-point filter line-search algorithm for large-scale nonlinear programming. *Mathematical Programming* 106 (2006) 25–57.

[20] P. J. Goulart, Y. Chen. Clarabel: an interior-point solver for conic programs with quadratic objectives. arXiv:2405.12762, 2024.

[21] I. Dunning, J. Huchette, M. Lubin. JuMP: a modeling language for mathematical optimization. *SIAM Review* 59(2) (2017) 295–320.

[22] J. Bezanson, A. Edelman, S. Karpinski, V. B. Shah. Julia: a fresh approach to numerical computing. *SIAM Review* 59(1) (2017) 65–98.

[23] J. Revels, M. Lubin, T. Papamarkou. Forward-mode automatic differentiation in Julia. arXiv:1607.07892, 2016.

[24] A. Griewank, A. Walther. *Evaluating Derivatives: Principles and Techniques of Algorithmic Differentiation*, 2.ª ed. SIAM, 2008.

[25] R. Luus, T. H. I. Jaakola. Optimization by direct search and systematic reduction of the size of search region. *AIChE Journal* 19(4) (1973) 760–766.

[26] D. E. Goldberg. *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, 1989.

[27] R. Storn, K. Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization* 11 (1997) 341–359.

[28] J. Kennedy, R. Eberhart. Particle swarm optimization. En *Proc. ICNN'95, International Conference on Neural Networks*, vol. 4, 1942–1948, 1995.

[29] S. Hochreiter, J. Schmidhuber. Long short-term memory. *Neural Computation* 9(8) (1997) 1735–1780.

[30] Y. Gal, Z. Ghahramani. Dropout as a Bayesian approximation: representing model uncertainty in deep learning. En *Proc. ICML*, 2016.

[31] S. S. Wilks. Determination of sample sizes for setting tolerance limits. *Annals of Mathematical Statistics* 12(1) (1941) 91–96.

[32] H. Glaeser. GRS method for uncertainty and sensitivity evaluation of code results and applications. *Science and Technology of Nuclear Installations* (2008).

[33] A. Hakobyan, T. Aldemir, R. Denning, S. Dunagan, D. Kunsman, B. Rutt, U. Catalyurek. Dynamic generation of accident progression event trees. *Nuclear Engineering and Design* 238(12) (2008) 3457–3467.

[34] M. Kloos, J. Peschke. MCDET: a probabilistic dynamics method combining Monte Carlo simulation with the discrete dynamic event tree approach. *Nuclear Science and Engineering* 153(2) (2006) 137–156.

[35] A. B. Owen. *Monte Carlo Theory, Methods and Examples*. Libro de acceso abierto, 2013.

[36] A. Charnes, W. W. Cooper. Chance-constrained programming. *Management Science* 6(1) (1959) 73–79.

[37] A. Shapiro, D. Dentcheva, A. Ruszczyński. *Lectures on Stochastic Programming: Modeling and Theory*. SIAM, 2009.

[38] T. Homem-de-Mello, J. Valencia, F. Lagos, G. Lagos. Forecasting outside the box: application-driven optimal pointwise forecasts for a class of two-stage stochastic programs. *Mathematical Programming* (2026). doi:10.1007/s10107-026-02359-9.

[39] G. P. McCormick. Computability of global solutions to factorable nonconvex programs: Part I — Convex underestimating problems. *Mathematical Programming* 10 (1976) 147–175.

[40] R. Horst, H. Tuy. *Global Optimization: Deterministic Approaches*, 3.ª ed. Springer, 1996.

[41] R. E. Moore, R. B. Kearfott, M. J. Cloud. *Introduction to Interval Analysis*. SIAM, 2009.

[42] K. Makino, M. Berz. Taylor models and other validated functional inclusion methods. *International Journal of Pure and Applied Mathematics* 4(4) (2003) 379–456.

[43] R. Krawczyk. Newton-Algorithmen zur Bestimmung von Nullstellen mit Fehlerschranken. *Computing* 4 (1969) 187–201.

[44] L. Benet, D. P. Sanders y colaboradores. `IntervalArithmetic.jl`: aritmética de intervalos validada en Julia. `https://github.com/JuliaIntervals/IntervalArithmetic.jl`.